



**Revisión sistemática del estado del arte de  
aplicaciones de la Inteligencia Artificial a la mejora  
de la salud y el bienestar de embarazadas**

**Andreea Madalina Oprescu**

Máster Universitario en Ingeniería Informática  
Departamento de Tecnología Electrónica  
Universidad de Sevilla

Dirigido por  
Dra. María del Carmen Romero Ternero

Julio 2020



Quiero agradecer en primer lugar a los miembros del equipo de revisión, que han hecho un gran trabajo colaborando en este proyecto y han aportado su experiencia y conocimiento. En especial, quiero agradecer a mi tutora, por todo su conocimiento y apoyo.

Me gustaría agradecer también a mis padres y reconocerles el gran trabajo y esfuerzo que llevan haciendo toda la vida.



# Índice general

<b>Índice de figuras</b>	<b>IX</b>
<b>Índice de tablas</b>	<b>XI</b>
<b>1. Introducción y contexto</b>	<b>1</b>
1.1. Descripción . . . . .	1
1.2. Antecedentes . . . . .	2
1.3. Motivación . . . . .	2
1.4. Objetivos . . . . .	4
<b>2. Estado del arte de las revisiones de la literatura científica</b>	<b>7</b>
2.1. Introducción . . . . .	7
2.2. Metodologías de revisión . . . . .	7
<b>3. Metodología de la revisión sistemática exploratoria (scoping review)</b>	<b>13</b>
3.1. Scoping Studies: towards a methodological framework . . . . .	14
3.2. Scoping Studies: advancing the methodology . . . . .	15
3.3. Enhancing the scoping study methodology . . . . .	18
3.4. Scoping reviews: time for clarity in definition, methods, and reporting . . . . .	20
3.5. Joanna Briggs Institute Reviewer's Manual . . . . .	21
3.6. PRISMA Extension for Scoping Reviews (PRISMA-ScR) . . . . .	27
<b>4. Protocolo desarrollado en la revisión sistemática exploratoria</b>	<b>31</b>
4.1. Título . . . . .	31
4.2. Resumen . . . . .	31
4.2.1. Antecedentes . . . . .	31
4.2.2. Métodos . . . . .	32
4.2.3. Resultados . . . . .	32
4.2.4. Conclusiones . . . . .	32

4.3.	Introducción . . . . .	32
4.3.1.	Justificación . . . . .	32
4.3.2.	Objetivos . . . . .	33
4.4.	Métodos . . . . .	34
4.4.1.	Protocolo y registro . . . . .	34
4.4.2.	Criterios de inclusión . . . . .	34
4.4.3.	Fuentes de información . . . . .	34
4.4.4.	Búsqueda . . . . .	35
4.4.5.	Selección de estudios . . . . .	39
4.4.6.	Proceso de extracción de datos . . . . .	40
4.4.7.	Variables de estudio . . . . .	41
4.4.8.	Síntesis de los resultados . . . . .	50
4.5.	Resultados . . . . .	50
4.5.1.	Selección de estudios . . . . .	50
4.5.2.	Características de los estudios . . . . .	52
4.5.3.	Resultados de la extracción de datos de cada estudio . . . . .	54
4.5.4.	Síntesis de los resultados . . . . .	57
<b>5.</b>	<b>Análisis de los resultados de la revisión sistemática exploratoria</b>	<b>59</b>
5.1.	Categorías analizadas . . . . .	59
5.1.1.	Descriptores (Author Keywords) . . . . .	59
5.1.2.	Países de publicación . . . . .	60
5.1.3.	Productos finales y sus funciones . . . . .	61
5.1.4.	Factores sociales, demográficos, etc. . . . .	63
5.1.5.	Estándares de la salud (Health standards) . . . . .	63
5.1.6.	Subcampo de Inteligencia Artificial . . . . .	63
5.1.7.	Fuente de los datos . . . . .	64
5.1.8.	Preprocesamiento de los datos . . . . .	65
5.1.9.	Tipo y técnica del modelo . . . . .	65
5.1.10.	Algoritmos . . . . .	66
5.1.11.	Validación y test del modelo . . . . .	66
5.1.12.	Lenguajes de programación y Frameworks . . . . .	67
5.1.13.	Seguridad TI y protección de datos personales . . . . .	68
5.1.14.	Procesos asociados al embarazo . . . . .	68
5.2.	Discusión . . . . .	104
5.2.1.	Resumen de los resultados . . . . .	104
5.2.2.	Limitaciones . . . . .	108

---

5.2.3. Conclusiones . . . . .	109
5.3. Lista de acrónimos . . . . .	109
<b>6. Análisis temporal, económico, de viabilidad y aplicabilidad</b>	<b>113</b>
6.1. Análisis temporal . . . . .	113
6.2. Análisis económico . . . . .	117
6.3. Análisis de viabilidad . . . . .	117
6.4. Análisis de aplicabilidad . . . . .	117
<b>7. Conclusiones</b>	<b>119</b>
7.1. Trabajo Futuro . . . . .	120
<b>Bibliografía</b>	<b>121</b>
<b>Apéndice A. Anexo A</b>	<b>139</b>
A.1. Python Script 1 . . . . .	139
A.2. Python Script 2 . . . . .	143
A.3. Python Script 3 . . . . .	146
A.4. Python Script 4 . . . . .	148
A.5. Python Script 5 . . . . .	150
A.6. Python Script 6 . . . . .	152





# Índice de figuras

4.1. Búsqueda en Scopus . . . . .	36
4.2. Búsqueda en Pubmed . . . . .	37
4.3. Búsqueda en Web of Science . . . . .	37
4.4. Búsqueda en ACM . . . . .	37
4.5. Búsqueda en IEEE Xplore . . . . .	38
4.6. Muestra del fichero de títulos y su origen . . . . .	38
4.7. Reparto de los documentos entre los miembros del equipo para la selección de los estudios . . . . .	39
4.8. Reparto de los documentos entre los miembros del equipo para la extracción de datos . . . . .	40
4.9. Esquema de componentes de Machine Learning I . . . . .	48
4.10. Esquema de componentes de Machine Learning II . . . . .	49
4.11. Diagrama de flujo de la estrategia de búsqueda e inclusión del protocolo desarrollado . . . . .	52
4.12. Estudios publicados a lo largo del periodo incluido en la revisión . . . . .	53
4.13. Tipología de los estudios . . . . .	53
4.14. Plantilla de extracción: bloque "General" . . . . .	54
4.15. Plantilla de extracción: bloque "Medicina" . . . . .	55
4.16. Plantilla de extracción: bloque "Computación" . . . . .	56
4.17. Plantilla de extracción: bloque "Tecnologías de la información" . . . . .	57
5.1. Descriptores más relevantes presentes en los estudios revisados . . . . .	60
5.2. Países de procedencia de los autores de los estudios revisados . . . . .	61
5.3. Producto final obtenido en los estudios revisados . . . . .	62
5.4. Subcampos de la Inteligencia Artificial tratados en los estudios revisados . .	64
5.5. Fuentes de adquisición de datos en los estudios revisados . . . . .	65
5.6. Lenguajes de programación empleados en los estudios revisados . . . . .	68
5.7. Procesos asociados al embarazo presentes en los estudios revisados . . . . .	69

6.1. Diagrama de Gantt del Trabajo Fin de Máster . . . . .	116
--	-----

# Índice de tablas

2.1. Método SALSA aplicado a los distintos tipos de revisión [1] . . . . .	9
5.1. Inteligencia artificial aplicada al estudio del embarazo prematuro . . . . .	70
5.2. Inteligencia artificial aplicada al estudio de los defectos de nacimiento . . .	71
5.3. Inteligencia artificial aplicada al estudio de la diabetes gestacional . . . . .	73
5.4. Inteligencia artificial aplicada al estudio de la pre-eclampsia y trastornos hipertensivos . . . . .	75
5.5. Inteligencia artificial aplicada al estudio del estado fetal . . . . .	78
5.6. Inteligencia artificial aplicada al estudio de la mortalidad . . . . .	80
5.7. Inteligencia artificial aplicada al estudio del parto . . . . .	82
5.8. Inteligencia artificial aplicada al estudio del crecimiento fetal . . . . .	84
5.9. Inteligencia artificial aplicada al estudio de la salud mental . . . . .	85
5.10. Inteligencia artificial aplicada al estudio de la calidad de vida . . . . .	88
5.11. Adquisición de datos y preprocesamiento según el proceso . . . . .	91



# Introducción y contexto

## 1.1. Descripción

En este Trabajo Fin de Máster (TFM) se describe pormenorizadamente el proceso completo de elaboración, incluyendo los resultados, de una revisión sistemática exploratoria (en inglés, *scoping review*) de la literatura científica de los últimos 12 años que trata sobre la aplicación de la Inteligencia Artificial (en adelante IA) en los ámbitos de salud y bienestar de las embarazadas. Asimismo, en este TFM se presentarán distintas tipologías y metodologías de revisión, con un mayor enfoque en la revisión sistemática exploratoria y la literatura que existe acerca de su elaboración (metodologías, guías, directrices, etc.). La metodología empleada para realizar la revisión es la propuesta por Arksey y O'Malley [2], en conjunción con las directrices de la guía PRISMA-ScR [3].

Las revisiones de tipo *scoping review* generalmente no son realizadas por una sola persona, ya que en todas las metodologías se establece la necesidad de llevarla a cabo en equipo, por varios motivos: la cantidad de trabajo es sumamente elevada para una sola persona, es necesaria la revisión y criterio de más de una persona para que la revisión tenga validez y representatividad, además, un equipo reducirá la probabilidad de que existan sesgos en la investigación. Por ello, esta revisión ha contado con un equipo de personas, que inicialmente fue de cuatro y finalmente, debido al volumen del estudio, ha sido de seis (tres perfiles del ámbito de la salud y tres perfiles del ámbito de las tecnologías de la información).

Este documento está organizado de la siguiente manera. En este primer capítulo se plantean la motivación, los antecedentes y los objetivos del TFM. El Capítulo 2 aborda el estado de la cuestión acerca de las revisiones de la literatura científica y sus distintas tipologías y aspectos más relevantes para su elaboración. Seguidamente, nos centramos en un tipo de revisión concreta, el *scoping review*, que se presenta de forma detallada en el Capítulo 3, contemplando definiciones, metodologías, guías, etc. Posteriormente, en el Capítulo 4, se describe pormenorizadamente el protocolo concreto de *scoping review* llevado a cabo en este caso, donde se explica detenidamente el proceso de ejecución de la revisión

(cómo se ha hecho), y se ha dedicado el Capítulo 5 para mostrar los resultados de la revisión (qué se ha hecho y qué se ha descubierto). En el Capítulo 6 se incluye un análisis temporal, económico, de viabilidad y de aplicabilidad del trabajo realizado en el TFM, y en último lugar, las conclusiones finales del TFM se exponen en el Capítulo 7.

Al final de este documento se incluye un capítulo donde se listan todas las referencias consultadas (Sección Referencias); un glosario de los acrónimos utilizados en las gráficas y las tablas desarrolladas para ilustrar los resultados del estudio (Sección 5.3); y una serie de anexos que se mencionan a lo largo del documento (Anexo A).

Los rótulos de las gráficas y las tablas utilizadas en esta memoria están en inglés, ya que serán empleadas directamente en el artículo que será enviado para publicación de este protocolo en una revista científica de impacto internacional.

## 1.2. Antecedentes

Durante el primer curso del Máster en Ingeniería Informática (2017-2018), la alumna autora de este TFM comenzó a colaborar con la tutora a través de una Beca de Colaboración para la investigación del Ministerio de Educación, Cultura y Deporte. En aquel momento, y en el marco de la beca, comenzaron a trabajar en una revisión sistemática exploratoria con la intención de encontrar las técnicas, metodologías, algoritmos y frameworks que se utilizaban en la Inteligencia Artificial y Computación Afectiva aplicada a la salud en general.

Ha sido durante este curso 2019-2020, cuando han trabajado en la revisión aquí presentada. La temática surgió a partir de una posible colaboración con médicos del Hospital Virgen del Rocío, interesados en técnicas de computación automatizadas que pudieran utilizarse para el diagnóstico precoz de trastornos en el embarazo y sobre las que investigar para mejorar la salud y el bienestar de las embarazadas. Ante la posibilidad de realizar un trabajo de investigación en esta temática, surgió la necesidad de realizar una revisión del estado del arte y se decidió abordarlo de forma rigurosa mediante una *scoping review*, que prometía ser el tipo de revisión que más se ajustaba a las necesidades planteadas en la fase actual del trabajo de investigación donde se está iterando sobre la pregunta de investigación.

## 1.3. Motivación

Durante el embarazo, hay un gran número de trastornos que pueden ser sufridas tanto por la embarazada como por el feto, además pudiendo éstas resultar en graves complicaciones, poniendo en peligro la vida de ambos. Es evidente que es un periodo que puede llegar a ser muy complicado y lleno de cambios, en el que la mujer debe adaptar sus hábitos de vida

(alimentación, deporte, sueño, trabajo, etc.), debe adquirir muchos nuevos conocimientos e información, y efectuar las visitas al médico que sean convenientes. Además, en algunos casos puede conllevar problemas psicológicos, como son la depresión, la preocupación y el estrés.

Durante las últimas décadas, la IA se ha ido aplicando cada vez más a distintas disciplinas, una de ellas ha sido la de la salud. Además de buscar estudiar la aplicación de la IA a la salud y bienestar de las embarazadas de forma general, en este trabajo se pretende investigar también el uso de la Computación Afectiva (*Affective Computing*). La Computación Afectiva es un campo multidisciplinar donde la computación da la mano a las ciencias cognitivas, la psicología, la fisiología y a otras ingenierías (eléctrica, mecánica y robótica). En este contexto, la máquina no solamente es capaz de reconocer, interpretar, procesar o simular las emociones humanas, si no que además puede adaptar su comportamiento en función de la emoción expresada por la persona con la que interacciona.

Son numerosas las revisiones realizadas y publicadas por la comunidad científica en relación a este tema. Tan solo durante el año 2019 y lo transcurrido del 2020, en la base de datos bibliográfica Scopus se obtienen más de 400 resultados si se buscan *reviews* o *survey* relacionadas con la Inteligencia Artificial o la Computación Afectiva en el ámbito de la salud (en concreto, la búsqueda es: ((survey OR review) AND (“artificial intelligence” OR “affective computing”) AND health) AND (LIMIT-TO (PUBYEAR , 2020) OR LIMIT-TO (PUBYEAR , 2019)) AND (LIMIT-TO (DOCTYPE, “re”))). El interés de la comunidad científica por esta rama de la computación y la salud es manifiestamente evidente. Se publican revisiones acerca de un gran número de temáticas, y para ilustrar este hecho, se nombrarán algunas de ellas:

- *Artificial Intelligence and Machine Learning in Cardiovascular Health Care* [4]
- *Artificial Intelligence and Machine Learning for HIV Prevention: Emerging Approaches to Ending the Epidemic* [5]
- *Deep learning in mental health outcome research: a scoping review* [6]
- *A review of dementia screening tools based on Mobile application. Health and Technology* [7]
- *Artificial intelligence in decision support systems for type 1 diabetes* [8]
- *Innovative assisted living tools, remote monitoring technologies, artificial intelligence-driven solutions, and robotic systems for aging societies: Systematic review* [9]

Aunque el término Inteligencia Artificial y Machine Learning aparecen de manera recurrente, la presencia de la Computación Afectiva es aún prácticamente anecdótica, no encontrando apenas resultados reseñables. Si entre los resultados de la revisión anterior se realiza la búsqueda de la palabra *affect* o *emotion*, las ocurrencias se reducen drásticamente a dos:

- *Wearable-Based Affect Recognition—A Review* [10]
- *Emotional expression in psychiatric conditions: New technology for clinicians* [11]

Si se busca *pregnan*, aparece un solo resultado: *Enabling pregnant women and their physicians to make informed medication decisions using artificial intelligence* [12]. Esta revisión es de tipo sistemática y se han revisado 31 artículos. Se estudian métodos de IA aplicados durante el embarazo con un enfoque en la optimización de los tratamientos y medicamentos tomados por la embarazada.

También se puede plantear una búsqueda más específica, en la que directamente se busca el término *pregnan*\*: TITLE-ABS-KEY (( survey OR review) AND (“artificial intelligence” OR “affective computing”) AND *pregnan*\*) AND (LIMIT-TO(DOCTYPE, re)) AND (LIMIT-TO (PUBYEAR, 2020) OR LIMIT-TO (PUBYEAR, 2019)). En Scopus aparecen ocho resultados, de los cuales los más relevantes y más relacionados con el embarazo, son:

- *Enabling pregnant women and their physicians to make informed medication decisions using artificial intelligence* [12]
- *Use of artificial intelligence (AI) in the interpretation of intrapartum fetal heart rate (FHR) tracings: a systematic review and meta-analysis* [13]

Utilizando un método formal de realización de revisiones sistemáticas sobre la literatura científica y analizando la información obtenida, este TFM pretende sentar las bases para la realización de un futuro trabajo de investigación en el marco de una tesis doctoral, facilitando una panorámica completa y obtenida de forma rigurosa de lo que acontece en esta materia (estado del arte).

## 1.4. Objetivos

Los objetivos planteados inicialmente en este TFM fueron los siguientes:

1. Objetivo 1: conocer y aplicar un método para la realización de revisiones sistemáticas científicas rigurosas.



2. Objetivo 2: estudio y análisis pormenorizado de la información para conocer qué técnicas de Inteligencia Artificial se aplican en el ámbito de la salud y el bienestar de las embarazadas.
3. Objetivo 3: realizar una propuesta de arquitectura desde el punto de vista de los sistemas de información necesarios para abordar el desarrollo de una solución que permita abordar un problema clínico concreto.

Como queda reflejado a lo largo de esta memoria se han completado con creces los objetivos 1 y 2. Asimismo, en el camino se han conseguido logros que inicialmente ni siquiera estaban planteados, como la profundización en el conocimiento de la rama de *Machine Learning* como paso previo a la revisión. Sin embargo, el tercer objetivo finalmente se ha quedado fuera del alcance del TFM debido a que, como se explica en los siguientes apartados, el volumen de artículos que se ha tenido que analizar en la revisión sistemática ha sido muy elevado, requiriendo una dedicación mayor de lo previsto inicialmente. No obstante, la autora de este TFM ha sido admitida en el programa de doctorado Ingeniería Informática, donde se prevé que este tercer objetivo sea abordado durante la realización de su tesis doctoral en el marco de la colaboración mencionada con médicos e investigadores del Hospital Virgen del Rocío.

El objetivo global de este trabajo fin de máster, por tanto, ha sido la aplicación de un método sistemático de revisión de la literatura científica para identificar nichos de investigación en el dominio de la IA aplicada a la salud y, en particular, en el ámbito de los procesos asociados al embarazo y del bienestar de las embarazadas.



# Estado del arte de las revisiones de la literatura científica

## 2.1. Introducción

En este capítulo se va a tratar el estado de la cuestión sobre las revisiones de la literatura científica y distintos tipos de revisiones y metodologías para llevarla a cabo. Una revisión de la literatura es una búsqueda y evaluación de la literatura científica existente en un tema concreto. El resultado es el estado del arte del tema que está siendo tratado en la revisión. Una revisión permite a su autor (o autores) obtener un mejor entendimiento y familiarización con el tema que se está tratando, así como una visión más global, al conocer lo que ya se sabe y se ha trabajado acerca de dicho tema. Asimismo, se comprenderá mejor el desarrollo que el tema ha ido teniendo a lo largo de los años al conocer los pasos que otros autores han realizado previamente. Esta exploración de la literatura puede ser más o menos exhaustiva, evaluando la calidad de la misma o no. En resumen, una revisión de la literatura y la forma de realizarla ha de ser ajustada a las necesidades del autor (o autores), por lo cual, es muy importante plantearse el objetivo de la misma. Es también importante conocer las distintas tipologías de revisión que hay y las distintas metodologías que existen para su realización. En la siguiente sección se verán algunos ejemplos.

## 2.2. Metodologías de revisión

Los autores Grant y Booth identifican en [1] los catorce tipos de revisión más comunes. Proporcionan una descripción de cada uno, así como características clave, ventajas, y debilidades. Reflejan, para cada tipo de revisión, cómo se llevan a cabo cada uno de los siguientes pasos: búsqueda, evaluación, síntesis y análisis, utilizando el marco de referencia SALSA (*Search, Appraisal, Synthesis and Analysis*). También en este trabajo, los autores presentan

ejemplos de cada tipo de revisión dentro del campo de la salud y de la informática aplicada a la salud. De forma análoga, se presentarán en esta sección ejemplos más actualizados de cada tipo de revisión.

1. **Revisión crítica** (*Critical review*): El autor de la revisión ha investigado de forma exhaustiva la literatura sobre un tema y ha evaluado la calidad de la misma. Va más allá de la simple descripción, incluyendo un alto grado de análisis. Como resultado se puede esperar generalmente una hipótesis o un modelo.
2. **Revisión de la literatura** (*Literature review*): Término genérico que engloba todo tipo de material que examine literatura científica reciente. Puede cubrir una gran variedad de tópicos a distintos niveles de exhaustividad.
3. **Mapecto sistemático** (*Systematic map / Mapping review*): Relacionar y clasificar la literatura, para elaborar futuras revisiones o estudios si se ha encontrado un nicho de investigación.
4. **Meta-análisis** (*Meta-analysis*): Uso de técnicas que combinan resultados estadísticos de estudios cuantitativos para obtener una precisión en el resultado. Los estudios incluidos han de ser lo suficientemente similares en sus características: población objetivo, el tipo de intervención, etc.
5. **Mixed studies review/Mixed methods review**: Uso de técnicas que combinan resultados estadísticos de estudios cuantitativos para obtener una precisión en el resultado. Los estudios incluidos han de ser lo suficientemente similares en sus características: población objetivo, el tipo de intervención, etc
6. **Revisión general** (*Overview*): Término genérico para referirse a los sumarios de literatura que consisten en repasos y descripciones de la misma.
7. **Revisión sistemática cualitativa / Síntesis cualitativa** (*Qualitative systematic review / Qualitative evidence synthesis*): Integrar o comparar los resultados y conclusiones de estudios cualitativos.
8. **Revisión rápida** (*Rapid review*): Análisis sobre lo conocido acerca de políticas o prácticas. Se utilizan técnicas de las revisiones sistemáticas para efectuar la búsqueda y se evalúa de forma crítica la evidencia científica.
9. **Revisión sistemática exploratoria**: Identificar la naturaleza y extensión de la evidencia científica acerca de un tema, incluyendo la investigación en curso. Una primera evaluación acerca del alcance y cantidad del conocimiento disponible.

10. **Revisión de estado del arte** (*State-of-the-art review*): Generalmente atienden a cuestiones recientes. Se ofrecen nuevas perspectivas o se destaca un área donde se necesita más conocimiento.
11. **Revisión sistemática** (*Systematic review*): Búsqueda sistemática de evaluación y síntesis de la evidencia científica. De forma habitual se utilizan metodologías para llevar a cabo este tipo de revisión.
12. **Búsqueda y revisión sistemática** (*Systematic search and review*): Este tipo de revisiones combinan las ventajas de las revisiones críticas con una estrategia exhaustiva de búsqueda. Atienden generalmente a preguntas amplias.
13. **Revisión sistematizada** (*Systematized review*): Se utilizan técnicas de las revisiones sistemáticas pero a una menor escala. Generalmente se realizan por estudiantes.
14. **Umbrella review**: Recopilación de información de múltiples revisiones en un solo documento. Se estudian problemas para los cuales existen distintos tipos de intervenciones y se revisan las distintas revisiones y sus resultados, en las que se mencionan los distintos tipos de intervención.

Tabla 2.1 Método SALSA aplicado a los distintos tipos de revisión [1]

Revisión	Búsqueda	Evaluación	Síntesis	Análisis
Revisión crítica	Identificar los términos más significativos	Evaluar acorde a la contribución	Narrativa, conceptual o cronológica	Identificar las contribuciones de las que poder formular teorías
Revisión de la literatura	Exhaustiva o no	Análisis de calidad opcional	Generalmente narrativa	Conceptual, temático, cronológico, etc.
Mapeo sistemático	Alcance delimitado por objetivo y periodo de estudio	No hay análisis formal de la calidad	Gráficos y/o tablas	Tipología, diseño u otras características. Identificación de necesidad de investigación, revisiones.

continuación

Tabla 2.1 – continuación

<b>Revisión</b>	<b>Búsqueda</b>	<b>Evaluación</b>	<b>Síntesis</b>	<b>Análisis</b>
Meta-análisis	Exhaustiva	Calidad: criterio de inclusión o exclusión (opcional)	Gráficas y tablas con complementos narrativos	Conceptual, temático, cronológico, etc.
Mixed studies review	Estrategia amplia	Calidad: criterio de inclusión o exclusión (opcional)	Gráficas y tablas con complementos narrativos	Numérico, asumiendo la falta de heterogeneidad.
Revisión general	Exhaustiva o no (dependiendo de si se trata de revisión general sistemática)	Calidad: criterio de inclusión o exclusión (opcional, dependiendo de si se trata de revisión general sistemática)	Generalmente narrativo, puede incluir tablas	Cronológico, conceptual, temático, etc.
Revisión sistemática cualitativa	Puede utilizar elección deliberada de muestras	Criterios de calidad para la evaluación, no para incluir o no	Narrativo cualitativo	Temático, modelos conceptuales
Revisión rápida	Alcance delimitado por objetivo y periodo de estudio	Time-limited formal quality assessment	Generalmente narrativo con tablas	Cantidad de evidencia y calidad
Revisión sistemática exploratoria	Alcance delimitado por objetivo y periodo de estudio. Trabajos en proceso.	Calidad: criterio de inclusión o exclusión (opcional)	Generalmente formato de tablas, incluyendo resumen narrativo	Agrupación por tipología, diseño del estudio, u otras características clave.

continuación

Tabla 2.1 – continuación

<b>Revisión</b>	<b>Búsqueda</b>	<b>Evaluación</b>	<b>Síntesis</b>	<b>Análisis</b>
Estado del arte	Exhaustiva, busca literatura reciente	No hay análisis formal de la calidad	Generalmente narrativo, puede incluir tablas	Estado actual del conocimiento y trabajo futuro
Revisión sistemática	Exhaustiva	Calidad: criterio de inclusión o exclusión (opcional)	Generalmente narrativo con tablas	Qué se conoce y se desconoce, recomendaciones para la toma de decisiones y estudios futuros
Búsqueda y revisión sistemática	Exhaustiva	Análisis de calidad opcional	Mínimamente narrativo. Estudios resumidos en formato de tabla	Qué se conoce, recomendaciones para la práctica. Limitaciones
Revisión sistematizada	Exhaustiva o no	Análisis de calidad opcional	Generalmente narrativo con tablas	Qué se conoce
Umbrella review	Únicamente revisiones	Análisis de la calidad de los estudios que componen la revisión y/o de la revisión	Gráficas y tablas con complementos narrativos	Qué se conoce, limitaciones de la metodología





# Metodología de la revisión sistemática exploratoria (scoping review)

La primera definición de una revisión sistemática exploratoria (*scoping review*, en inglés) la ofrecen en el año 2001 Mays et al. [14]: “relacionar los conceptos clave subyacentes a un área de investigación con las principales fuentes y tipos de evidencia disponibles, de una manera ágil, pudiendo realizarse como proyectos individuales, especialmente cuando un área de estudio es muy compleja y no ha sido revisada de forma comprensiva con anterioridad”.

Los autores Arksey y O'Malley [2] trabajando sobre la definición dada por Mays et al. [14], describen en el año 2005 una metodología con la intención de comenzar a desarrollar un marco de referencia para la realización de este tipo de revisiones. Levac y Colquhoun [15] revisan y mejoran la metodología en el año 2010, y sobre este trabajo, tres años más tarde, Daudt et al. [16] proponen otro conjunto de mejoras. En 2014, Colquhoun y Levac [17] plantean recomendaciones para llegar a una clarificación y consenso de términos, definiciones y metodologías.

Basándose en todos estos trabajos anteriores, en 2015 Peters et al. [18] publican de la mano del Instituto Joanna Briggs (JBI), un documento guía para la realización de revisiones sistemáticas exploratorias, posteriormente actualizado en 2017 como un capítulo dentro del Manual del Revisor del Instituto Joanna Briggs [19].

A pesar de la existencia de metodologías y guías, Tricco et al. [20] identifican la necesidad de una mayor transparencia y de mejorar el modo en el que se informa sobre cómo se ha ejecutado la revisión. Finalmente, en 2018, de la mano de investigadores del mismo equipo, nace PRISMA-ScR (*Preferred Reporting Items for Systematic reviews and Meta-Analyses extension for Scoping Reviews*) checklist and explanation [3]. Como su propio título indica, es una extensión para *scoping review* de PRISMA [21], una guía para informes (*reporting guideline*) para revisiones sistemáticas y meta análisis de estudios. El Manual del Revisor del Instituto Joanna Briggs [19] cuenta con actualizaciones periódicas y a día de hoy, es consistente con las directrices expuestas en PRISMA-ScR [3].

A continuación se detallarán los trabajos más relevantes de los arriba mencionados.

### 3.1. Scoping Studies: towards a methodological framework

El trabajo de Arksey y O'Malley [2] es el primero en ofrecer a los investigadores un marco de referencia a seguir a la hora de elaborar una revisión sistemática exploratoria. Con una revisión de esta naturaleza, se pueden cumplir los siguientes objetivos:

1. Examinar el alcance y naturaleza de la investigación científica: obtener una visión general acerca de la literatura existente sobre un tema de interés.
2. Como paso previo de una revisión sistemática: buscar si hay suficiente literatura al respecto, la existencia de otras revisiones, así como el coste que puede conllevar su realización. En resumen, estudiar la viabilidad de una revisión sistemática.
3. Resumir y divulgar resultados científicos.
4. Identificar una ausencia de evidencia científica sobre un tema. Hay que tener en cuenta que, al no evaluar la calidad de la investigación, se pasarán por alto dichas ausencias donde la evidencia científica exista pero no sea de una cierta calidad.

El proceso que proponen a través de la metodología es iterativo, por lo que los investigadores pueden repetir los pasos que consideren necesarios. A lo largo de la definición y explicación de los pasos de la metodología, los autores también proveen ejemplos. Los pasos son los siguientes:

1. **Identificar la pregunta de investigación:** es el punto de partida. Es necesario encontrar los aspectos relevantes ya que son los que guiarán la elaboración de la revisión: ¿qué se espera encontrar? Puntualizan que una pregunta de investigación muy amplia aseguraría en mayor medida la cobertura de más literatura, pero generaría una gran cantidad de referencias. Este tipo de enfoque es conocido como búsqueda en anchura.
2. **Identificar estudios relevantes:** definen distintas vías donde encontrar evidencia científica, destacando en este punto que es necesario limitar tanto los idiomas como el periodo de estudio de dicha evidencia. Esta decisión implica que se pueden perder estudios relevantes. Las posibles fuentes pueden ser: bases de datos electrónicas, bibliografías de los estudios (especialmente revisiones), búsqueda manual en revistas de interés, organizaciones relevantes, conferencias, redes de contactos.

3. **Selección de los estudios:** es necesario desarrollar un criterio para decidir, de todos los estudios recuperados en el punto anterior, cuáles son relevantes para la pregunta de investigación, ya que dependiendo de cómo se haya definido la búsqueda, cabe la posibilidad de que se hayan recopilado estudios que no lo son. Para ello, se definen los criterios de inclusión y exclusión, que al menos dos revisores aplicarán a todos los estudios. En principio, los revisores leen el resumen del estudio, y en el caso de que no quedara claro, se revisaría todo el documento. En una siguiente iteración, los revisores leen el estudio completo para decidir su inclusión o exclusión.
4. **Extracción de la información:** identificar los conceptos y términos clave que se quieren cubrir con la revisión, para localizarlos en los estudios. Por ejemplo: autores, año de la publicación, lugar del estudio, objetivo, metodología, conclusiones, etc.
5. **Recopilación, resumen e informe de los resultados:** con el objetivo de presentar una visión general de todo el material que se ha revisado. Pueden utilizarse distintas formas de representación de la información, como gráficas, tablas, imágenes, etc.
6. **Consultar la información (opcional):** en algunos casos puede ser interesante consultar, a modo de asesoría, los resultados con beneficiarios, clientes, etc, que podrían aportar información relevante.

Entre las ventajas de la revisión sistemática exploratoria, los autores destacan que permite presentar la información e identificar carencias en un tema, empleando menos tiempo que una revisión sistemática, pero también presenta las siguientes desventajas: no evalúa la calidad de la literatura, puede generar una gran cantidad de información que revisar, y puede ser complicado decidir sobre si la búsqueda se realizará en anchura o en profundidad y en qué medida.

Algo que es importante destacar, es que los autores no proponen su trabajo como una metodología completa y finalizada, si no que animan a otros a que trabajen sobre ella para mejorar aspectos de la misma. Es por ello que podemos encontrar un gran número de trabajos realizados en torno a esta primera versión de la metodología.

## 3.2. Scoping Studies: advancing the methodology

Con el objetivo de presentar una mejora, en este artículo [15] los autores elaboran varias *scoping reviews* guiándose por la metodología propuesta por Arksey y O'Malley [2], lo que les permite identificar dificultades y retos a la hora de su implementación. Para cada uno de los

pasos, enumeran *los siguientes retos encontrados* con las correspondientes recomendaciones para su superación:

### Identificar la pregunta de investigación

1. *Las preguntas de investigación planteadas son demasiado amplias.*
  - Es necesario definir una pregunta de investigación que el equipo revisor pueda abarcar. Para ello, considerar los conceptos que se quieren cubrir, la población objetivo y los efectos en salud que se quieren estudiar, a fin de delimitar la pregunta y los objetivos.
2. *Establecer el objetivo del scoping review no está asociado a ningún paso de la metodología.*
  - Visualizar el resultado esperado y tener en mente la pregunta de investigación a la hora de definir el objetivo de la revisión.
3. *Los motivos por los que realizar una revisión sistemática exploratoria no están lo suficientemente claros.*
  - Considerar los motivos de realizar una revisión sistemática exploratoria para determinar su finalidad.

### Identificar estudios relevantes

1. *Realizar una búsqueda nivelada tanto en anchura como en profundidad puede ser complicado si se cuenta con recursos limitados.*
  - Las decisiones deberían tomarse teniendo en mente la pregunta de investigación y el objetivo.
  - En lo que respecta al equipo revisor, la experiencia y adecuación de sus miembros puede ser un factor determinante en el buen resultado.
  - Justificar la decisión de reducir el alcance en el caso que sea absolutamente necesario y reconocer las potenciales limitaciones de la revisión.

### Selección de estudios

1. *Se describe este paso como si se tratase de uno lineal, cuando en realidad debería ser iterativo.*

- Este paso debería ser un proceso iterativo, consistiendo en las siguientes tareas: buscar en la literatura, refinar la estrategia de búsqueda y revisar artículos para su inclusión.

2. *No queda claro el proceso de toma de decisiones respecto a la inclusión de artículos.*

- Al comienzo del proceso, el equipo debería reunirse para poner en común los criterios de inclusión y exclusión. Al menos dos miembros han de revisar de forma independiente el resumen de cada artículo.
- Los revisores deberían reunirse al comienzo, mediados y final de la revisión para puestas en común, aclaraciones y resolución de dudas y dificultades que puedan surgir a lo largo del proceso. Si fuese necesario, se puede refinar la búsqueda y volver a realizarla.
- Dos revisores, de manera independiente, deberían revisar el artículo completo para decidir su inclusión.
- Ante desacuerdos acerca de la inclusión o descarte de un artículo, el desempate lo debería de realizar un tercer revisor.

### **Extracción de la información**

1. *No queda claro qué datos se han de extraer de los estudios incluidos.*

- El equipo revisor debería desarrollar conjuntamente la plantilla de extracción. Es fundamental tener presente la pregunta de investigación ya que se debe responder con la información extraída.
- Este paso debería realizarse de manera iterativa: la necesidad de adecuar, pulir, mejorar, la plantilla puede surgir a lo largo del proceso de extracción de información, y se ha de hacer las veces que se estime oportuno.
- Antes de comenzar con el proceso de extracción de información, dos miembros del equipo pueden extraer de forma independiente datos de algunos estudios incluidos (entre cinco y diez), utilizando la plantilla previamente definida. Con esto, se permite evaluar la adecuación de la plantilla a la pregunta de investigación y objetivo de la revisión.

2. *El método de análisis descriptivo propuesto está poco definido.*

- Optar por un análisis cualitativo del contenido en lugar de descriptivo.

## Recopilación, resumen e informe de los resultados

1. *Ofrece poco detalle* Este paso debería ser dividido en varias subtareas:

- Análisis cualitativo.
- Recoger la información y producir el resultado que de respuesta a la pregunta de investigación.
- Interpretar los resultados destacando su relación con el objetivo de la revisión, considerar las implicaciones que puedan tener en futuros trabajos, prácticas y políticas.

## Consultar la información

1. *El paso de consulta es opcional:*

- Este paso no debería ser opcional, si no un componente esencial de la metodología.

2. *No queda claro cuándo, cómo y por qué consultar a los interesados, ni cómo integrar la nueva información que se haya podido producir en la asesoría:*

- Establecer un objetivo para cada reunión.
- Se puede mantener una asesoría tomando como base las primeras conclusiones.
- Establecer quiénes son los interesados que se van a consultar, y de qué forma la información reportada va a ser recogida, analizada, notificada e integrada en el resultado final del estudio.

## 3.3. Enhancing the scoping study methodology

Debemos entender la mejora propuesta en el trabajo *Enhancing the scoping study methodology: a large, inter-professional team's experience with Arksey and O'Malley's framework* [16] como paralela a la de Levac y Colquhoun [15], ya que ambos trabajan sobre la metodología original. No obstante, es importante mencionar que los autores han considerado las recomendaciones introducidas por Levac et al. [15]. De forma análoga, presentan una serie de recomendaciones para cada uno de los pasos:

**Identificar la pregunta de investigación**

1. Asegurarse de que la revisión sistemática exploratoria es la solución más adecuada al problema planteado: buscar información e investigar acerca de su realización, comprender su objetivo, sus limitaciones, etc.
2. Establecer la relación entre la pregunta de investigación y el objetivo de la revisión. Asegurarse de que los conceptos de la pregunta de investigación son claros.

**Identificar estudios relevantes**

1. Ser flexible respecto a la pregunta de investigación y a los términos de búsqueda: podría ser necesario realizar cambios.
2. Formar un equipo multidisciplinar e interprofesional. Contar con un miembro con experiencia en la realización de este tipo de revisiones e interesados, si es posible.
3. Contar con investigadores cualificados del grupo de investigación y profesionales con experiencia puede asegurar completar la revisión en el tiempo acordado.

**Selección de estudios**

1. Si se cuenta con un equipo grande, dividir el equipo en tres subgrupos y repartir los estudios que se han de revisar de forma equitativa. Cada miembro revisará los estudios que se le hayan asignado para decidir su inclusión o descarte. Se comparan los resultados y si no hay acuerdo, un tercer revisor debe desempatar.
2. Analizar la calidad de los estudios para decidir su inclusión o descarte, a través de métodos validados.

**Extracción de la información**

1. Realizar un ejercicio de extracción de datos previo (una prueba piloto), para asegurar la consistencia en el proceso por parte de todo el equipo, así como identificar posibles ajustes o cambios que se deban realizar.
2. Crear una plantilla de extracción exhaustiva, incluyendo tanto información general como específica.
3. Comunicación efectiva manteniendo reuniones frecuentes para asegurar que el equipo está realizando este proceso de forma consistente.

4. Si se cuenta con un equipo grande, de nuevo dividirlo en subgrupos (distintos a los de la etapa anterior) y asignar los estudios de forma equitativa. Cada miembro decidirá cuáles de los documentos asignados se incluyen, y cada subgrupo compara sus resultados. Un miembro, de forma independiente, leerá y extraerá la información de cada documento.
5. Asignar a cada documento un número de identificación único para evitar confusión. De esta forma, también será más fácil de identificar.

### **Recopilación, resumen e informe de los resultados**

1. Una parte del equipo se encargará de estudiar la información recogida y decidir en qué poner el énfasis.

### **Consultar la información (opcional)**

1. Si hay interesados que no forman parte del equipo de revisión, mantener asesorías con ellos. Solamente hacerlo si se están obteniendo resultados significativos en la revisión.
2. Si los resultados no son significativos, es posible que sea necesario ir más allá de la revisión para hacer una contribución valiosa.

Junto a estas recomendaciones, los autores terminan destacando las siguientes lecciones aprendidas:

- Es necesaria la evaluación de la calidad de los estudios incluidos.
- Proponen la eliminación del término *ágil* de la definición, planteando así un cambio de visión: una revisión de esta naturaleza no admite un proceso rápido, si no que es proceso minucioso, exhaustivo y lento.

## **3.4. Scoping reviews: time for clarity in definition, methods, and reporting**

Las aportaciones de Colquhoun et al. [17] consisten principalmente en recomendaciones y aclaraciones que se van a describir a continuación.

1. Términos, definición, metodología:
  - Recomiendan el uso explícito de los términos *scoping review* o *scoping study* al realizar una revisión de esta naturaleza.



- Recomiendan la siguiente definición: “Un *scoping review* o *scoping study* es una forma de sintetizar el conocimiento, que consiste en buscar, seleccionar y resumir de manera sistemática la información de un área o campo definido de investigación, con el objetivo de relacionar conceptos clave, tipos de evidencia, y encontrar posibles carencias.”
  - Hasta que se desarrolle una guía completa y más consensuada, recomiendan el uso de la metodología desarrollada por Arksey y O'Malley [2], incorporando las mejoras propuestas por Levac y Colquhoun [15].
2. Necesidad de establecer unas directrices: proponen la creación de una versión de PRISMA [21] específica, para mejorar la transparencia, reproducibilidad y exhaustividad. Asimismo, para que permita una evaluación más rigurosa y una mejor calidad metodológica.

### 3.5. Joanna Briggs Institute Reviewer's Manual

Inicialmente, un grupo de trabajo del Instituto Joanna Briggs, formado por Peters, Godfrey, McInerney, entre otros, publican el artículo *Guidance for conducting systematic scoping reviews* [18] en el que se propone una definición de *scoping review*, orientaciones para decidir cuándo realizar uno, así como conceptos clave y cómo exponer los pasos que se han llevado a cabo. Se puede apreciar tanto en esta aportación como en la de Colquhoun et al. [17] cómo va haciéndose patente la necesidad de una descripción detallada y esquematizada de cómo se ha llevado a cabo la revisión. Aunque gran parte de su contenido fue posteriormente incluido en el Manual del Revisor del Instituto Joanna Briggs, a continuación se destacan algunos aspectos interesantes que los autores ya tenían en mente y que posteriormente desarrollarían con mayor precisión en el manual:

Se define una revisión sistemática exploratoria como: “Las revisiones sistemáticas exploratorias se utilizan generalmente como estudios de *reconocimiento*: para aclarar definiciones en las que se está trabajando y diferencias conceptuales acerca de un área o tema. Por tanto, son particularmente útiles cuando la literatura de un tema no ha sido todavía revisada de forma exhaustiva, o cuando presenta una naturaleza compleja y heterogénea que no puede cubrirse mediante una revisión sistemática.”

Durante el desarrollo de una revisión sistemática exploratoria al menos dos personas deben formar el equipo revisor y es necesario definir previamente un protocolo (es parte del proceso de las revisiones sistemáticas y los autores proponen su incorporación para las

revisiones sistemáticas exploratorias). Dada su naturaleza iterativa, es necesario justificar en el protocolo establecido cualquier modificación que haya sido necesaria.

Los autores también mencionan y explican aspectos clave que han de formar parte del plan metodológico y por ende, de la revisión: título, antecedentes, pregunta de investigación y objetivos, criterios de inclusión; población objetivo, concepto y contexto; búsqueda, extracción de datos, discusión, etc. Estos conceptos y muchos otros fueron incluidos en el manual [19] y se explicarán a continuación.

En el manual, se dedica un capítulo completo a este tipo de revisiones (*Chapter 11: Scoping Review*), actualizado por última vez en marzo de 2020. Se tratan aspectos como: definición, motivación, marco de referencia, cómo establecer un protocolo para su desarrollo, la revisión en sí y los componentes que debería contener el informe final de los resultados. Aunque algunos conceptos se van a repetir entre el apartado del protocolo y el apartado de elaboración del informe final, es importante diferenciar entre el proceso de planificación y establecimiento de un protocolo (cómo se van a hacer las cosas) y la forma en la que se va a exponer el resultado (cómo se van a mostrar las cosas).

- **Marco de referencia (framework):** Redefinen y amplían el marco de referencia propuesto por Arksey y O'Malley [2] y posteriormente mejorado por Levac et al [15].
  1. Definir y relacionar de los objetivos y la pregunta de investigación.
  2. Desarrollar y relacionar los criterios e inclusión con los objetivos y la pregunta de investigación.
  3. Describir la planificación realizada para la búsqueda, selección, extracción y presentación de la evidencia científica.
  4. Búsqueda de la evidencia científica.
  5. Selección de la evidencia científica.
  6. Extracción de la evidencia científica.
  7. Análisis de la evidencia científica.
  8. Presentación de los resultados.
  9. Resumen de la evidencia científica, relacionando con el objetivo de la revisión.  
Describir conclusiones e implicaciones de los resultados.
- **Protocolo de Scoping Review:** antes de comenzar se propone que los investigadores establezcan un protocolo, con la intención de que se utilice como guía y planificación. Con ello, también se reduce la posibilidad de que se produzcan sesgos a la hora de describir el proceso que se ha llevado a cabo. Se debe destacar y explicar cualquier

desviación del protocolo, en caso de que ocurriera. En el caso de otro tipo de revisiones, como por ejemplo la sistemática, los autores pueden registrar el protocolo seguido para su elaboración en la agencia PROSPERO (*International prospective register of systematic reviews*) [22], pero este no es el caso ahora mismo para los *scoping reviews*. De momento, los protocolos de *scoping review* se pueden publicar en algunas revistas, en Open Science Framework (plataforma donde compartir procesos de investigación) [23] o Figshare (repositorio de datos de ciencia abierta) [24].

1. **Título:** se puede utilizar la siguiente regla nemotécnica: PCC (Population, Concept, Context), a través de la cual identificar los tres conceptos claves para reflejarlos en el título. Población objetivo: destacar características de los participantes que hayan sido relevantes a la hora de su inclusión en el estudio. Concepto: qué es lo que se está examinando a través de la revisión. Contexto: como por ejemplo, factores culturales, localización geográfica, etc. Por último pero no menos importante, el título debe incluir la palabra *scoping review*.
2. **Pregunta de investigación:** guía y dirige los criterios de inclusión de la revisión. Al igual que el título, debe incluir los elementos de la regla *PCC (Population, Concept, Context)*.
3. **Introducción del protocolo:** en la introducción se han de explicar los motivos por los que se está desarrollando la revisión y qué se pretende informar a través de ella. Antes de comenzar con el proceso, es necesario buscar posibles revisiones ya publicadas sobre el tema de interés. En el caso de existir, se debe justificar la realización de una nueva revisión: qué es lo que se va a hacer diferente, qué se va a aportar. Hay que abordar este tema en la introducción, incluyendo las fechas y las bases de datos que se han utilizado en las búsquedas. La longitud de esta sección debería ser de aproximadamente mil palabras.
4. **Criterios de inclusión:** deben estar claramente definidos.
5. **Estrategia de búsqueda:** se ha de llevar a cabo una búsqueda lo más exhaustiva posible, teniendo presentes las restricciones de tiempo y recursos que presente el equipo. Cualquier limitación impuesta a este proceso ha de ser informada y justificada. La estrategia se puede dividir en tres pasos:
  - a) Realizar una búsqueda inicial limitada a dos bases de datos que sean relevantes para la misma. Analizar título, resumen y palabras clave de los resultados obtenidos.

- b)* Realizar una segunda búsqueda en todas las bases de datos seleccionadas donde se empleen como palabras clave los términos identificados en la fase anterior.
- c)* Buscar otros posibles documentos interesantes en las referencias de los artículos que se han localizado en el paso anterior.

No hay que olvidar especificar el periodo de tiempo para el que se ha realizado la búsqueda, así como los idiomas que se van a incluir. Este proceso se puede iterar en caso de que sea necesario, y ha de ser transparente y trazable.

6. **Selección de estudios:** dos revisores de manera independiente decidirán si se incluye o no un documento, y los desacuerdos serán resueltos por un tercer revisor. Este paso se describirá en su totalidad y será acompañado por un diagrama (propuesto en PRISMA-ScR [3]). Como anexos, se deben detallar los documentos incluidos y una breve mención a los que han sido descartados, explicando el por qué. Recomiendan que se realice una fase piloto, en la que se aplican los criterios de inclusión/exclusión a 25 documentos (sólo título-resumen), para dar la oportunidad de contrastar opiniones y discrepancias de los revisores. El equipo podrá comenzar cuando se alcance al menos un 75 % de acuerdo.
7. **Extracción de los datos:** se desarrolla una plantilla o formulario sobre el que plasmar la información relevante, que será acorde a la pregunta de investigación y objetivo de la revisión. Es un proceso iterativo, por lo que la plantilla puede estar en constante evolución. Se recomienda una fase piloto en la que al menos dos miembros del equipo extraen la información de al menos dos o tres documentos, para asegurar que todos los detalles relevantes están siendo considerados correctamente. La plantilla puede constar de la siguiente información, que se adaptará para cada caso:
  - a)* Autor(es)
  - b)* Año de publicación
  - c)* Origen (dónde se ha publicado o dónde se ha llevado a cabo)
  - d)* Objetivo/propósito
  - e)* Población objetivo
  - f)* Métodos y/o metodología
  - g)* Tipo de intervención y detalles de la misma (si es aplicable)
  - h)* Resultados
  - i)* Conclusiones y aspectos relevantes a la pregunta de investigación.

8. **Análisis de la información extraída:** Los revisores deben describir explícitamente cómo se ha realizado la extracción y cómo se ha llegado a los resultados de la revisión. Esto se puede hacer utilizando tablas, gráficos, etc. También es interesante que los autores creen categorías en función de los datos que se manejan, siempre explicando y dejando claro todas las consideraciones hechas.
  9. **Comunicación de los resultados:** pueden utilizarse recursos como figuras, tablas, gráficos, etc, de tal forma que responda de forma clara a la pregunta de investigación, relacionando los conceptos encontrados en la evidencia científica con los objetivos de la revisión. Esta relación debería presentarse además en forma de texto explicativo junto a los elementos de la presentación.
- **Scoping Review y resumen de los resultados:** se detallan los componentes del informe final del *scoping review* y la información que debe contener.
1. **Título:** debe incluir la palabra *scoping review* y reflejar claramente los contenidos más importantes de la revisión. No debería formularse en forma de pregunta ni en forma de conclusión. Para facilitar la comprensión, no debería contener más de 25 palabras.
  2. **Autores de la revisión:** deben aparecer las afiliaciones de cada autor y una dirección de correo electrónico e información sobre la persona de contacto.
  3. **Resumen:** debe reflejar los elementos más importantes de la revisión. Se propone la siguiente estructura:
    - a) **Objetivo:** en una o dos frases, plasmar el objetivo de la revisión utilizando los elementos clave que forman los criterios de inclusión.
    - b) **Introducción:** en dos o tres frases, describir cuál es el tema de la revisión y qué se conoce ya sobre el tema.
    - c) **Criterios de inclusión:** en una o dos frases, hacer un resumen de los mismos. No hacer subsecciones individuales para cada uno, solo mencionarlos.
    - d) **Métodos:** debe incluir las fuentes utilizadas, limitaciones impuestas (por ejemplo, idiomas), el periodo de tiempo estudiado y/o la fecha de la última búsqueda. Asimismo, en este apartado se debe mencionar si se ha realizado alguna modificación relevante a la metodología utilizada.
    - e) **Resultados:** debe ser la parte más extensa del resumen, en el que se ha de mencionar el número de documentos que ha formado parte de la revisión e informar acerca de los hallazgos más importantes.

- f) Conclusiones:* nombrar brevemente las conclusiones, respondiendo al objetivo y a la pregunta de investigación. Comentar brevemente las implicaciones que se hayan podido encontrar.
4. **Introducción:** Nombrar todos los elementos principales de la revisión y justificar por qué se ha decidido realizar una revisión sistemática exploratoria. Deben quedar claros el objetivo principal y la pregunta de investigación. Finalizando la introducción, es necesario especificar que se han realizado búsquedas de revisiones sistemáticas y sistemáticas exploratorias sobre la temática tratada, incluyendo las fuentes. Esto es para aclarar que los autores están aportando una revisión novedosa. Para concluir, dejar clara la relación del objetivo con los criterios de inclusión.
  5. **La pregunta de investigación:** Indicar la pregunta de investigación, así como preguntas secundarias si fuese necesario.
  6. **Criterios de inclusión:** esta sección ha de reflejar de la forma más transparente posible el razonamiento realizado por los revisores para decidir los criterios por los cuales se incluye un documento. Puede utilizarse la regla *PCC (Population-Concept-Context)* y explicar cada uno de estos puntos. Justificar las tipologías (artículos de revista, editoriales, etc.) de documentos que se han incluido.
  7. **Métodos:** se deben reflejar los pasos establecidos para llevar a cabo la revisión, así como justificar cualquier cambio que haya sufrido la planificación inicial. Si el protocolo seguido ha sido publicado, ha de incluirse la referencia en este apartado. Citar las metodologías empleadas.
    - a) **Estrategia de búsqueda:** explicar de forma exhaustiva y detallada la realización de este paso, ya que aporta validez a la revisión. Incluir las búsquedas exactas de la mayoría de las bases de datos bibliográficas empleadas y nombrar cualquier otra modalidad de búsqueda empleada: a mano, en las referencias de los documentos incluidos, etc. Declarar limitaciones existentes, así como el periodo de tiempo.
    - b) **Revisión y selección de la evidencia científica:** este paso debe describir el proceso por el que han pasado los documentos desde que se comienzan a revisar hasta que se deciden incluir. Explicar cómo se han llevado a cabo las revisiones (si han sido sobre el texto completo, o solamente sobre el resumen y/o título, etc.), y cómo se han resuelto los desacuerdos entre los revisores.

- c) **Extracción de la información:** debe comprender toda la información relevante para la revisión. Algunos campos pueden ser: Autor y año, propósito, participantes (características, número total), concepto, contexto, etc.
- d) **Análisis y comunicación de los resultados:** Explicar los métodos mediante los cuales se presentan los resultados de la revisión: tablas, diagramas, esquemas, descripciones, etc. Cada recurso de este tipo debe venir acompañado por un resumen descriptivo en el que se relacionen los resultados con la pregunta y objetivos de la revisión.

#### 8. Resultados:

- a) **Discusión:** comentar los resultados de la revisión en el contexto actual, práctica profesional y directrices. No se deben volver a exponer los resultados si no comentarlos dentro de los contextos que sean oportunos.
- b) **Conclusiones y recomendaciones:** explicar más detenidamente las conclusiones, así como las implicaciones de los hallazgos en el futuro de la investigación y las implicaciones de cara a la práctica profesional.
- c) **Conflictos y agradecimientos:** declarar en ambos sentidos, tanto si puede existir un conflicto de interés como si no. Se deben nombrar las agencias financiadoras, si las hay, así como el rol que cada una ha tenido en la realización de la revisión. En el caso de haber agencias financiadoras, declarar si puede considerarse la existencia de algún tipo de conflicto de interés o sesgo intelectual. Las entidades financiadoras de los documentos incluidos en la revisión también pueden ser nombradas.
- d) **Referencias:** listado completo de referencias, en el orden en el que se mencionan.
- e) **Anexos:** se han de numerar utilizando la numeración romana, y en el orden en el que se nombran en el texto. Se puede incluir como anexo, por ejemplo, la estrategia de búsqueda (de forma detallada y con todas las fuentes), extracción de la información (adjuntar el instrumento utilizado).

### 3.6. PRISMA Extension for Scoping Reviews (PRISMA-ScR)

Entre los autores de este trabajo se encuentran nombres ya familiares a lo largo de la cronología de este tipo de revisiones, como pueden ser: Colquhoun, Levac, Peters [3]

PRISMA-ScR es un “reporting guideline” presentado bajo la forma de una lista de comprobación de items, que han demostrado mejorar la transparencia de la metodología puesta en práctica. Los items de PRISMA-ScR son:

1. **Título:** Identificar el artículo como *scoping review*.

2. **Resumen:**

- **Resumen estructurado**, incluyendo lo que sea relevante de entre los siguientes puntos (antecedentes, objetivos, criterios de inclusión, fuentes de información, métodos de extracción, resultados y conclusiones relacionadas al propósito y a la pregunta de investigación).

3. **Introducción:**

- **Justificación:** estableciendo el contexto alrededor del tema de investigación y lo que ya se conoce, justificar la necesidad de realizar una revisión sistemática exploratoria. Explicar por qué se ha elegido realizar esta y no otro tipo de revisión.
- **Objetivos:** explicar y relacionar la pregunta de investigación y objetivos con los elementos clave (por ejemplo: participantes o población objetivo del estudio, conceptos y contexto).

4. **Métodos:**

- **Protocolo y registro:** indicar si se ha seguido un protocolo de revisión y si es accesible. En caso afirmativo, proveer la información de registro.
- **Criterios de inclusión:** especificar y justificar dichos criterios así como proveer detalles como los años considerados, los idiomas, etc.
- **Fuentes de información:** describir las fuentes utilizadas para buscar la información (registros electrónicos, referencias, etc.), así como la fecha de la búsqueda más reciente.
- **Búsqueda:** proveer la estrategia completa de la búsqueda en al menos una base de datos electrónica, con todos los detalles necesarios de tal forma que sea reproducible.
- **Selección de estudios:** Explicar el proceso de selección de los estudios que formarán parte de la revisión.
- **Proceso de extracción de datos:** describir los métodos puestos en práctica, como pueden ser utilización de formularios, por cuántos miembros del equipo se ha revisado un mismo estudio, etc.



- **Variables de estudio:** Listar y definir los conceptos que se han buscado en los estudios, así como supuestos y simplificaciones impuestas.
- **Valoración crítica de los estudios:** Si se ha realizado, justificar la necesidad y los métodos utilizados para ello.
- **Síntesis de los resultados:** Describir los métodos de tratamiento y síntesis de los datos extraídos.
- **Posible sesgo entre los estudios:** No aplicable.
- **Selección de estudios:** especificar el número de estudios seleccionados, revisados para su inclusión y finalmente incluidos, explicando los motivos de descarte en cada paso, preferiblemente utilizando un diagrama de flujo.
- **Características de los estudios:** presentar las características del estudio por las que se ha extraído información y citarlo adecuadamente.
- **Valoración crítica de los estudios:** Presentar esta información si se ha estudiado. Ver este mismo ítem en el apartado de Métodos para más información.
- **Resultados de la extracción de datos de cada estudio:** presentar los resultados de forma individual para cada estudio, relacionándolos con la pregunta de investigación y objetivos.

## 5. Discusión:

- **Resumen de los resultados:** resumir los resultados principales relacionándolos con la pregunta de investigación y los objetivos.
- **Limitaciones:** comentar las posibles limitaciones del proceso de revisión.
- **Conclusiones:** interpretar los resultados respecto a la pregunta de investigación y objetivos, así como posibles implicaciones y/o los pasos que se darán en el futuro.

6. **Financiación:** Describir no únicamente las fuentes de financiación y su rol para la realización del *scoping review*, si no también el origen de la financiación percibida por los artículos incluidos para su realización.



# Protocolo desarrollado en la revisión sistemática exploratoria

En este capítulo se va a detallar cómo se ha realizado la revisión sistemática exploratoria. El contenido se va a agrupar acorde a las directrices de Prisma-ScR [3], para lo cual abordaremos las siguientes secciones: Título, Resumen, Introducción, Métodos, Resultados, Discusión. Se presentarán en este capítulo las cuatro primeras secciones y el resto se tratarán en el siguiente capítulo.

## 4.1. Título

**“What is known from the existing literature about methodologies, techniques, algorithms and frameworks used in Artificial Intelligence applied to pregnancy health and well being?”**

## 4.2. Resumen

### 4.2.1. Antecedentes

La IA, un campo de la computación que está constantemente demostrando su potencial, ha cobrado un papel importante en los últimos años en distintas disciplinas, entre ellas, la medicina (Jiang et al., 2017) [25]. Es numerosa la literatura científica en la que se explora cómo la IA puede aportar mejoras significativas en aspectos relacionados con la salud y el bienestar de las personas. En la revisión presentada por Jiang et al. acerca de la IA y su pasado, presente y futuro en la salud, se destaca la importancia de los datos clínicos.

Es innegable el constante crecimiento tanto en la capacidad de almacenamiento de datos como en la cantidad de datos que se generan en el ámbito médico y el papel fundamental que ha tenido en este aspecto.

Se encuentran datos de muy diversa índole en forma de registros electrónicos de pacientes, registros y anotaciones médicas, exámenes físicos, imágenes, escáneres, información demográfica, etc. La disponibilidad de estos datos facilita y potencia el uso de la IA en el ámbito de la salud.

#### **4.2.2. Métodos**

Para la realización de esta revisión, se ha considerado la metodología de revisiones sistemáticas exploratorias propuesta por Arksey y O'Malley [2] y las posteriores mejoras realizadas a la misma por distintos autores. Asimismo, se han considerado las directrices de la extensión PRISMA para revisiones sistemáticas exploratorias (Prisma-ScR). [3]

Se ha desarrollado una plantilla de extracción en la que se han plasmado los aspectos más relevantes de cada trabajo estudiado. Posteriormente, la información ha sido analizada y sintetizada.

Para su exposición, se han utilizado distintos tipos de recursos, principalmente gráficas, tablas y narrativas.

#### **4.2.3. Resultados**

La literatura incluida en esta revisión, un total de 156 artículos, ha sido publicada en el periodo comprendido entre el 01/01/2008 y 14/02/2020 en las bases de datos Scopus, Web of Science, Pubmed, IEEEExplore y ACM. Todos estos artículos han sido revisados y su información extraída por el equipo revisor. Se indicarán en esta revisión los aspectos relacionados con la pregunta de investigación.

#### **4.2.4. Conclusiones**

Las conclusiones se encuentran detalladas en la sección 5.2.3 del Capítulo 5.

### **4.3. Introducción**

#### **4.3.1. Justificación**

Según la *survey* publicada en 2017 por Jiang et al. [25] en la que se refleja el uso de la IA en el campo de la salud, se destacan varias aplicaciones: ofrecer soporte a los profesionales de la salud en materia de información actualizada de revistas científicas, prácticas médicas, libros, etc, que les pueda asistir en los cuidados del paciente; reducir los errores de diagnóstico; y

extraer información útil de grandes bases de datos médicas para inferir en tiempo real riesgos para la salud y realizar predicciones en los diagnósticos médicos.

En otra revisión publicada por Topol et al. en 2019 [26], se destacan los tres niveles en los que la IA puede tener aplicación en el campo de la salud. Por un lado, para los profesionales de la salud, brindándoles de métodos rápidos y fiables para interpretar imágenes, para los sistemas sanitarios, un flujo de trabajo mejorado y potencialmente, la reducción de errores médicos. Por otro lado, para los pacientes, es realmente interesante la aplicación de la IA tanto para llevar a cabo el seguimiento personalizado de los pacientes, como para que estos puedan recibir una asistencia acorde con sus necesidades específicas a través de sistemas inteligentes.

Un estudio publicado en 2019 por Tran et al. [27] sobre la evolución global de la literatura científica dedicada a la IA aplicada a medicina y salud, demuestra un aumento exponencial de los estudios realizados en este campo, sobre todo comenzando alrededor de los años 2002-2003, pudiendo esto deberse en parte al crecimiento de la capacidad computacional y de la capacidad de almacenamiento de datos.

Junto al rápido avance de la literatura científica en este ámbito, surge la necesidad de realizar revisiones que permitan evaluar el estado de la cuestión. Sin embargo, hasta el momento no se ha encontrado ninguna revisión en la que se realice un estudio de cómo se aplica la IA a la salud y bienestar en las embarazadas. De forma análoga a los tres niveles planteados por [26], la IA puede, en primer lugar, asistir a los profesionales médicos a la hora de la toma de decisiones. Por ejemplo, decidir el tiempo de espera adecuado antes de realizar una cesárea a una paciente [28]. En cuanto a los sistemas sanitarios, puede ayudar a los profesionales de la salud y/o responsables, a la adecuada asignación de los recursos sanitarios en materia de salud pública [29]. A las pacientes, les puede ofrecer una herramienta de monitorización desde casa, acompañándolas en el embarazo [30], incluso detectar posibles futuras complicaciones, como puede ser la pre-eclampsia, antes de que se manifiesten [31].

#### 4.3.2. Objetivos

Se pretende explorar la literatura científica presente en distintas bases de datos científicas a lo largo de un periodo de diez años, en relación a las técnicas, metodologías, algoritmos y frameworks de inteligencia artificial aplicados a mejorar la salud y bienestar de las embarazadas.

## 4.4. Métodos

En la siguiente sección se detallarán los siguientes subapartados: protocolo y registro, los criterios de inclusión, las fuentes de información, la búsqueda y selección de artículos, el proceso de extracción de datos, las variables de estudio y la síntesis de los resultados.

### 4.4.1. Protocolo y registro

El protocolo de esta revisión se encuentra en esta misma sección de Métodos, pero no aún se ha procedido a su registro. Se prevé que se realice su registro antes de su publicación en revista de impacto (Q1).

### 4.4.2. Criterios de inclusión

Siguiendo la regla *Población objetivo-Concepto-Contexto (PCC)* de [19], los artículos han de cumplir los siguientes criterios:

- **Población objetivo:** embarazadas y/o fetos.
- **Concepto:** propone, aplica y/o se evalúa una metodología, marco de referencia, algoritmo o técnica de inteligencia artificial, incluyendo cualquiera de sus sub-ramas (machine y deep learning, sistemas expertos, multi-agente, sistemas de decisión, procesamiento de lenguaje natural, etc.).
- **Contexto:** salud y bienestar de embarazadas y/o fetos.

Además, se han establecido criterios de inclusión que atienden a aspectos no relacionados con el contenido:

- **Tipo de publicación:** artículos en revistas y ponencias.
- **Idioma:** inglés.
- **Periodo de publicación:** 2008-2020 (en concreto, fecha de la última búsqueda: 14 febrero 2020)

### 4.4.3. Fuentes de información

Para ubicar publicaciones relevantes, se han considerado las siguientes bases de datos: Scopus [32], Web of Science [33], Pubmed [34], IEEE Xplore Digital Library [35] y ACM Digital Library [36].

- **Scopus:** incorpora un gran número de registros, entre los cuales encontramos libros, artículos de revistas científicas, ponencias, artículos en prensa, etc. Además, incorpora herramientas inteligentes con las que analizar en más profundidad la literatura.
- **Pubmed:** permite consultar principalmente la base de datos MEDLINE, junto a otras revistas científicas.
- **IEEE Xplore Digital Library:** proporciona acceso al material publicado por el *Institute of Electrical and Electronics Engineers (IEEE)* [37], reconocido por su gran componente científico-tecnológico. Destacamos revistas que pueden ser de gran interés para el estudio, como *IEEE Transactions of Affective Computing*, *IEEE Transactions on Signal Processing*, *IEEE Transactions of Biomedical and Health Informatics*, entre otras.
- **Web of Science:** aglutina varias bases de datos bibliográficas, ofreciendo así un gran número de recursos. Indexa el contenido de revistas no solo de ciencia y tecnología, si no también de ciencias sociales, artes y humanidades.
- **ACM Digital Library:** catálogo digital de la *Association for Computing Machinery* recoge los contenidos publicados en revistas del ámbito de la computación. No solamente es relevante para el estudio por su temática, sino porque recoge entre sus revistas, títulos como los siguientes: *ACM Transactions on Computing for Healthcare*, *ACM Transactions on Interactive Intelligent Systems*, *ACM Transactions on Computer-Human Interaction*.

#### 4.4.4. Búsqueda

En primer lugar, el equipo revisor ha acordado los descriptores de la búsqueda, extraídas de forma directa de la pregunta de investigación y objetivo propuesto: por un lado, el conjunto de términos relacionados con el aspecto computacional: “artificial intelligence”, “machine learning”, “affective computing”; por otro lado, los términos relacionados con la población objetivo: pregnan\* (el asterisco simboliza cualquier terminación: pregnancy, pregnant); por último, “health”, “well-being”.

Los términos de una categoría se han relacionado entre ellos mediante operaciones *OR* y con los términos de las categorías restantes mediante operaciones *AND*. Por tanto, la búsqueda se ha construido de la siguiente manera:

((“artificial intelligence” OR “machine learning” OR “affective computing”) AND (pregnan\*) AND (health OR well-being))

A la hora de trasladar la búsqueda a consultas en las bases de datos bibliográficas, se ha decidido utilizar como campos de búsqueda, en la medida de lo posible, los campos **título, resumen y palabras clave** de los documentos. Esto es porque se entiende que en estos tres campos deben aparecer los términos de interés en el caso de que se traten en el artículo. Una alternativa es realizar la búsqueda en todos los campos de la publicación, pero esto genera un gran número de resultados entre los cuales se encontrarán muchos falsos positivos (artículos que mencionan dichos términos pero cuya temática se aleja de la que interesa para la pregunta de investigación). Por otro lado, limitar únicamente a un campo, como puede ser el título, puede dejar atrás muchos documentos interesantes.

Dado que no todos los buscadores son iguales ni permiten realizar la búsqueda en los campos deseados, la forma de buscar se ha ajustado de forma personalizada a cada buscador, primando siempre que la búsqueda sea exhaustiva en lugar de limitante. Todos los resultados de las búsquedas se han exportado en formato bibliográfico BibTeX [38]. Así se han realizado las búsquedas para cada una de las bases de datos:

**Scopus:** permite la búsqueda simultáneamente en los campos título, resumen y palabras clave, obteniendo unos resultados refinados. Se han limitado los tipos de documento para evitar recoger revisiones u otras tipologías que no resultan de interés para el scoping review, y se han limitado los idiomas a inglés y español.

Scopus	Title-Abs-Key(("artificial intelligence" OR "machine learning" OR "affective computing") AND (health OR "well being") AND pregnan*) AND pubyear>2008 AND (limit-to (doctype, "ar") OR limit-to (doctype, "cp") OR limit-to (doctype, "no") OR limit-to (doctype, "ed") OR limit-to (doctype, "ch") OR limit-to (doctype, "le")) AND (limit-to (language, "English") OR limit-to (language, "Spanish"))
--------	--

Figura 4.1 Búsqueda en Scopus

**Pubmed:** permite búsquedas utilizando operadores booleanos, sobre título y resumen, y ofrece la posibilidad de buscar en el tesoro MeSH (Medical Subject Headings) [39], lo que podría entenderse como el equivalente al campo de palabras clave. Se planteaban dos alternativas, la primera, realizar la búsqueda utilizando los descriptores del tesoro, que ayudaría a definir la búsqueda de forma más exacta, o, la segunda, buscar en todo el documento. Ante la posibilidad de que las palabras clave no coincidieran exactamente con los descriptores, se tomó la decisión de buscar en el documento completo y realizar un filtrado posterior, ya que el número de resultados era asequible para el equipo. Pubmed no permite



exportar los resultados a BibTeX directamente, así que se ha utilizado una herramienta online llamada TeXMed [40], que dada una búsqueda en Pubmed, genera el fichero deseado. Ha sido necesario filtrar a posteriori el periodo de publicación y la tipología de artículo.

Pubmed	"artificial intelligence"[All Fields] OR "machine learning"[All Fields] OR "affective computing"[All Fields]) AND (health[All Fields] OR "well being"[All Fields]) AND (pregnant[All Fields] OR pregnancy[All Fields])
--------	--

Figura 4.2 Búsqueda en Pubmed

**Web of Science:** su buscador avanzado no permite búsquedas en resumen y palabras clave, pero sí en título. Dado que se ha tomado la decisión de realizar búsquedas inclusivas en lugar de excluyentes siempre que sea posible, se ha utilizado el campo “*Tema*”, ya que es más amplio.

Web of Science	(TS= ("artificial intelligence" OR "machine learning" OR "affective computing") AND (pregnan*) AND (health OR "well being"))
Filtros aplicados en el buscador: IDIOMA: (English OR Spanish) AND TIPOS DE DOCUMENTOS: (Article OR Abstract of Published Item OR Book OR Book Chapter OR Correction OR Correction, Addition OR Editorial Material OR Letter OR Meeting Abstract OR Meeting Summary OR Note OR Proceedings Paper). Periodo de tiempo 2019-2020.	

Figura 4.3 Búsqueda en Web of Science

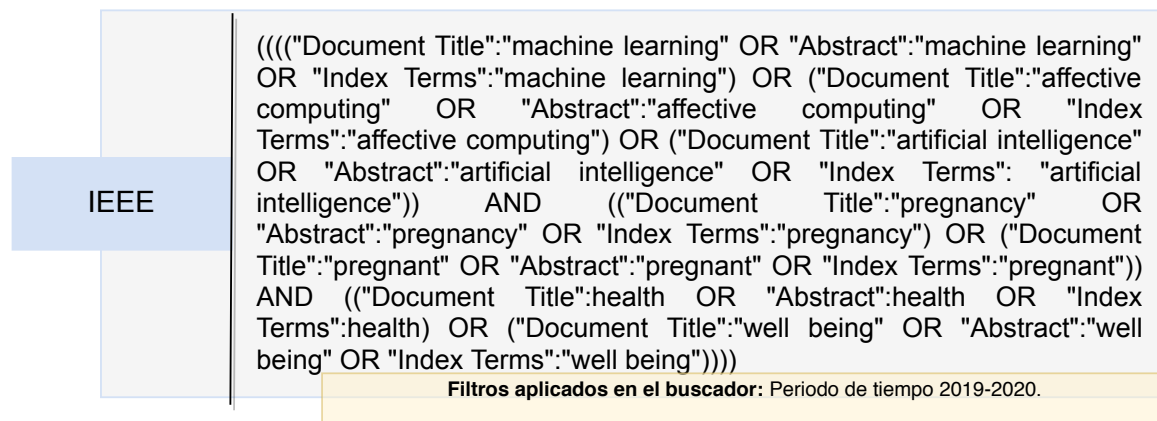
**Association for Computing Machinery:** el buscador avanzado de este catálogo permite el uso de operadores booleanos y búsquedas por título y resumen, pero no por palabras clave. Dado que en este caso el número de resultados sí es asequible para plantear una revisión posterior, se decide incluir esta fuente de datos y realizar la búsqueda en todos los campos.

ACM	[[All: "affective computing"] OR [All: "machine learning"] OR [All: "artificial intelligence"]] AND [[All: health] OR [All: "well being"]] AND [[All: pregnant] OR [All: pregnancy]] AND [Publication Date: (01/01/2009 TO 10/02/2020)]
-----	---

Figura 4.4 Búsqueda en ACM

**IEEE Xplore:** esta base de datos incorpora un buscador avanzado que permite afinar en gran medida. Permite la búsqueda por título, resumen e “Index Terms” [41], que es una

combinación de los siguientes campos: palabras clave del autor, IEEE Terms (palabras clave asignadas a los artículos y ponencias de IEEE utilizando un vocabulario propio), INSPEC Terms (explicar) y MeSH Terms.



(((("Document Title":"machine learning" OR "Abstract":"machine learning" OR "Index Terms":"machine learning") OR ("Document Title":"affective computing" OR "Abstract":"affective computing" OR "Index Terms":"affective computing") OR ("Document Title":"artificial intelligence" OR "Abstract":"artificial intelligence" OR "Index Terms": "artificial intelligence"))) AND ((("Document Title":"pregnancy" OR "Abstract":"pregnancy" OR "Index Terms":"pregnancy") OR ("Document Title":"pregnant" OR "Abstract":"pregnant" OR "Index Terms":"pregnant"))) AND ((("Document Title":health OR "Abstract":health OR "Index Terms":health) OR ("Document Title":"well being" OR "Abstract":"well being" OR "Index Terms":"well being")))))

Filtros aplicados en el buscador: Periodo de tiempo 2019-2020.

Figura 4.5 Búsqueda en IEEE Xplore

Como se ha mencionado anteriormente, los resultados de las búsquedas se han exportado de cada base de datos a un formato de referencias bibliográficas BibTeX. Antes de comenzar a evaluar los resultados, es necesario detectar y eliminar los duplicados. Para ello, se ha utilizado el lenguaje de programación Python: se realiza la lectura de todos los archivos BibTeX resultantes de las búsquedas y se eliminan los duplicados haciendo comparaciones de los datos de la publicación, como por ejemplo: texto, *DOI (Digital Object Identifier)* [42], año de publicación, etc. En este caso, se ha utilizado la comparación de títulos por semejanza. También mediante programación, se han asignado las bases de datos en las que se han encontrado dichos artículos para mantener la trazabilidad de su origen.

Como resultado, los documentos únicos se han exportado en un archivo BibTeX único, para posteriormente poder importar su contenido en un software de gestión de referencias bibliográficas, y también en un documento Microsoft Excel donde se relaciona cada documento con su base de datos origen. Si un título aparece relacionado con más de una base de datos, significa que es un duplicado que se ha unificado correctamente y que ha resultado en las búsquedas de dichas bases de datos.

	A	B
1	Título	Fuente
2	Cardiotocography signals with artificial neural network and extreme learning machine	IEEE
3	"What is the best method of family planning for me?": a text mining analysis of messages between users and agents of a digital hea	Scopus, Pubmed
4	A Machine Learning Approach for an Early Prediction of Preterm Delivery	Scopus, IEEE, WoS
5	(Re-)Framing Menopause Experiences for HCI and Design	ACM
6	A Virtual Counseling Application Using Artificial Intelligence for Communication Skills Training in Nursing Education: Development	Scopus, WoS, Pubmed
7	A Comparison of Neuromorphic Classification Tasks	ACM

Figura 4.6 Muestra del fichero de títulos y su origen

El archivo BibTeX único con todos los resultados se ha importado en el software *Mendeley* [43] de gestión de referencias bibliográficas.

#### 4.4.5. Selección de estudios

Al haber elegido una estrategia de búsqueda inclusiva, buscando en todos los campos en algunas bases de datos (Pubmed, ACM), un miembro del equipo se encarga de revisar los documentos en búsqueda de falsos positivos. Se revisan los títulos, resumen y palabras clave de cada documento para excluir aquellos que no proceden en los que no aparecen los descriptores definidos en la búsqueda. Tras este paso inicial, se establece la siguiente organización para el siguiente paso en el proceso de revisión:

- Cada artículo ha sido revisado de forma independiente por dos revisores. Cada revisor ha etiquetado el artículo como *Incluido*, *Descartado* o *Dudoso*.
- Los artículos han sido divididos en cuatro bloques a partes iguales entre los miembros del equipo, recibiendo cada uno dos bloques para revisar. La revisión de cada bloque por parte de un miembro corresponde a una iteración, realizándose por tanto una doble revisión para cada artículo (dos iteraciones). En la Figura 4.7 se puede observar cómo se ha efectuado el reparto de los documentos.
- La asignación de revisores se ha realizado de forma rotativa para que las parejas no se repitan en los distintos bloques.
- Los desacuerdos (cualquier caso en el que no hubiese inclusión o descarte del artículo por las dos partes) han sido revisados por los otros dos revisores.

BLOQUE 1		BLOQUE 2	
IT1: Revisor A	IT2: Revisor C	IT1: Revisor D	IT2: Revisor A
BLOQUE 3		BLOQUE 4	
IT1: Revisor B	IT2: Revisor D	IT1: Revisor C	IT2: Revisor B

Figura 4.7 Reparto de los documentos entre los miembros del equipo para la selección de los estudios

#### 4.4.6. Proceso de extracción de datos

Para extraer la información de los artículos incluidos, se ha decidido elaborar una plantilla utilizando el software de hojas de cálculo Microsoft Excel. En el proceso de elaboración han intervenido dos revisores que se han encargado de realizar una propuesta conjunta. Tras elaborar esta primera versión de prueba, los mismos dos revisores han realizado de forma individual una prueba piloto para evaluar la adecuación y claridad de la plantilla, utilizando tres artículos de cada uno de los cuatro bloques, con un total de nueve artículos. Tras este paso, los dos revisores se han reunido para poner en común y evaluar la plantilla, a la que se han realizado cambios y mejoras. En la propuesta se distinguen tres grandes bloques: información general del artículo, parte médica y parte informática. Se decide que la extracción de la información de cada artículo debe ser realizada por dos revisores y que, además, las partes de medicina e informática deben ser revisadas por profesionales de cada campo.

Para hacer posible la revisión de cada documento por dos personas de cada área de conocimiento, se decide invitar a la revisión a otros dos miembros, Revisor E y Revisor F, profesionales de la salud. Por tanto, el equipo queda integrado por tres profesionales de la salud y tres ingenieras. Para este número de integrantes, el total de artículos se divide en tres bloques en lugar de cuatro, como en el proceso de selección.

La división de artículos se ha realizado de la siguiente manera: un revisor de cada área de conocimiento revisará la parte general de un bloque y la parte correspondiente a su área de conocimiento de dos bloques, tal y como se puede observar en la figura 4.8.

Bloque	General	Medicina	Computación y TI
B1	Revisor A	Revisor F	Revisor A
	Revisor C	Revisor C	Revisor B
B2	Revisor F	Revisor F	Revisor D
	Revisor B	Revisor E	Revisor B
B3	Revisor D	Revisor C	Revisor D
	Revisor E	Revisor E	Revisor A

Figura 4.8 Reparto de los documentos entre los miembros del equipo para la extracción de datos

Se ha hecho llegar a los revisores una copia de la plantilla de extracción elaborada para comenzar con el proceso de extracción de datos, así como un documento de instrucciones en el se indicaba cómo se debe realizar la extracción para cada uno de los campos contemplados en la plantilla. Cada revisor ha utilizado una copia de la plantilla en la que trabajar de forma individual. Posteriormente, una vez finalizada la extracción por cada revisor, los seis documentos se han unificado en uno solo de forma automatizada, para lo que se ha utilizado Python y la librería Pandas (véase Anexo A).

#### 4.4.7. Variables de estudio

En la siguiente sección se van a enumerar y definir todas las variables estudiadas, así como las simplificaciones y suposiciones que se hayan podido realizar.

##### General

- **Autores** (*Authors*): información sobre los autores bajo el formato *Apellidos, Nombre del primer autor et. al.*
- **Título** (*Title*): tal y como aparece en la base de datos de origen.
- **Revista/Congreso** (*Journal/Conference*): el medio en el que se ha publicado el estudio.
- **Descriptores del autor** (*Author Keywords*): Solamente los descriptores que aparecen en documento (no se incluyen los que pueden aparecer en las bases de datos bibliográficas o los proporcionados por la revista/congreso).
- **País** (*Country*): Los países que se mencionen en el artículo, ya sea porque el estudio se haya realizado en dicho país o porque se trate del origen de los datos. También se han considerado los países de los autores.
- **Resumen** (*Short summary*): Breve descripción del artículo destacando información relevante para la pregunta de investigación.
- **Objetivo** (*Purpose/aim*): Señalar los objetivos del artículo más relevantes para la pregunta de investigación.
- **Producto final** (*Final product*): Las categorías principales en las que se han dividido los productos finales presentados en los artículos son las siguientes:

1. **Aplicación móvil** (*Mobile application*)
  2. **Aplicación web** (*Web application*)
  3. **Aplicación de escritorio** (*Desktop*)
  4. **Sistema de decisión** (*Decision Support System*)
  5. **Sistema electrónico de salud** (*Decision Support System*)
  6. **Framework**
  7. **Modelo** (*Model*)
  8. **Wearable**
  9. **Simulación** (*Simulation*)
  10. **Ontología** (*Ontology*)
  11. **Sistemas expertos** (*Expert systems*)
  12. **Sistemas multi-agente** (*Multiagent systems*)
  13. **Chatbot**
- **Funciones** (*Functions*) Las funciones del producto final. Aunque hay muchas, las más utilizadas son las siguientes categorías:
1. **Clasificación del estado fetal** (*Fetal state classification*)
  2. **Cuidado de la madre** (*Providing maternal care*)
  3. **Monitorización del embarazo desde casa** (*Home pregnancy monitoring*)
  4. **Predicción del embarazo pretérmino** (*Prediction of preterm birth*)
  5. **Predicción de la pre-eclampsia** (*Gestational diabetes prediction*)
  6. **Monitorización de la salud** (*Health monitoring*)
  7. **Monitorización de la diabetes gestacional** (*Gestational diabetes monitoring*)
  8. **Detección de aneuploidía** (*Aneuploidy detection*)
  9. **Predicción del tipo de parto** (*Prediction of delivery type*)
  10. **Predicción de la depresión posparto** (*Prediction of postpartum depression*)
- **Tamaño del experimento** (*Experiment size*): Dato que refleja el número de datos de partida que se menciona en el artículo.
- **Estándares en salud** (*Health standards*): Se recogerán aquí manuales, clasificaciones y definiciones, procesos de diagnóstico, etc. que tengan la consideración de estándares. También se mencionará aquí si un estudio cuenta con aprobación de un comité ético.

- **Parámetros sociales** (*Social parameters*): Se recogerán aquí factores sociales, culturales, socio-económicos, demográficos, étnicos, religiosos, etc. que se hayan mencionado en los estudios y/o que incluso hayan sido utilizados como datos.
- **Conclusiones** (*Conclusions*): Los resultados generales más relevantes para la pregunta de investigación se recogerán aquí.

### Medicina

- **Proceso asociado con el embarazo** (*Pregnancy related process*): En esta categoría se recogerán los aspectos estudiados del embarazo.
  1. **Defectos de nacimiento** (*Birth defects*)
  2. **Diabetes gestacional** (*Gestational diabetes*)
  3. **Estado fetal** (*Fetal distress*)
  4. **Parto pretérmino** (*Preterm birth*)
  5. **Crecimiento del feto** (*Fetal growth*)
  6. **Pre-eclampsia** (*Fetal growth*)
  7. **Mortalidad** (*Mortality*)
  8. **Trastornos hipertensivos** (*Hypertensive disorders*)
  9. **Parto** (*Labour and delivery*)
  10. **Depresión** (*Depression*)
  11. **Estrés** (*Stress*)
  12. **Anemia**
  13. **Interrupción** (*Termination*)
  14. **Complicaciones posparto** (*Postpartum complications*)
  15. **Patologías de la placenta** (*Placental disorders*)
  16. **Otros:** Pérdida del embarazo, Virus de la inmunodeficiencia humana (*HIV*), Diabetes Mellitus, Síndrome HELLP, Glucosa en sangre, Esclerosis múltiple, Lupus eritematoso sistémico, Hipotensión, Emociones.
- **Características del embarazo** (*Pregnancy characteristics*): Información acerca del embarazo, como puede ser la edad gestacional / trimestre, embarazo múltiple, complicaciones existentes, etc.

- **Variables y características maternas** (*Maternal variables and characteristics*): Cualquier dato recogido de la embarazada en el estudio: edad, patologías, caso clínico, historial clínico (propio y familiar), estado actual de salud, análisis de sangre, etc.
- **Variables y características fetales** (*Fetal variables and characteristics*): Cualquier dato recogido del feto en el estudio: situación, posición, peso, sexo, biometría (diámetro biparietal, circunferencia cefálica), placenta, anatomía, etc.
- **Parto** (*Labour and delivery*): Cualquier dato recogido del proceso del parto, tanto de la madre como del bebé: test de Bishop, tipo de parto (cesárea, natural, prematuro...), edad gestacional, datos clínicos durante el parto: presión sanguínea, etc.
- **Aspectos posparto** (*Postpartum aspects*): Información extraída tras el parto, tanto de la madre como del recién nacido: puntuación de Apgar, peso al nacer, estado de salud materna, depresión, etc.

## Computación

- **Subcampo de la IA** (*Approach*): Se ha utilizado como guía la categoría propuesta por la *European Conference on Artificial Intelligence (ECAI)* [44], aunque se han considerado otras:
  1. Agent-based and Multi-agent Systems (MAS)
  2. Computational Intelligence (CI)
  3. Constraints and Satisfiability (CS)
  4. Games and Virtual Environments (GAME)
  5. Heuristic Search (HEU)
  6. Human Aspects in AI (HAI)
  7. Information Retrieval and Filtering (IRF)
  8. Knowledge Representation and Reasoning (KRR)
  9. Machine Learning (ML)
  10. Multidisciplinary Topics and Applications (MULT)
  11. Natural Language Processing (NLP)
  12. Planning and Scheduling (PLAN)
  13. Robotics (ROB)



14. Safe, Explainable, and Trustworthy AI (XAI)
15. Semantic Technologies (SEM)
16. Uncertainty in AI (UAI)
17. Vision (VIS)

- **Adquisición de datos** (*Data acquisition*): Las fuentes de los datos que se utilizan en el estudio. Es posible que en ocasiones los datos puedan pertenecer a varias categorías, por ejemplo: los datos se han extraído de una base de datos o un estudio clínico en el que a su vez se ha utilizado equipo médico para su adquisición. Se categorizará, en todos los casos, la relación que el artículo tenga de forma directa con la fuente de información y se clasificará según la fuente especificada en el mismo artículo. Se han identificado las siguientes categorías:

1. **Bases de datos y/o repositorios** (*Database repository*): cuando los datos utilizados en el estudio no se han adquirido de forma directa por los investigadores que lo realizan, sino que se extraen de otras fuentes externas.
2. **Equipamiento médico** (*Medical equipment*): en el artículo se ha utilizado equipo médico para extraer los datos que se utilizan. Se entiende por ello: analíticas de sangre, ecógrafos, etc.
3. **Estudio** (*Study*): los datos provienen de un estudio (clínico o no) mencionado en el artículo.
4. **Cuestionarios realizados a pacientes** (*Patient questionnaire*): información proveniente de personas que han contestado a un cuestionario.
5. **Registros médicos** (*Medical records*): datos provenientes de sistemas de información alojados en hospitales, tanto digitales como en papel. Se especificará el nombre del hospital/centro médico/clínica cuando esté disponible.
6. **Encuesta** (*Survey*): información proveniente de una encuesta realizada.
7. **Expertos** (*Experts*): información proveniente directamente de expertos (profesionales de la salud).
8. **Sensor** (*Sensor*): datos extraídos utilizando sensores, como pueden ser sensores de temperatura, impedancia, presión sanguínea, etc.
9. **Redes sociales** (*Social media*): datos extraídos de Internet, concretamente, redes sociales, como pueden ser Twitter, Facebook, Reddit, etc.
10. **Datos simulados** (*Synthetic data*): la información no es real, si no que los autores han utilizado o simulado ellos mismos los datos.

11. **Institutos de la salud** (*Health Institutes*): datos provenientes de este tipo de instituciones.

- **Representación del conocimiento** (*Knowledge representation*): técnicas de representación del conocimiento que se hayan aplicado en el estudio.
- **Metodología** (*Methodology*): propuesta por el estudio o estándar.
- **Algoritmos** (*Algorithms*): se enumerarán los algoritmos que hayan sido implementados o desarrollados en cada estudio.

## Machine Learning

- **Datos** (*Dataset*): información recogida del estudio acerca de los datos utilizados, su composición, división, etc. Si el número de datos totales ha cambiado durante el preprocesamiento (datos excluidos, eliminados, etc), se especificará aquí la cantidad de datos empleada finalmente.
- **Preprocesamiento** (*Preprocessing / Data curation*): Se recogerán las técnicas de preprocesamiento y de ingeniería de características que se utilicen en el artículo. En ciertas técnicas de Machine Learning es generalmente necesario realizar un preprocesamiento de los datos ya que en pocas ocasiones dichos datos presentarán un formato adecuado para su uso en un algoritmo de forma directa. El preprocesamiento de datos puede consistir en su normalización, estandarización, etc.
- **Tipo** (*Type*): el tipo de aprendizaje.
  1. **Aprendizaje Supervisado** (*Supervised Learning*): el aprendizaje supervisado es aquel en el que se utilizan datos “etiquetados”. Entrenar un algoritmo de aprendizaje supervisado consiste en utilizar un conjunto de ejemplos con resultados conocidos (datos “etiquetados”).
  2. **Aprendizaje No supervisado** (*Unsupervised Learning*): los datos que se utilizarán en este caso tendrán una estructura desconocida, “no etiquetados”. En este caso no se busca encontrar una clasificación si no llegar a conocer mejor los datos con los que se está trabajando (agrupación, reestructuración...)
  3. **Aprendizaje por Refuerzo** (*Reinforcement Learning*): consiste en un agente que aprende -es entrenado- en función de las recompensas que recibe. El error se reprende y el acierto se premia.

- **Técnica del modelo** (*Model technique*): el valor de esta columna dependerá del tipo de aprendizaje.
  1. **Clasificación** (*Classification*): predicción de valores categóricos en el aprendizaje supervisado.
  2. **Regresión** (*Regression*): predicción de valores continuos en el aprendizaje supervisado.
  3. **Clustering**: agrupación según la similaridad de los datos en el aprendizaje no supervisado.
  4. **Reducción de la dimensionalidad** (*Dimensionality reduction*): reducción del número de variables del conjunto de datos en el aprendizaje no supervisado.
- **Validación / Test** (*Validation / Test*): se recogerán aquí los métodos utilizados para la validación de los modelos de *Machine Learning*, así como información acerca de los test realizado, más concretamente el porcentaje o número del total de datos que se hayan utilizado.
- **Rendimiento** (*Metrics*): Se recogerán las técnicas para medir el rendimiento de los algoritmos y/o modelos utilizados en el artículo. Se recogerá también en aquellos casos en los que la información esté disponible, aquellos algoritmos o modelos que hayan tenido mejor rendimiento acorde a alguna de las técnicas de rendimiento utilizadas.

En las figuras 4.9 y 4.10 se muestran unos esquemas de apoyo para que fueran consultados por los miembros del equipo de revisión, donde se recoge de forma esquemática y visual los conceptos y vocabulario más comunes asociados a la rama de *Machine Learning*.

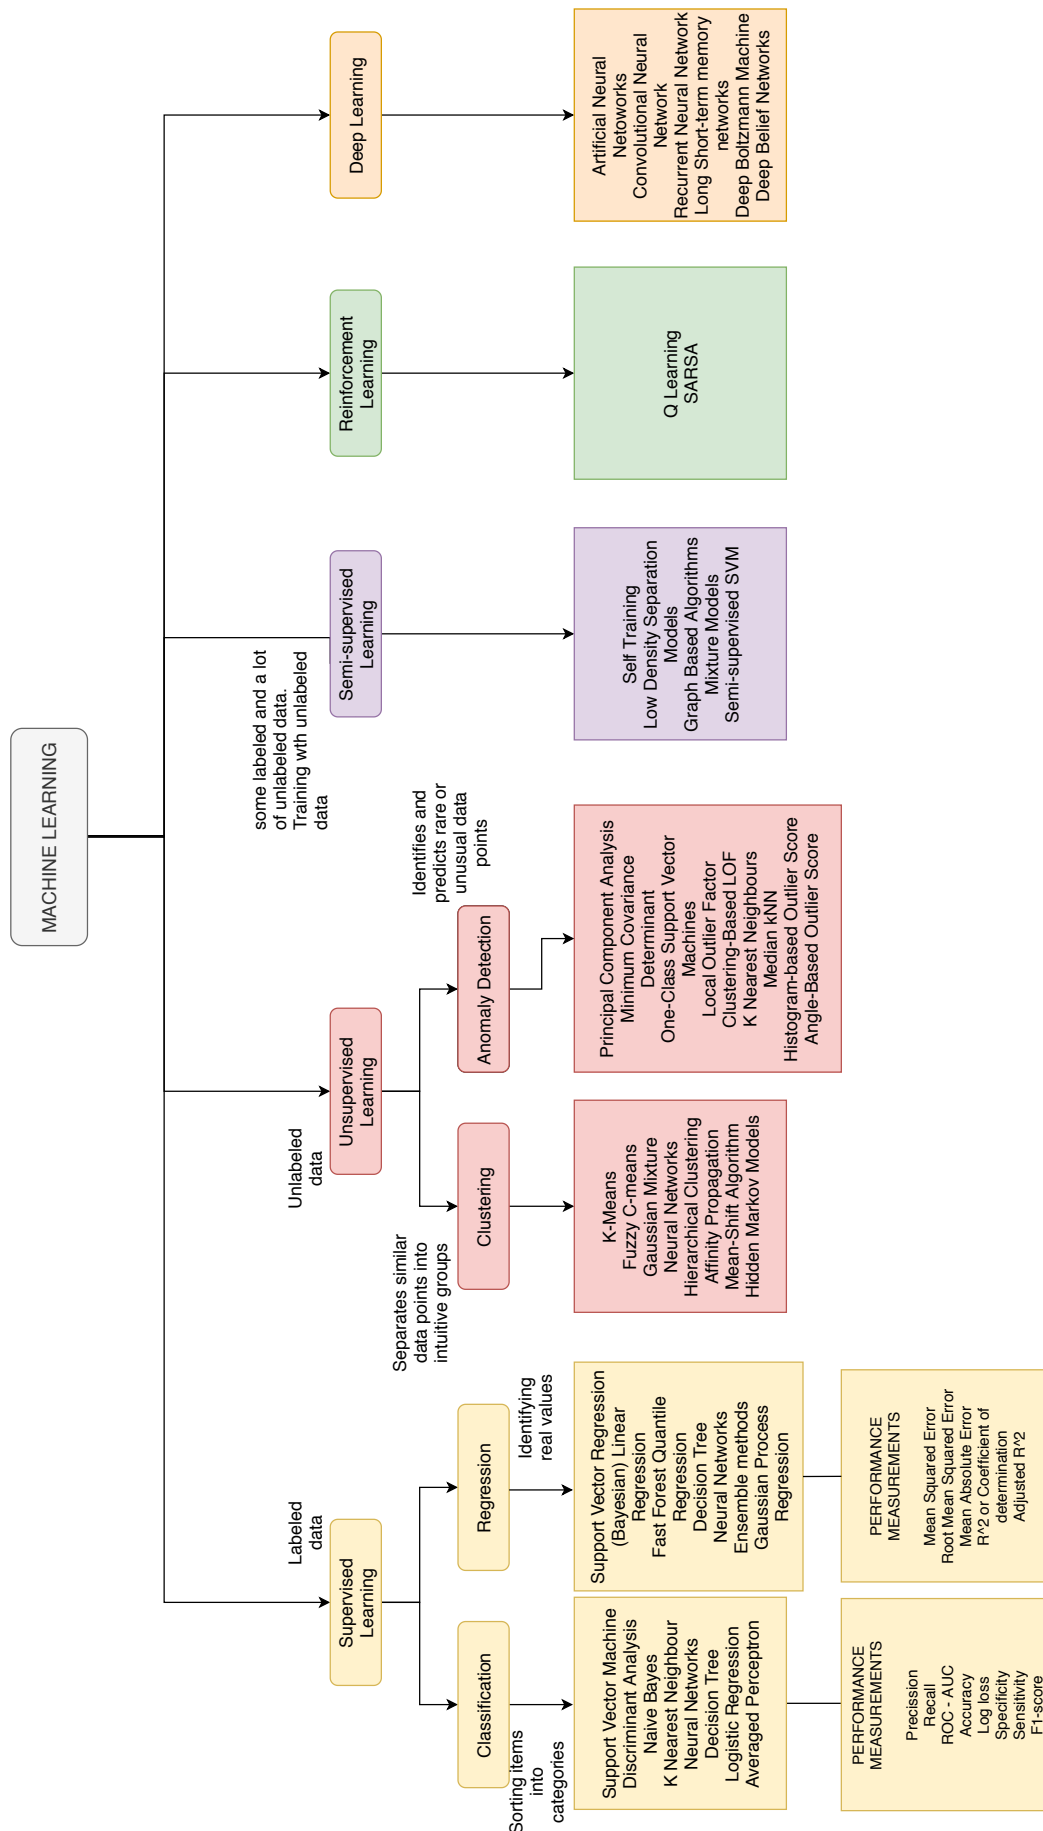


Figura 4.9 Esquema de componentes de Machine Learning I

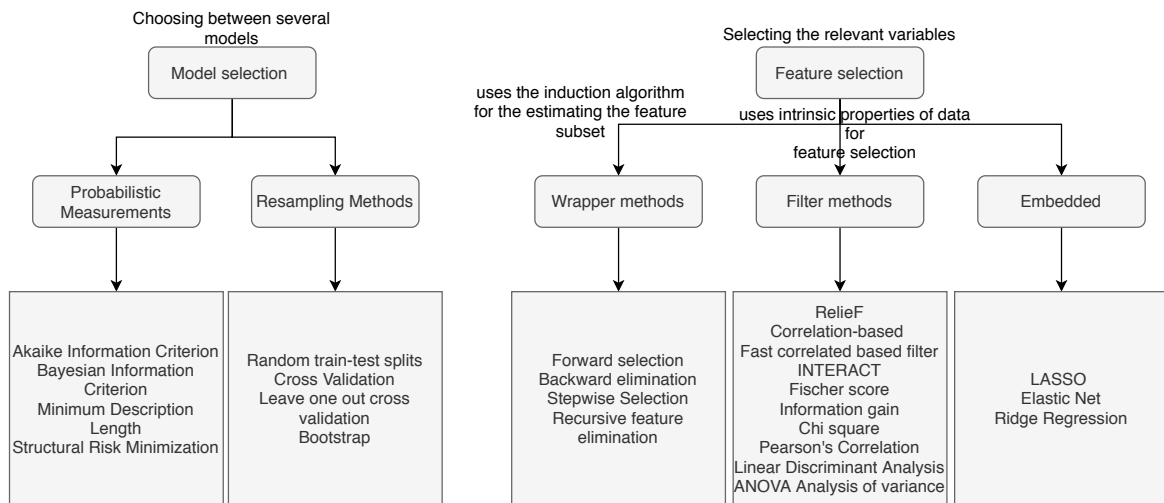


Figura 4.10 Esquema de componentes de Machine Learning II

### Tecnologías de la Información

- **Framework:** Se recogerán los frameworks que se utilicen en el artículo para la implementación de algoritmos y/o modelos. Cuando la información esté disponible, también se detallará la versión utilizada, el paquete y/o función, y qué se ha implementado con dicho framework.
- **Lenguaje de programación (*Programming language*):** El lenguaje de programación y cuando sea posible, la versión y para qué se ha utilizado.
- **Arquitectura del sistema de información (*Information system architecture*):** En aquellos casos en los que en el artículo se describa la utilización y/o implementación de un sistema de información, se recogerán los datos acerca de la arquitectura así como tecnologías utilizadas.
- **Seguridad TI (*IT Security*):** Se identificarán los artículos en los que se haya implementado seguridad en los sistemas informáticos utilizados.
- **Privacidad / Protección de datos personales (*Privacy / Personal data protection*):** Se identificarán los artículos en los que se mencionen aspectos acerca de la protección de la privacidad y de los datos personales desde puntos de vista de leyes y regulaciones.

#### **4.4.8. Síntesis de los resultados**

La información extraída en la plantilla se ha utilizado para definir los puntos principales a tratar en la revisión. Para ello, se ha elaborado una propuesta de presentación y estudio de los datos en la que se han definido los métodos para llevarlo a cabo. Se utilizarán tanto métodos automatizados como manuales para elaborar las gráficas y tablas que se presentan en este trabajo.

### **4.5. Resultados**

#### **4.5.1. Selección de estudios**

El equipo revisor ha comenzado con 201 artículos. Al finalizar la primera revisión, se ha llegado a un 74,1 % de acuerdo (149 de 201 documentos). Se han utilizado los comentarios incluidos por los revisores para constatar que el motivo por el que se han producido la mayor parte de los desacuerdos es porque algunos revisores incluían los estudios que trataban únicamente sobre los fetos, y otros revisores los descartaban. Tras aclarar este aspecto y decidir que es adecuado incluir también los estudios sobre fetos, los revisores han vuelto a considerar aquellos documentos en los que no se había llegado un acuerdo (Incluido/Descartado o Dudoso/Descartado), o los que habían quedado en empate Dudoso-Dudoso, para decidir su inclusión, descarte o duda.

Al finalizar esta segunda revisión, se han vuelto a estudiar los resultados. El equipo había alcanzado ya un 97 % de acuerdos (195 de 201 documentos). Se someten a una votación los estudios en los que se sigue sin llegar a un acuerdo, realizándose dicha votación de la siguiente manera: los dos otros revisores que no son los revisores iniciales del documento, leen título, resumen, descriptores y conclusiones y deciden si Incluir o Descartar el estudio. Al ser ya una etapa final, no se permitiría marcar el artículo con el estado 'Dudoso'.

Al finalizar esta etapa de selección resultaron incluidos por el equipo 169 artículos del total que se obtuvo de las bases de datos: 681 (antes de quitar los duplicados y realizar selección alguna). En este momento, dado que los conceptos sobre los documentos a incluir en la revisión estaban mucho más claros, se ha iterado un paso de la selección de artículos. Dos revisores volvieron a revisar (título, abstract y keywords) de la lista inicial de artículos obtenidos de la base de datos. De esta iteración, se obtuvieron 5 documentos, que pasaron el proceso de revisión que todos los demás artículos. De estos 5, se incluyeron finalmente 2.

De estos 169, no se tenía acceso al texto completo de 5 artículos. Para ello, se contactó con la Biblioteca de la Universidad de Sevilla que facilitó el documento completo de 2 artículos. En el resto de los casos se contactó con los autores, de los cuales uno respondió

con el documento completo del artículo requerido. Adicionalmente, se recibió por parte del autor otro artículo relacionado con el tema de la revisión y se decidió incluir, ya que la metodología lo permite. En este punto, el equipo contaba con 170 artículos, dos de ellos sin texto completo.

No obstante, a lo largo del proceso de extracción de datos, varios documentos fueron excluidos por varios motivos: tipología distinta a la definida en los criterios de inclusión, documento duplicado, artículos del mismo autor con un grado de afinidad muy alto: un artículo es el precursor del segundo. Dado que en el segundo artículo se incorpora toda la información del primero, se escoge el segundo. Igualmente se han descartado los documentos en los que solamente se menciona el uso de Inteligencia Artificial pero no se da ningún tipo de detalle.

En el diagrama de flujo inspirado en el propuesto por las directrices Prisma [3] que se ha representado en la Figura 4.11, se puede observar el camino recorrido por los artículos desde su búsqueda hasta su inclusión. Para una mayor claridad, cuando en el diagrama se especifica *Documentos revisados* y *Documentos revisados II*, se refiere a la, primero, la revisión inicial realizada para eliminar los falsos positivos. La segunda revisión hace referencia a la que realizan todos los miembros del equipo, posterior a la primera.

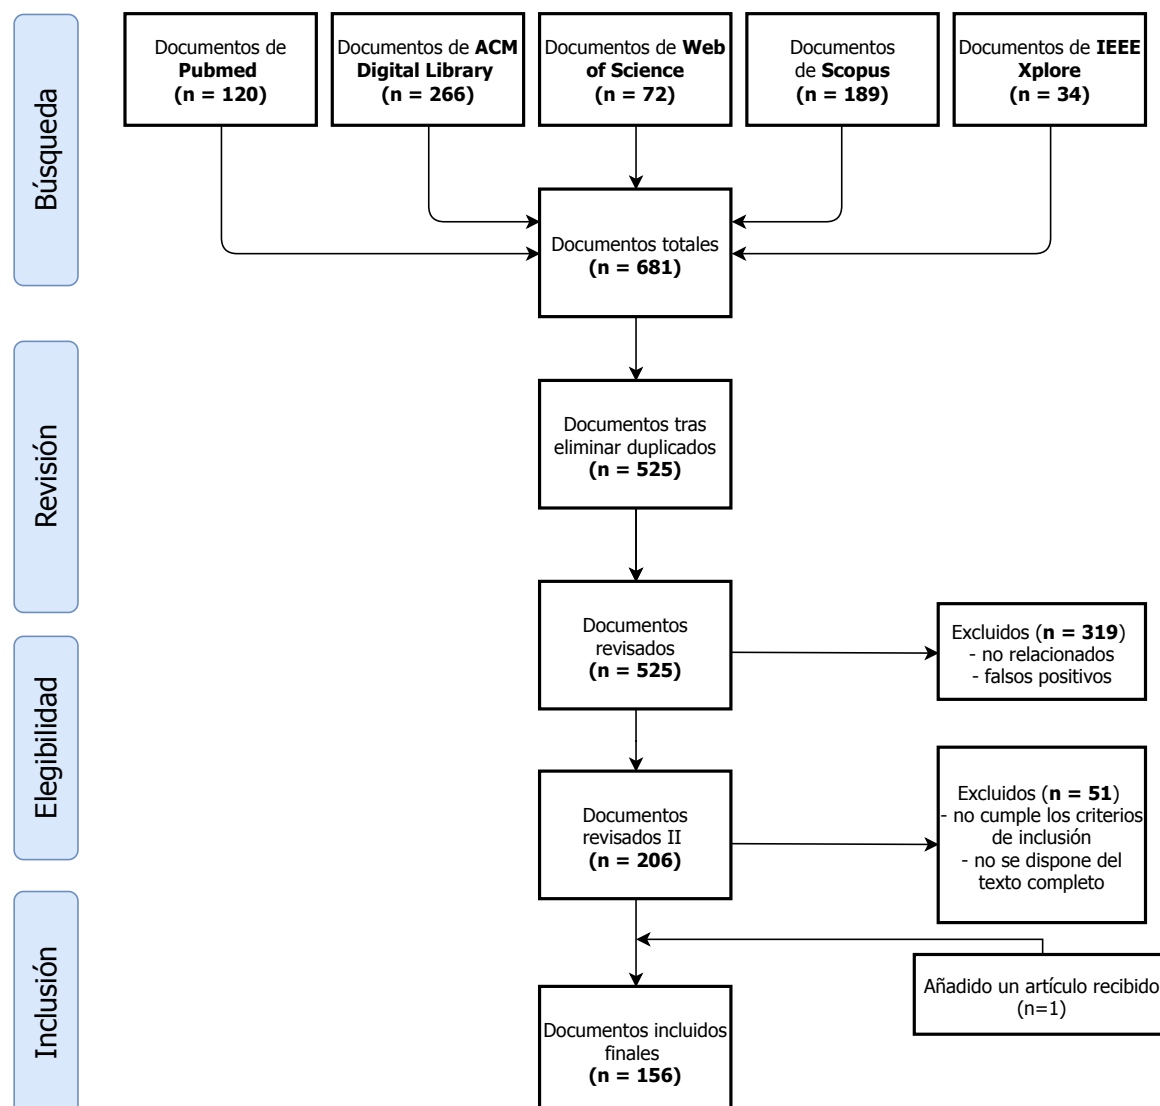


Figura 4.11 Diagrama de flujo de la estrategia de búsqueda e inclusión del protocolo desarrollado

#### 4.5.2. Características de los estudios

En esta sección se van a dar a conocer los detalles acerca de los estudios que se han incluido en la revisión.

Se puede observar en la Figura 4.12 la tendencia prácticamente creciente de publicación que han seguido los artículos. Al principio, los artículos publicados eran cada vez más pero seguían una subida muy suave, hasta que en el año 2018 y 2019 se aprecia un cambio en el ritmo de publicación. El año 2020 aparece con menos artículos ya que esta gráfica se ha elaborado con los datos extraídos a fecha de la última búsqueda (14 febrero 2020).






Figura 4.12 Estudios publicados a lo largo del periodo incluido en la revisión

En cuanto a la tipología de artículos, tal y como se puede ver en el gráfico 4.13, los más frecuentes son los artículos de revista (*Articles*), publicaciones en congresos o conferencias (*Conference proceedings*) y artículos que forman parte de un libro (*Book*).




Figura 4.13 Tipología de los estudios

### 4.5.3. Resultados de la extracción de datos de cada estudio

A título ilustrativo, en este apartado se muestra como ejemplo la información extraída de un artículo para cada uno de los bloques abordados: general (Figura 4.14), medicina (Figura 4.15), computación (Figura 4.16) y tecnologías de la información (Figura 4.17).

GENERAL	
Authors	Cerqueira, F.R. et al.
Title	NICeSim: An open-source simulator based on machine learning techniques to support medical research on prenatal and perinatal care decision making
Journal / Conference	Artificial Intelligence in Medicine
Publication Year	2014
Country	Brazil
Short Summary	This paper describes NICeSim, an open-source simulator that uses machine learning (ML) techniques to aid health professionals to better understand the treatment and prognosis of premature newborns.
Purpose / Aim	To deliver a computational system to aid medical research in understanding the correlation of key variables with the studied outcome so that new standards can be established for future clinical decisions
Final product	Model
Functions	Prediction of neonatal mortality
Experiment size	N/A
Health standards	The project was submitted for analysis and approval by UFV Ethical Committee for Research with Human Subjects (CEP), in accordance with Resolution 196/1996 and Resolution 466/2012 of the Brazilian National Health Council (Conselho Nacional de Saúde do Brasil).
Social parameters	N/A
Conclusions	Once the simulator is fed with appropriate data, it can be a powerful tool to comprehend quantitative and qualitative characteristics of the attributes and the outcome variable; It has been demonstrated the usefulness of NICeSim for studies on prenatal and perinatal care by constructing a model with a very good predictive power to simulate the effects that the variables Apgar scale, respiratory distress syndrome, gestational age, and birth weight have on the death risk of preterm neonates

Figura 4.14 Plantilla de extracción: bloque "General"

MEDICAL	
Process	Mortality
Pregnancy characteristics	NS
Maternal variables and characteristics	NS
Fetal variables and characteristics	NS
Delivery	NS
Postpartum aspects	Birth weight, Apgar score, respiratory distress syndrome

Figura 4.15 Plantilla de extracción: bloque “Medicina”

COMPUTING: Artificial Intelligence	
Approach	Machine Learning; Decision Support System
Data acquisition	Medical records: collected from hospital. Neonatal Intensive Care Unit of São Sebastião Hospital, at Vicoso, Minas Gerais State, Brazil
Knowledge Representation	NS
Methodology	NS
Algorithm	Artificial Neural Networks; Support Vector Machine
Dataset	<p>Premature newborn information: Apgar score, respiratory distress syndrome, gestational age, and birth weight (Initial 114 attributes);</p> <p>The final dataset is composed by the four remaining attributes: apgarLess7, occurrence of intrauterine growth restriction (IUGR), gestational age (GA), occurrence of respiratory distress syndrome (RDS)</p>
COMPUTING: Machine Learning	
Preprocessing / Data curation	<p>Dimensionality reduction: initial set of attributes was reduced (based on a pre-analysis by partner physicians and second using ML algorithms) to only the 15 reducing its dimensionality, without losing important information.</p> <p>Feature selection: computational (wrapper) methods and human input</p>
Type	Supervised
Model technique	Classification
Validation / Test	34% data for test; 10-fold cross-validation
Metrics	<p>Accuracy; Sensitivity; Specificity; AUC-ROC.</p> <p>Best: ANN (multilayer with backpropagation approach). Accuracy of 86,7%. AUC-ROC of 0.84 for the positive class</p>

Figura 4.16 Plantilla de extracción: bloque “Computación”

Information Technology	
Framework	Weka software: machine learning algorithms
Programming language	NS
IS Architecture	GUI (clinicians)
IT Security issues	NS
Protection personal data / privacy	NS

Figura 4.17 Plantilla de extracción: bloque “Tecnologías de la información”

#### 4.5.4. Síntesis de los resultados

Esta sección se corresponde a la presentación de los resultados de la revisión. Debido a su entidad, se dedica a continuación todo un capítulo aparte.



# Análisis de los resultados de la revisión sistemática exploratoria

## 5.1. Categorías analizadas

Seguidamente se presentan las categorías analizadas, correspondientes a los temas de interés definidos en el protocolo de la revisión sistemática exploratoria llevada a cabo.

En los gráficos y las tablas que se muestran en este capítulo aparecen multitud de acrónimos que facilitan su visualización. El significado de todos los acrónimos puede consultarse el apartado 5.3 que se encuentra al final de este capítulo.

### 5.1.1. Descriptores (Author Keywords)

En la Figura 5.1 se pueden observar los descriptores del autor que han aparecido con mayor frecuencia. Se pueden dividir en dos grandes bloques, la parte médica con 6 ocurrencias distintas: *Pregnancy*, *Fetal heart rate*, *Cardiotocography*, *Gestational diabetes*, *prenatal care* y la parte de inteligencia artificial con 14 ocurrencias: *Machine Learning*, *Decision Support Systems*, *Data Mining*, *Artificial neural networks*, *Mobile health*, *Decision Trees*, *Support vector machines*, *Big data*, *Artificial Intelligence*, *Random Forest*, *E-Health*, *Classification*, *Computational Intelligence*.

A simple vista se puede observar que dentro de la IA, los subcampos más populares son el de *Machine Learning*, *Decision Support Systems*, *Data Mining* y *Big data* y *Classification* mientras que los algoritmos más populares son *Artificial Neural Networks*, *Decision Trees*, *Support Vector Machines* y *Random Forest*. Desde el punto de vista médico, destaca la popularidad de la palabra *Pregnancy*, así como *Fetal heart rate* y *Cardiotocography*. Se observa también una gran popularidad del término *Gestational Diabetes*, que es la única afección que aparece en el gráfico.

No se han podido incluir en el gráfico todos los descriptores, así que por motivos de legibilidad, se han añadido solamente aquellos con una frecuencia mayor de 5. Otro detalle importante es que, ante la gran variedad de descriptores, se ha realizado una unificación de los términos más recurrentes en los que se entiende que se está refiriendo a lo mismo (por ejemplo: se han unificado los resultados en singular y en plural; se han unificado términos como *pollutants*, *polluants*, *pollution*; *social networks*, *social media*; *clinical decision support*, *decision support*, *clinical decision support system*; etc.




Figura 5.1 Descriptores más relevantes presentes en los estudios revisados

### 5.1.2. Países de publicación

Como se puede observar en la Figura 5.2, los países donde más se ha publicado acerca de este tema son: Estados Unidos (40 de 156 artículos, 25,64 %), India (25 artículos, 16 %), Portugal (19 artículos, 12,18 %), Brasil y China (18 artículos cada una, 11,53 %). En menor medida se ha publicado en Inglaterra, Pakistán, Arabia Saudí, Sudáfrica, Rusia, Canadá, España, Italia, Holanda, Etiopía, Kenya, Marruecos, Francia, Alemania, Rumanía, Turquía, Irán, Afganistán, México, Colombia, Austria, Grecia, Albania, Estonia, Bélgica, Indonesia, Irlanda, Noruega, Finlandia, Suecia, Serbia, Bosnia y Herzegovina. Es un tema que se estudia a lo largo de todo el mundo.








Figura 5.3 Producto final obtenido en los estudios revisados

Los *e-health systems* presentan distintas funciones: predicción del estado de salud del feto [45, 30], predicción de sufrir un aborto [46], detección de la hipertensión [47], monitorización del estrés de la embarazada [48] y la predicción de la muerte del recién nacido [49].

En el caso de los *wearables*, dos de los tres estudios proponen su uso para monitorización del estado general y mejora de la calidad de vida [50, 51], mientras que el tercero lo propone para la monitorización del azúcar en sangre, dato relevante en la diabetes gestacional [52].

Las aplicaciones móviles se proponen para mejorar la atención y tratamiento de la depresión en la embarazada [53], monitorización del estado de salud de una embarazada con trastornos hipertensivos [54, 31], y monitorización del estado de salud en general [55–57].

Los *chatbots* se han presentado con la finalidad de proveer asistencia a las mujeres durante el embarazo [58, 59].

En el caso de los sistemas de soporte a decisiones, del total de 12 artículos, 4 tratan la diabetes gestacional [60–63], mientras que 2 de ellos tratan la pre-eclampsia [64] o trastornos hipertensivos [65].

Del resto de artículos, se estudia el estado de salud y bienestar del feto [66], la toma de decisiones a la hora de realizar una cesárea [67] y algunos tratan temas relacionados con la calidad de vida y bienestar [68–71].

#### 5.1.4. Factores sociales, demográficos, etc.

Del total de 156 artículos, casi la mitad, 71 (45,5 %) han considerado factores socio-económicos, demográficos, étnicos y/o religiosos. De estos 71, el factor étnico/racial se ha tenido presente en 25 artículos (16 % del total).

Un elevado número de artículos (un 14,1 % del total, 22 artículos) se han realizado en países o regiones en los que el nivel de ingreso es medio-bajo o en circunstancias en las que se ha considerado que había una falta de atención médica y/o de recursos médicos, situaciones de desigualdad, áreas rurales, etc.

Asimismo, son 20 artículos (12,8 % del total) en los que se ha considerado el nivel de educación de las pacientes.

#### 5.1.5. Estándares de la salud (Health standards)

Han sido un total de 42 artículos (26,9 %) los que mencionan haber contado con la aprobación de un comité ético, tratándose en su gran mayoría de comités éticos de los hospitales en los que se llevaban a cabo los estudios.

En dos casos, se indica explícitamente que no se ha necesitado una revisión ética ya que, aunque se trataba información de pacientes reales, las bases de datos habían sido anonimizadas [72, 73].

Se ha mencionado el uso o aplicación de estándares de la salud en 69 artículos (44,2 % del total), siendo los más utilizados: International Classification of Diseases (diferentes versiones) [74–76, 61, 77, 78, 54, 65, 79–82], World Health Organization [78, 83–87] y Health Level-7 (HL-7) [65, 64, 62, 63].

#### 5.1.6. Subcampo de Inteligencia Artificial

*Machine Learning* encabeza la lista de las técnicas de IA más utilizadas en los estudios, seguida por *Decision Support Systems* y *Data Mining*, quedando el resto con una representatividad de menos del 10 %, según se puede observar en la Figura 5.4.

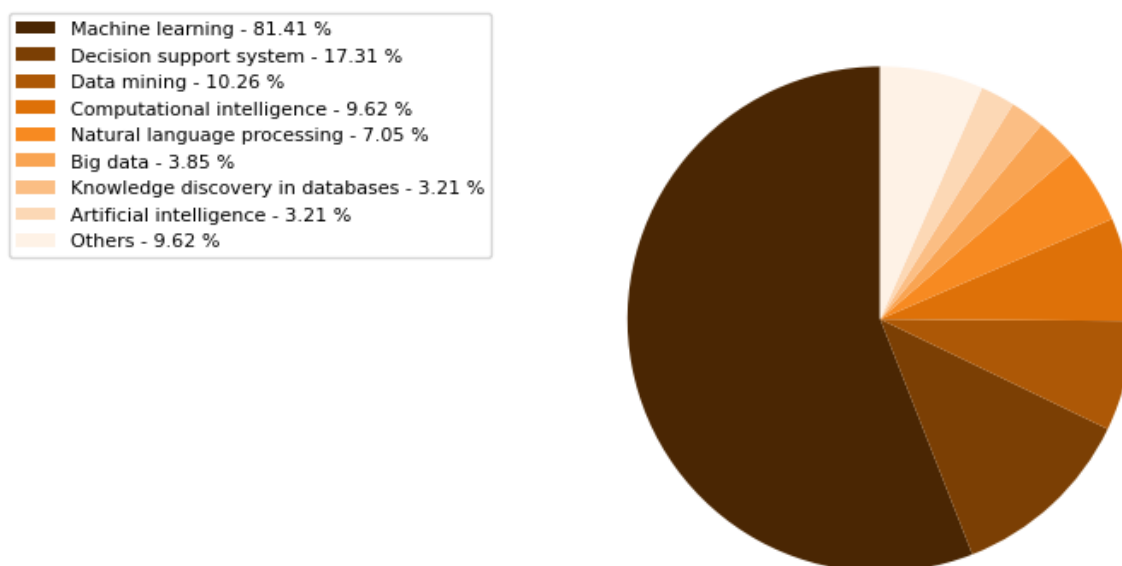


Figura 5.4 Subcampos de la Inteligencia Artificial tratados en los estudios revisados

### 5.1.7. Fuente de los datos

Se observan en la Figura 5.5 los métodos de adquisición de datos de los estudios revisados. Los registros médicos provienen en su totalidad de hospitales o clínicas.

Se emplean como fuente de datos bases de datos provenientes de repositorios en 32 artículos (20,5 % del total), y los más utilizados son: *UCI Machine Learning cardiotocography dataset*, en forma de cardiotocografías fetales, (7 de 32, un 21,9%); *Term-Preterm EHG Database de Physionet* (5 de 32, un 15,6%), en forma de electrohisterogramas.

El uso de sensores aparece en un 11,5 % de los casos (18 del total). Los sensores son utilizados para tanto para realizar mediciones a la embarazada: actividad, glucosa, pulso y presión arterial, nivel de azúcar en sangre; como al feto: corazón (electrocardiograma fetal); como al entorno de ambos: humedad, temperatura, niveles de polución.

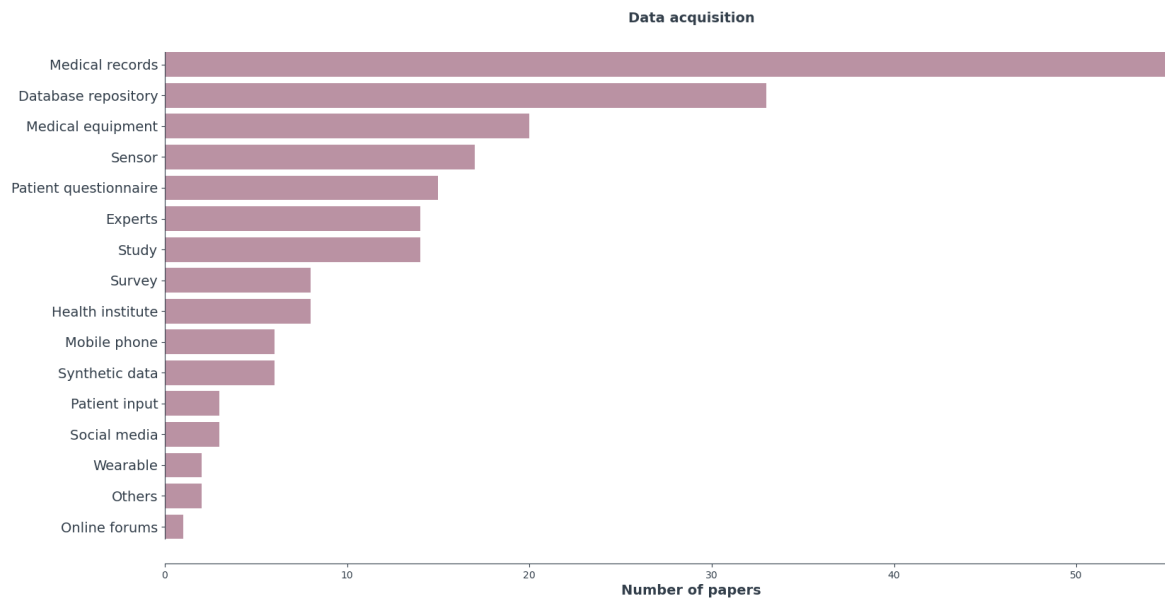


Figura 5.5 Fuentes de adquisición de datos en los estudios revisados

### 5.1.8. Preprocesamiento de los datos

De los 59% de estudios (92 de 156) que han mencionado la utilización de alguna técnica de preprocesamiento de los datos, en un 31,52% (29 artículos) se ha mencionado aplicación de alguna técnica de ingeniería de características, siendo variadas las técnicas utilizadas: *Logistic Regression*, *Segmented Pigeon Hole algorithm*, *Wrapper methods*, *Principal Component Analysis*, *ReliefF*, *Recursive Feature Elimination*, *Haar-like features*, etc. En el preprocesamiento de datos es también común la técnica Synthetic Minority Over-sampling Technique (SMOTE), lo que deja entrever que los datos suelen tener clases minoritarias y mayoritarias, sin que exista un equilibrio de casos. Esto puede afectar a la calidad de los resultados de los algoritmos si no se aplica algún tratamiento a dichos datos. En un 24% de los casos (22 artículos) se han reportado datos incompletos, siendo la fuente de estos datos registros médicos en su gran mayoría.

### 5.1.9. Tipo y técnica del modelo

En el caso de que el subcampo de IA mencionado en el estudio fuera aprendizaje automático, se ha extraído información acerca del tipo y la técnica. Este dato se ha recogido para un 77,56% de los artículos (121 de 156). Mayoritariamente, solamente se ha empleado un único tipo de aprendizaje en el artículo (112 artículos de 121, 92,56%), siendo el más común el aprendizaje supervisado (*Supervised learning*), con 104 artículos (86%). En los

artículos en los que se ha empleado más de un tipo, la combinación más repetida ha sido la de aprendizaje supervisado y no supervisado (8 artículos, 6,61 %).

En cuanto a las técnicas, esta información aparece en un 76,2 % de los estudios (119 estudios del total de 156), siendo Clasificación la que más se repite (98 artículos, 82,36 %), seguida de Clustering (14 artículos, 11,76 %), Regresión (11 artículos, 7,05 %) y Reducción de la dimensionalidad (2 artículos, 1,68 %).

### 5.1.10. Algoritmos

La gran mayoría de los artículos han especificado el uso de algún tipo de algoritmo, independientemente de la técnica de IA utilizada: un 92,3 % (144 de 156 artículos). Más de la mitad de estos estudios (66 %, 95 artículos) utilizan más de un algoritmo.

Uno de los algoritmos más empleados es Árboles de decisión (*Decision trees*) y sus variantes, incluyendo también aquí *Random Forest*. Se implementan en un 45,83 % de los estudios (66 de 144), siendo las variantes más utilizadas: *Decision trees*, *Random Forest*, *Classification and Regression Trees*, *Boosted Trees*, así como algunas implementaciones: C4.5, J48 e ID3. Otro algoritmo popular es Máquinas de vectores de soporte (*Support Vector Machines*), implementado en un 36,11 % de los casos (52 de 144 artículos), en ocasiones utilizando distintas funciones kernel (*Linear*, *Radial Basis function*) y Regresión Logística (*Logistic Regression*), 27,78 % de los estudios (40 de 144). Las Redes Artificiales Neuronales (*Artificial Neural Network*) han sido implementadas en un 24,3 % (35 de 144 artículos). El algoritmo de K-vecinos más Próximos (*K-Nearest Neighbours*), se ha implementado en un 12,5 % (18 de 144) artículos. La técnica de Adaboost se ha utilizado en 6,9 % de los artículos (10 de 144). El algoritmo de Clustering más utilizado es k-medias (*k-means*), en un 6,25 % de los artículos (9 de 144). Otros algoritmos que se han utilizado en menor medida son: Regresión Lineal, Naive Bayes, Extreme Machine Learning, Ensemble classifiers, Genetic Algorithms, Timed Fuzzy Cognitive Map, Quantile regression.

La lista completa de algoritmos se puede observar en la Tabla 5.11.

### 5.1.11. Validación y test del modelo

Para realizar la validación del modelo, 71 artículos (45,51 %) utilizan técnicas de validación cruzada (*k-fold cross-validation*). De estos artículos, son 59,15 % (42 artículos) los que dividen el número de subconjuntos en 10 (*10-fold-cross-validation*), siendo la división más utilizada. Dividen los datos en 5 subconjuntos el 23,5 % de los artículos (18 de 71). La validación cruzada del tipo *Leave One Out Cross-Validation* se emplea en un 5,63 % de los casos (4 artículos), y *Hold One Out Cross-Validation* en un 8,45 % de los estudios (6

artículos). En el resto de los casos se emplean otro número de subconjunto: *3-fold*, *4-fold*, *9-fold*, etc.

### 5.1.12. Lenguajes de programación y Frameworks

62 artículos (33,87 %) han proporcionado información sobre el lenguaje de programación utilizado para realizar la implementación. Esta lista está encabezada por el lenguaje de programación R, que aparece en un 32,2 % de los artículos (20 de 62), Python (27,4 %, 17 de 62 artículos), MATLAB (17,7 %, 11 de 62 artículos) y Java (9,67 %, 6 de 62 artículos). Estos resultados y el resto de lenguajes de programación con menos incidencia se puede observar en el gráfico 5.6.

Información acerca de los frameworks utilizados ha sido localizada en 99 artículos del total, 63,44 %. Los frameworks de IA utilizados hacen un 79,69 % (79 de los 99 artículos), siendo el resto frameworks de otras tecnologías también utilizadas en los artículos pero no IA (por ejemplo: Bluetooth, Internet of Things). Los frameworks más utilizados de IA son: Scikit-learn de Python (12 artículos de 79, 15,2 %), WEKA software (11 artículos de 79, 13,9 %), MATLAB (11 artículos de 79, 13,9 %), SPSS Software de IBM (10 artículos de 79, 12,66 %), STATA Software (5 de 79 artículos, 6,32 %), SAS Software (4 artículos de 79, 5 %).

En cuanto a paquetes de lenguajes de programación, en el que más se han utilizado ha sido en R: *randomforest*, *dismo*, *gbm*, *rpart*, *paralell*, *doparalell*, *cared*, *libsvm*, *mice*, *hmisc*, *glmnet*, *prcomp*, *glmulti*, *dsa*, *gcdnet*. En menor medida, se han utilizado los siguientes paquetes de Python: *LightGBM*, *SHAP*, *hmmlearn*.

En el resto de los casos donde se emplean frameworks, mayoritariamente se utiliza Android studio para desarrollo móvil y estándares de comunicación como pueden ser Bluetooth, o formatos de intercambio de datos: JSON, XML.




Figura 5.6 Lenguajes de programación empleados en los estudios revisados

### 5.1.13. Seguridad TI y protección de datos personales

En 11 artículos (7 %) se menciona el tema de la seguridad informática. Las soluciones propuestas son: uso de certificados web y protocolo seguro de transferencia de hipertexto (HTTPS), cifrado de datos y contraseñas, uso de red privada virtual, uso de la UNE-EN ISO 13606-1:2013 (Informática sanitaria. Comunicación de la historia clínica electrónica), firewall, *Onion routing* y pruebas de caja blanca.

El aspecto de la protección y privacidad de la información personal se ha abordado en 23 % de los estudios (36 del total). El 86,1 % (31 de 36) de los estudios han solicitado el consentimiento informado a los pacientes, mientras que el resto han utilizado información anonimizada.

### 5.1.14. Procesos asociados al embarazo

Según se puede observar en la Figura 5.7, el espectro de procesos asociados con el embarazo que se han identificado en la revisión es muy amplio. Ordenados de mayor a menor ocurrencia, los estudios tratan sobre: estado fetal, defectos de nacimiento, parto pretérmino, diabetes gestacional, crecimiento del feto, pre-eclampsia, mortalidad, trastornos hipertensivos, parto, depresión, estrés, anemia, interrupción y complicaciones posparto.

Es notable que la mayoría de los estudios investigan acerca de la salud física de la embarazada, mientras que son muy pocos los que se enfocan en la salud mental o en temas



relacionados con las emociones. En concreto, en la categoría de *Postpartum depression, Depression y Stress*, hay sólo un 5,13 % de documentos (8 de los 156 totales).

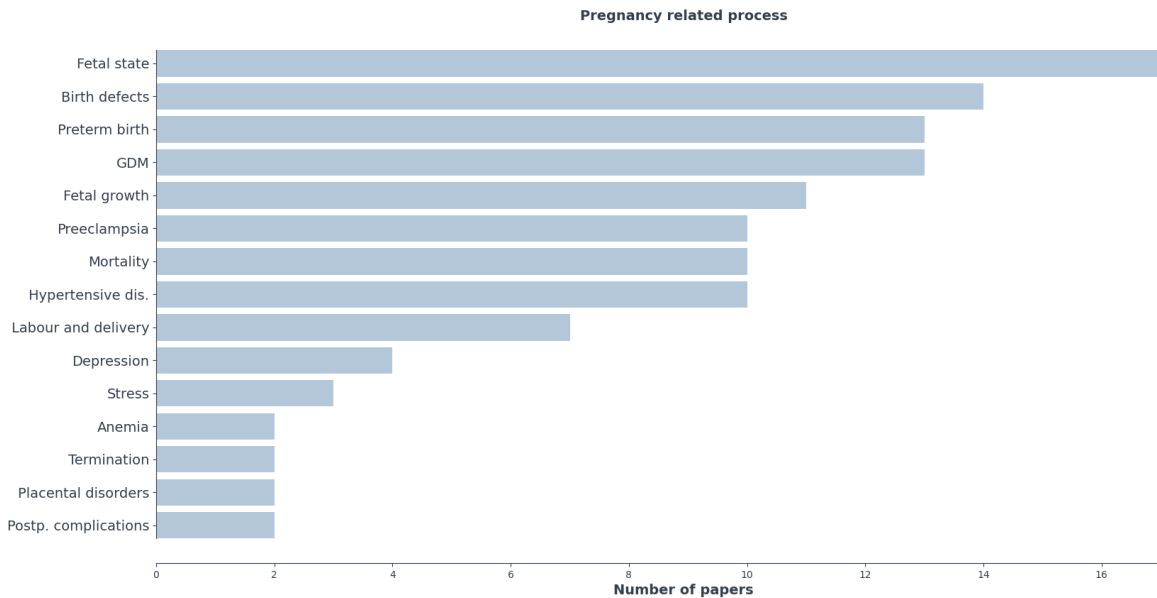


Figura 5.7 Procesos asociados al embarazo presentes en los estudios revisados

A continuación se desglosa el detalle para los procesos más estudiados:

### Parto pretérmino o prematuro

Se estudian los embarazos que finalizan en parto pretérmino (5,13 % del total) y *Machine Learning* es el enfoque más utilizado, siendo las tareas de clasificación las más comunes. En todos los casos, la finalidad es la predicción del parto pretérmino. En un caso se relacionan los partos pretérmino con la exposición a partículas materiales ambientales (PM2.5). El total de los estudios presentan como producto final un modelo. Las fuentes de datos son en su mayoría bases de datos médicas, registros médicos y estudios de la salud.

La información desglosada por artículos se puede encontrar en la Tabla 5.1.

Tabla 5.1 Inteligencia artificial aplicada al estudio del embarazo prematuro

<b>Approach</b>	<b>Task</b>	<b>Algorithms</b>	<b>Final product</b>	<b>Functions</b>	<b>Ref</b>
ML	Classification	RF, Penalized LR	Model	prediction of preterm birth	[88]
ML, Big data	Classification	RF, DT, SVM, Ensemble	Model	prediction of preterm birth	[89]
ML	Classification	Linear, Quadratic Discriminant, UND, PCL, kNN, DT, SVM Parzen	Model	prediction of preterm birth	[90]
ML	Regression	SuperLearner, Linear Regression, RF Regression, Generalized additive models	Model	prediction of preterm birth	[91]
ML	Classification	SVM (linear and RBF kernels), LR	Model	prediction of preterm birth	[92]
ML	Classification	Linear Correlation, Normalized Mutual Information, DT, LR	Model	prediction of preterm birth	[93]
ML	Classification	kNN, RF, SVM	Model	prediction of preterm birth	[94]
ML, NLP	Regression	NLP, Regularized LR, SVM, Gradient boosting, Recurrent NN	Model	prediction of extreme preterm birth	[76]
ML	Classification	RF, Ellipse fitting	Model	relationship evaluation between PM2.5 exposure and preterm birth	[95]

continuación

Tabla 5.1 – continuación

Approach	Task	Algorithms	Final product	Functions	Ref
ML, DSS	Classification	SVM with smooth linear kernel function	Model	prediction of preterm birth, Apgar score prediction	[96]
ML	Classification	SuperLearner	Model	prediction of birth outcome	[75]

### Defectos de nacimiento

Los estudios acerca de defectos de nacimiento (8,97 %, 14 artículos del total) se dividen principalmente en detección de aneuploidía (28,57 %, 4 artículos), predicción de defectos congénitos del corazón (21,42 %, 3 artículos) y predicción de la macrosomía (21,42 %, 3 artículos). En esta categoría se han desarrollado modelos y un sistema experto. La fuente de datos es muy variada: registros y equipos médicos, institutos de la salud, estudios, cuestionario a pacientes, repositorios de datos, etc. El 71 % de los estudios realizan algún tipo de preprocesamiento a sus datos, principalmente: eliminación de datos incompletos y tratamiento de datos no representativos de las clases.

La información desglosada por artículos se puede encontrar en la Tabla 5.2.

Tabla 5.2 Inteligencia artificial aplicada al estudio de los defectos de nacimiento

Approach	Task	Algorithms	Final product	Functions	Ref
ML, CI	Classification	ANN (Feed-forward)	Model	aneuploidy detection	[97]
ML, CI	Classification, Clustering	ANN (Feed-forward backpropagation), K-means	Model	aneuploidy detection	[98]
ML, CI	Classification	SVM, ANN, kNN	Model	aneuploidy detection	[99]
ML	Classification	DT, SVM, Hidden Markov models	Model	aneuploidy detection	[100]

continuación

Tabla 5.2 – continuación

<b>Approach</b>	<b>Task</b>	<b>Algorithms</b>	<b>Final product</b>	<b>Functions</b>	<b>Ref</b>
NLP, DM	NS	Rule based bootstrapping approach	Model	assessment of birth defects reporting on social media	[77]
ML, DM	Classification	Weighted SVM, Weighted RF, LR	Model	prediction of congenital heart defects	[101]
ML	Classification	RF, Gradient Boosting, LR	Model	prediction of congenital heart defects	[79]
Vision	NS	NS	Model	prediction of congenital heart defects	[102]
ML	Classification	MCMC sampling, Skewed multivariate random effects, Polynomial regression spline, Bayesian	Model	prediction of macrosomia	[103]
ML	Classification	Multivariable LR, RF	Model	prediction of macrosomia	[104]
ML	Classification	Ensemble ML, RF (XGBoost, GAM), LR, Spatial clustering	Model	relationship evaluation between PM2 exposure and macrosomia	[83]
ML	Classification	LR, RF	Model	prediction of gastroschisis	[105]
ML	Classification	LR, RF	Model	classification of drugs safety	[74]

continuación

Tabla 5.2 – continuación

Approach	Task	Algorithms	Final product	Functions	Ref
DM	NS	Modelling Association Rules	Expert system	prediction of congenital malformations	[106]

### Diabetes Gestacional

En la Tabla 5.3 se puede apreciar que los 13 artículos (8,34 %) en los que se estudia la diabetes gestacional, 8 (5 % del total) están enfocados en la predicción de la enfermedad mientras que el resto están dedicados a su monitorización, 3 de ellos desde casa. En gran medida se han desarrollado modelos y sistemas de soporte a la decisión, siendo solo uno el caso en el que se desarrolla un *wearable*. El enfoque de IA más empleado es *Machine Learning*, en concreto aprendizaje supervisado, siendo las tareas más recurrentes las de clasificación (para realizar la predicción de la enfermedad). En este caso, los algoritmos más comunes son: *Decision Trees*, *Logistic Regression*, *Random Forest*, *Bayesian Networks*, *Support Vector Machines* y *Adaptive Boosting*. La fuente de los datos es variada, siendo la principal los registros médicos. En algunos casos, se obtiene de sensores y wearables (sobre todo medidores de glucosa) y teléfonos móviles.

La información desglosada por artículos se puede observar en la Tabla 5.3.

Tabla 5.3 Inteligencia artificial aplicada al estudio de la diabetes gestacional

Approach	Task	Algorithms	Final product	Functions	Ref
ML	Classification (S)	DT, GBM; LR (baseline)	Model	prediction of GDM	[107]
ML	Classification (S)	Multivariate Bayesian LR using MCMC; Metropolis-Hastings algorithm	Model	prediction of GDM	[108]
ML	Classification (S)	LR, RF, AdaBoost	Model	prediction of GDM	[109]

continuación

Tabla 5.3 – continuación

<b>Approach</b>	<b>Task</b>	<b>Algorithms</b>	<b>Final product</b>	<b>Functions</b>	<b>Ref</b>
ML, CI	Classification (S)	RBFN	Model	prediction of GDM	[110]
ML	Classification (S); DL	DT, LR, DenseNet	Model	prediction of GDM	[111]
ML, CI	Classification (S)	AIRS, kNN; LR, DT, SVM (baseline)	Model	prediction of GDM	[112]
ML	Classification (S)	Cost-sensitive Hybrid Model, LR, BN, NN, SVM, CHAID tree	Model	prediction of GDM	[113]
ML, DSS	Clustering (U)	Expectation Maximization, C4.5 DT	DSS	home pregnancy and GDM monitoring	[60]
DSS	NS	statistical analysis (NS)	DSS	home pregnancy and GDM monitoring	[63]
ML	NS	statistical, computational analysis, ML algorithms (NS)	Wearable	home pregnancy and GDM monitoring	[52]
DSS	NS	intelligent data analysis (NS)	DSS	GDM monitoring	[62]
MAS	NS	deductive rules using Event Calculus	Demo	GDM monitoring	[114]
ML, KRR, Expert Systems	Classification (S)	Bayesian Networks	DSS	early diagnosis of GDM	[61]

### Pre-eclampsia y trastornos hipertensivos

La pre-eclampsia y los trastornos hipertensivos se estudian en 18 artículos (11,53 % del total). Concretamente, la pre-eclampsia aparece explícitamente en 10 artículos ([64, 115, 31, 81, 116, 117, 85, 118, 47, 119]), y los trastornos hipertensivos en otros 10 documentos [47, 119, 120, 78, 121, 54, 122–124, 65], siendo estudiadas tanto la pre-eclampsia como los trastornos hipertensivos de forma conjunta en 2 artículos [119, 120]. Aunque en el caso de la pre-eclampsia la mayoría de los estudios buscan su predicción, en los trastornos hipertensivos la finalidad de los estudios es mucho más variada: además de su predicción y monitorización, también se encuentran estudios que analizan su relación con la mortalidad de la embarazada, su impacto negativo en el embarazo y en el crecimiento fetal. En todos los casos, la tarea realizada es de clasificación. Se destaca que en un 22,2 % de los artículos se desarrollan *e-Health system* o aplicaciones móviles, pero se siguen encontrando con más frecuencia los modelos y los sistemas de soporte a la toma de decisiones. Nuevamente, es *Machine Learning* el enfoque que más se repite, aunque cabe destacar el uso de *Computational Intelligence*. En general, los algoritmos más utilizados son *Logistic Regression*, *Random Forest*, *Decision Trees*, *Support Vector Machines*, *Naive Bayes*. Los datos utilizados provienen en su mayoría de registros y equipos médicos y estudios de la salud. Cuando se han empleado sensores, ha sido para medir la presión arterial (22,2 %).

La información desglosada por artículos se puede observar en la Tabla 5.4.

Tabla 5.4 Inteligencia artificial aplicada al estudio de la pre-eclampsia y trastornos hipertensivos

Approach	Task	Algorithms	Final product	Functions	Ref
DSS	Classification	Bayesian Networks	DSS	providing maternal care, prediction of pre-eclampsia	[64]
ML	Classification	LR, DT, NB, SVM, RF, Stochastic GB, k-means	Model	prediction of pre-eclampsia	[115]

continuación

Tabla 5.4 – continuación

<b>Approach</b>	<b>Task</b>	<b>Algorithms</b>	<b>Final product</b>	<b>Functions</b>	<b>Ref</b>
ML	Classification	Bayesian Networks	Mobile app	prediction of pre-eclampsia, home pregnancy monitoring	[31]
ML	Classification	LR, RF, Backward Selection, Decision rules	Model	prediction of pre-eclampsia	[81]
ML	Classification	LR, Regularized Regression	Model	prediction of pre-eclampsia	[116]
ML	Classification	LR	Model	prediction of pre-eclampsia	[117]
ML	Classification	LR, SVM, RF, Gaussian NB	e-Health system	assesment of dietary habits	[85]
ML	Classification	RF, Boosted LR, C4.5, C5 Trees, SVM (linear kernel and RBF), kNN, LDA, Stochastic GB, MARSplines, AdaBoost	Model	prediction of pre-eclampsia	[118]
ML	Classification	LR, Gaussian NB, RF, SVM	e-Health system	detection of hypertension	[47]
ML	Classification	AODE	Model	prediction of pregnancy outcome	[119]
KRR	Classification	Ontology-based model	DSS	health monitoring	[65]

continuación



Tabla 5.4 – continuación

Approach	Task	Algorithms	Final product	Functions	Ref
ML, CI	Classification	Nature-inspired PSO, Multilayer perceptron, Conventional multilayer perceptron	Model	health monitoring	[121]
ML, KDD	Classification	AODE, NB, NB Tree, SVM, Multilayer Perceptron, RBFN, C4.5, RF	Model	prediction of maternal mortality, prediction of birth outcome	[120]
ML, DSS	Classification	ID4, NB Tree, J48 DT	Model	prediction of hypertensive disorder	[124]
ML, CI	Classification	ANN	Model	prediction of hypertensive disorder	[122]
ML, DSS	Classification	NB	Mobile app	health monitoring	[123]
ML	Classification	J48 DT, NB	Model	health monitoring	[54]
ML	Classification	DT, SVM, kNN, Boosted and Bagged trees	Model	prediction of SGA	[78]

### Estado del feto

El distrés fetal se estudia en 17 artículos (10,9 % del total), siendo lo más común los estudios de la clasificación del estado fetal. En la mayoría de estudios se han desarrollado modelos, concretamente en un 64 % de los casos, siendo el resto: *DSS*, *e-Health system*, y aplicación móvil. Como fuente de datos, en 10 artículos (58,82 %) se ha empleado el mismo conjunto de datos: cardiocografías del repositorio *UCI Machine Learning Repository*. En

el resto de artículos, se han empleado, respectivamente: un conjunto de datos de la base de datos *Daisy* (electrocardiogramas fetales), un conjunto de datos de la base de datos del *Massachusetts Institute of Technology* (electrocardiogramas abdominales), un conjunto de datos de un hospital (cardiotocografías), equipo médico (ecografía), cuestionarios a pacientes y expertos, y un teléfono móvil con un sensor para adquirir electrocardiogramas del feto. Aunque *Machine Learning* es el enfoque que más se repite, en el 50 % se emplea también *Computational Intelligence*, siendo las redes neuronales artificiales y sus variaciones las utilizadas más frecuentemente.

La información desglosada por artículos se puede observar en la Tabla 5.5.

Tabla 5.5 Inteligencia artificial aplicada al estudio del estado fetal

Approach	Task	Algorithms	Final product	Functions	Ref
ML	Classification	Boosted DT, Bayes Point Machine, DT, DJ, Locally-Deep SVM, SVM, LR, NN, Averaged Perceptron	e-Health system	fetal state classification	[45]
ML	Classification	CART	Model	fetal state classification	[125]
ML, DSS	Classification	SVM, AdaBoost	DSS	fetal state classification	[66]
ML, CI	Classification	NN, Extreme ML	Model	fetal state classification	[126]
ML	Classification	SVM (Linear and RBFK), kNN, XGBoost, AdBoost, RF, LR, Gaussian NB, DT	Model	fetal state classification	[127]
ML	Classification	Modular NN	Model	fetal state classification	[128]
ML, DSS, CI	Classification, Dimens. reduction	SVM, BN, Extreme ML, kNN	DSS	fetal state classification	[71]

continuación

Tabla 5.5 – continuación

<b>Approach</b>	<b>Task</b>	<b>Algorithms</b>	<b>Final product</b>	<b>Functions</b>	<b>Ref</b>
ML, CI	Classification	Multilayer perceptron NN and softmax classification	Model	fetal state classification	[129]
ML, DSS, CI	Classification	SVM, ANN, Adaptive Neuro Fuzzy inference system	Model	fetal state classification	[130]
ML, CI	Classification	ANN, SVM, LR, RBFN, CART, C4.5 DT, RF, kNN	Model	fetal state classification	[131]
ML, KDD, CI	Classification, Clustering	ANN, SVM, Fuzzy C-means, K-means	Model	fetal state classification	[132]
AI	NS	Least Mean Square based Adaptive Noise Cancelling	Model	fetal state classification	[133]
ML, CI	Classification	Back-propagation NN, Adaptive Linear NN	Model	fetal state classification	[134]
ML	NS	SVM, DGP (supervised and unsupervised)	Model	fetal HR classification	[135]
ML, CI	NS	Fuzzy logic, NN	e-Health system	home pregnancy monitoring; fetal state classification	[30]
ML, NLP	Classification	DT, SVM, NB	Model	fetal state classification	[136]

continuación

Tabla 5.5 – continuación

Approach	Task	Algorithms	Final product	Functions	Ref
ML, DM	NS	NS	Mobile app	home pregnancy monitoring; fetal state classification	[137]

## Mortalidad

Se engloba en el término mortalidad tanto la mortalidad de la madre como la del feto y el recién nacido. Son un total de 10 estudios (15,6% del total) los que estudian la mortalidad, tratando la mayoría de ellos (9 de los 10) de su predicción. En todos ellos se emplea *Machine Learning* y en el 70% el producto presentado es un modelo, siendo el resto un *Framework*, un *e-Health system* y un protocolo de estudio. Los algoritmos más utilizados son: *Logistic Regression* y *Random Forest*. Los datos utilizados en estos estudios provienen en su gran mayoría de registros médicos y repositorios de bases de datos.

La información desglosada por artículos se puede encontrar en la Tabla 5.6.

Tabla 5.6 Inteligencia artificial aplicada al estudio de la mortalidad

Approach	Task	Algorithms	Final product	Functions	Ref
ML, DSS, DM, NLP	Classification	NS NLP	Framework	prediction of maternal/ prenatal/ infant mortality	[137]
ML	Classification	Regularized LR	Model	prediction of severe maternal morbidity	[138]
ML	Classification	LR, L1 Regularized LR	Model	prediction of severe maternal morbidity	[80]

continuación

Tabla 5.6 – continuación

Approach	Task	Algorithms	Final product	Functions	Ref
ML, DSS	Classification	ANN, SVM	Model	prediction of neonatal mortality	[139]
ML	Classification	RF, LDA, LR (L2 penalty), NB	Model	prediction of perinatal mortality	[73]
ML	Classification	kNN	Model	prediction of perinatal mortality	[140]
ML	Classification	BN, Spatial regression	Model	predict the determinants of stillbirth	[72]
ML	Clustering	NS	Study protocol	prediction of adverse perinatal outcomes	[141]
ML, DSS, DM	Classification	DT (IDE3, C4.5), RF, BN	e-Health system	prediction of neonatal mortality	[49]
ML	Classification	LR, RF	Model	classification of drugs safety	[74]

## Parto

El proceso del parto aparece como objeto de estudio en 5,12 % (8 del total) de los artículos de la revisión, tratándose en 3 artículos (37,5 %) de la predicción del tipo de parto (parto normal o cesárea). Otros 2 (25 %) estudian tareas relacionadas con la inducción del parto: predecir la necesidad de intervenir en este procedimiento o predecir la posibilidad de que conlleve riesgos para la embarazada. También en un artículo estudian y analizan por qué las mujeres que viven en la región de estudio prefieren parir en casa. Por último, en un artículo estudian la posibilidad de crear un sistema que ayude a profesionales de la salud (concretamente enfermeros/as), a la toma de decisiones al asistir a un parto. En su mayoría

(62,5 %) se proponen modelos de *Machine Learning*, pero también sistemas de apoyo a la toma de decisiones y simulaciones. Los datos utilizados en estos estudios provienen en gran medida de registros y equipos médicos (electrohisterogramas), y en otros tres casos, de expertos, de las redes sociales y de una encuesta.

La información desglosada por artículos se puede observar en la Tabla 5.7.

Tabla 5.7 Inteligencia artificial aplicada al estudio del parto

Approach	Task	Algorithms	Final product	Functions	Ref
ML, DSS, NLP, Big Data	Classification	NB, DT, NN (Multilayer perceptron), SVM, RF, Decsion Making Rules	DSS	prediction of labour induction failure	[70]
AI	NS	Mixed-effects Linear Regression	Simulation	labour and delivery decision assistance	[142]
ML, DM	Classification	C4.5, NB, SVM, Probabilistic NN, Multilayer perceptron	Model	analysis of reasons for home birth	[143]
ML	Clasification	SVM	Model	prediction of the need for labour induction	[144]
ML	Classification	NN, SVM, RF, CTree, RPART	Model	prediction of delivery type (c-section or not)	[145]
ML	Classification	LR, LDA, SVM, kNN, NB, NN, AdaBoost	Model	prediction of delivery type (c-section or not)	[146]

continuación

Tabla 5.7 – continuación

Approach	Task	Algorithms	Final product	Functions	Ref
DSS	NS	Timed Fuzzy Cognitive Map	DSS	prediction of delivery type (c-section or not)	[67]
ML, CI	Classification	J48 DT, NB, SVM, ANN	Model	prediction of seeking skilled delivery assistance	[147]

### Crecimiento fetal

Se han identificado 7,7% de estudios (12 del total de 156) que tratan el tema del crecimiento fetal. Los estudios de esta categoría presentan distintas funciones, entre las más comunes: predicción del peso fetal, predicción de pequeño/grande para la edad gestacional, medición del perímetro cefálico. Es interesante destacar que uno de los estudios buscan la relación existente entre la exposición a contaminación y peso bajo al nacer del feto. La gran mayoría de los estudios (91,6 %, 11) emplean técnicas de *Machine Learning*, principalmente tareas de clasificación, siendo los algoritmos más comunes: *Logistic Regression*, *Random Forest*, *Decision Tree*, *SuperLearner*. Los dos estudios cuya tarea es de regresión, se busca predecir el peso del feto al nacer (valor continuo), mientras que las tareas de clasificación, buscan predecir valores binarios (por ejemplo, pequeño/grande para la edad gestacional o no). El origen de los datos utilizados es variado. En 3 estudios (25 %) se emplean datos de la base de datos *Term-Preterm ElectroHysteroGram DataBase* del repositorio *Physionet*. Estos electrohisterogramas fueron recogidos entre los años 1997 y 2005 en el Centro médico de la Universidad de Liubliana. En otros dos artículos (16,67 %), los datos provenían de un estudio realizado en el National Free Preconception Health Examination Project, en China (2010-2012).

La información desglosada por artículos se puede observar en la Tabla 5.8.

Tabla 5.8 Inteligencia artificial aplicada al estudio del crecimiento fetal

<b>Approach</b>	<b>Task</b>	<b>Algorithms</b>	<b>Final product</b>	<b>Functions</b>	<b>Ref</b>
ML	Classification	SuperLearner	Model	prediction of birth outcome	[75]
ML	Regression	Linear and Quantile Regression, Bayesian additive regression trees, GBM, RF	Model	prediction of fetal weight	[148]
ML	Classification	LR, RF, DT, SVM with Linear and RBF kernel	Model	prediction of LGA	[149]
ML	Classification	Non-iterative ellipse fitting method; RF	Model	prediction of LGA	[150]
ML	NS	SuperLearner	Model	prediction of LGA/SGA	[151]
ML	Classification	Multiple LR, Elastic Net, DT, RF, ANN, Gradient Boosting	Model	prediction of fetal growth abnormalities	[152]
ML	Regression	SVR: Linear, Polynomial, RBF and Nu	Model	prediction of birth weight	[153]
DM, KDD, DSS	Classification	AdaBoost, DT, kNN, NB, RF, SVM	Model	prediction of LBW	[154]
ML	Classification	BN, XGBoost	Model	prediction of LBW	[155]
ML	Classification	LR, Ellipse fitting	Model	measurement of HC	[156]
ML	Classification	Multi-task DN based on Link-Net	Model	prediction of fetal HC	[157]

continuación



Tabla 5.8 – continuación

Approach	Task	Algorithms	Final product	Functions	Ref
ML	Classification	Targeted maximum likelihood estimation, D/S/A algorithm, LR	Model	relationship evaluation between pollutants exposure and LBW	[158]

### Salud mental

Del total de artículos, un 5,8 % (9 artículos) incorporan las emociones como parte del conjunto de datos y/o directamente están enfocados a la salud mental de la embarazada. Los dos temas más frecuentemente estudiados son la depresión (4 de 9 artículos), y el estrés y la preocupación (4 de 9 artículos) (89 %, 8 estudios), siendo el estudio restante de análisis de sentimientos acerca de las técnicas invasivas y no invasivas de diagnóstico prenatal. Incluso en esta categoría, los productos finales más frecuentes son los modelos (66,67 %), pero se pueden destacar dos estudios que desarrollan un *e-Health system* para monitorización del estrés y una aplicación móvil para intervención en la depresión perinatal. También es interesante mencionar que en dos de los estudios para la detección del estrés se han utilizado sensores de actividad, aunque en general la fuente de datos es variada: registros médicos, cuestionarios a pacientes, encuestas, etc. Por lo general, los algoritmos más utilizados son *Support Vector Machines*, *Logistic Regression* y variantes, *Decision Trees*, *Naive Bayes*, etc.

La información desglosada por artículos se puede observar en la Tabla 5.9.

Tabla 5.9 Inteligencia artificial aplicada al estudio de la salud mental

Approach	Task	Algorithms	Final product	Functions	Ref
ML, Big Data	Classification	DT, SVM, kNN, Ensemble	Model	prediction of postpartum depression	[159]

continuación

Tabla 5.9 – continuación

<b>Approach</b>	<b>Task</b>	<b>Algorithms</b>	<b>Final product</b>	<b>Functions</b>	<b>Ref</b>
ML	Classification	NB, J48 DT, SVM, LR, AdaBoost, Bagging	Model	prediction of postpartum depression	[160]
ML	Classification	L2-regularized LR, SVM, DT, NB, XGBoost, RF	Model	prediction of postpartum depression	[82]
AI	NS	Existing artificial intelligence (AI) system for automated psychological support	Mobile app	perinatal depression intervention	[53]
ML	Classification, Clustering	SVM with RBF, DT, AdaBoost, NB, NN	Framework	stress detection in pregnant women	[161]
ML	Classification	SVM, NB, kNN, DT	Model	prediction of labour complications and birth defects due to stress	[162]
ML	Classification, Clustering	K-Means, RF, NN	e-Health system	stress monitoring in pregnant women	[48]
ML	Classification	LR, Regularized Regression	Model	prediction of preeclampsia	[116]

continuación

Tabla 5.9 – continuación

Approach	Task	Algorithms	Final product	Functions	Ref
NLP	Classification	OpinionFinder; Natural Language Toolkit	Model	sentiment analysis on prenatal invasive / non-invasive tests	[163]

### Calidad de vida

En esta sección, las funciones de los estudios son más variadas, ya que no se estudia un proceso concreto, sino que está más enfocado desde el punto de vida de mejorar la calidad de vida de las embarazadas. En esta categoría se encuentran 18,6% de los estudios (29 de 156), siendo la más amplia de todas. Se pueden plantear las siguientes subcategorías con las funciones que aparecen al menos dos veces:

- Cuidado de la madre (*providing maternal care*) (37,9%, 11 de 29 estudios)
- Monitorización/ seguimiento de la salud (*health monitoring*) (27,6%, 8 de 29 estudios)
- Monitorización/ seguimiento del embarazo desde casa (*home pregnancy monitoring*) (17,2%, 5 de 29 estudios)
- Predicción de la edad gestacional (*prediction of GA*) (10,34%, 3 de 29 estudios)
- Análisis y asociación entre la contaminación y el embarazo (10,34%, 3 de 29 estudios)

En esta categoría es también donde existe una mayor variedad de productos finales. De los 29 artículos, en 12 se propone un modelo (41,38%), en 5 (17,24%) se proponen aplicaciones (móvil, de escritorio y/o web), siendo la función principal la asistencia y cuidado materno. Los sistemas de tipo *Chatbot* se propone en 2 de los 30 artículos (6,9%), también con la función de asistencia y cuidado materno y monitorización de la salud de la embarazada. Asimismo, con esta función también se presenta un sistema de soporte a la toma de decisiones y un sistema multiagente. En uno de los estudios se desarrolla un ecógrafo portátil.

También es la categoría con más subcampos distintos utilizados y con más *multidisciplinaridad* dentro de la IA.

La fuente de datos es muy variada. Desde redes sociales (Twitter), hasta registros médicos. 27,6% (8 de 29 estudios) utilizan datos provenientes de los registros médicos. Un 20,7%, (6 de 29 estudios) han empleado sensores (acelerómetros para registrar el movimiento del feto, temperatura y humedad ambiental, temperatura corporal, pulsímetros, etc.). Un 17,24% (5 de 29 estudios), han utilizado datos proporcionados por pacientes, cuestionarios y datos de encuestas.

La información desglosada por artículos se puede observar en la Tabla 5.10.

Tabla 5.10 Inteligencia artificial aplicada al estudio de la calidad de vida

<b>Approach</b>	<b>Task</b>	<b>Algorithms</b>	<b>Final product</b>	<b>Functions</b>	<b>Ref</b>
KRR	NS	NS	Ontology	analysis of indoor air pollution	[164]
ML, DSS	Classification	BN: GES and BDeu scoring function, Pairwise association rule mining	Model	reducing health care variability	[165]
ML	NS	DSA algorithm; Bayesian maximum entropy interpolation; Generalized estimating equations	Model	association between PM2,5 exposure and pregnancy outcomes	[166]
ML	Classification, Regression	RF	Model	association between PM2,5 exposure and pregnancy outcomes	[167]
ML	Classification	CNN (1D ResNet and BasicBlocks, 1D MgNet); SVM, LR	Model	pregnancy detection	[168]

continuación

Tabla 5.10 – continuación

<b>Approach</b>	<b>Task</b>	<b>Algorithms</b>	<b>Final product</b>	<b>Functions</b>	<b>Ref</b>
ML	Classification	Fuzzy ARTMAP	Model	home pregnancy monitoring; health resources allocation	[51]
ML, DSS	Classification	CART	DSS	prediction of risk in pregnancy	[68]
DSS, KRR	NS	NS	Ontology	risk pregnancy management	[84]
ML	Classification	C4.5 DT	Model	health monitoring	[169]
ML, DM	NS	Iteration Reduced Threshold based classifier	Wearable	monitoring gait	[50]
ML	Classification, Clustering	L1-regularized LR, K-means, RF, NN, AdaBoost, Gradient boosting, Supervised GMM	Model	subpopulation analysis, risk factor identification	[170]
AI	Clustering	Autoregressive model based on the LMS	Model	detection of fetal QRS complex	[171]
ML	Classification	CNN	Framework	prediction of GA	[172]
ML, CI	NS	Genetic Algorithm	Model	prediction of GA	[86]

continuación

Tabla 5.10 – continuación

<b>Approach</b>	<b>Task</b>	<b>Algorithms</b>	<b>Final product</b>	<b>Functions</b>	<b>Ref</b>
ML, Vision	Regression	NN	Web and mobile app	home pregnancy monitoring; providing maternal care	[56]
DSS	NS	Embedded algorithm	Desktop app	providing maternal care	[87]
ML, Big Data	Clustering	DT	Web and mobile app	providing maternal care	[55]
Expert System	NS	NS	Mobile app	providing antenatal care	[57]
ML, DM	Clasification	DT, SVM, kNN, LR, Zero Rule	web app	providing maternal care	[173]
ML, NLP, MAS, GAME	Reinforcement	NS	Chatbot	providing maternal care, health monitoring	[58]
NLP	NS	NS ML and DL algorithms	Chatbot	providing maternal care, health monitoring	[59]
DSS	NS	Rule-based algorithm	DSS	providing maternal care; healthy lifestyle promotion; prevention of female feticide	[69]
ML	NS	NS	Ultrasound scanning system	health monitoring	[174]

continuación

Tabla 5.10 – continuación

<b>Approach</b>	<b>Task</b>	<b>Algorithms</b>	<b>Final product</b>	<b>Functions</b>	<b>Ref</b>
ML, Big Data	Classification, Clustering, Dimens. Reduction	LR, NB, CART, SVM, NN, K-means, LDA, PCA	Exploratory protocol	evaluation of health programs	[175]
DSS	NS	NS	Qualitative study	providing maternal care	[176]
MAS, DSS	NS	NS	Multi-agent system	providing maternal care	[177]
KDD, DM, DSS	Clustering	k-means, Expectation-Maximization, FarthestFirst	Model	prediction of pregnancy complications	[178]
ML, NLP	Classification	Sequential Minimal Optimization, NB, SVM	Model	classification of drugs safety	[179]
NLP, DM, Expert System	NS	Self-developed heuristic algorithm	Model	identification of pregnancy timeframe	[180]

En esta Tabla 5.11 se ha reflejado para cada proceso asociado al embarazo, la fuente de los datos y el preprocesamiento que se les ha dado. El contenido de esta tabla ha sido utilizado en el estudio de los distintos procesos.

Tabla 5.11 Adquisición de datos y preprocesamiento según el proceso

<b>Process</b>	<b>Data acquisition</b>	<b>Preprocessing</b>	<b>Ref</b>
Anemia	Medical equipment: non-invasive multi-wavelength spectroscopic device	Signal preprocessing, Feature extraction	[181]

continuación

Tabla 5.11 – continuación

Process	Data acquisition	Preprocessing	Ref.
Anemia	Medical equipment: blood draws	NS	[182]
GDM	Medical records: healthcare provider; patient questionnaire; Health Institute: risk factors defined by the NIH	Missing values: inherently handled (Gradient boosting); Feature Attribution: framework of Shapley values	[107]
GDM	Medical records; patient questionnaire; Study: Early Life Plan	Statistical analysis, Odds ratio	[108]
GDM	Medical equipment	Feature selection	[109]
GDM	Health Institute: NIDDK	discarded missing data	[110]
GDM	Medical records	reduce noise, remove redundant features, deduplicate, complete missing data; Feature selection: stepwise regression analysis	[111]
GDM	Medical records	EHR and missing data processing, discretization and normalization	[113]
GDM	Medical records	Data normalization to comply with the Euclidean distance	[112]
GDM	Patient input: via web GUI; Sensor: glucose meter	NS	[60]
GDM	Mobile phone; Sensors: glycometer; Medical records	NS	[63]
GDM	Sensor: glucose; Wearable: FitBit activity tracker; Mobile phone: food diary (camera)	preprocessing and cleaning	[52]

continuación



Tabla 5.11 – continuación

<b>Process</b>	<b>Data acquisition</b>	<b>Preprocessing</b>	<b>Ref.</b>
GDM	Sensors: BAN (Glucose meter, sphygmomanometer)	NS	[62]
GDM	Synthetic data; Patient input	NS	[114]
GDM	Medical records; Medical literature	NS	[61]
Diabetes Mellitus	Survey; Medical records	NS	[183]
Blood glucose	Medical equipment: glucose meter	NS	[184]
HELLP syndrome	Medical records	NS	[185]
Pre-eclampsia	Medical records; patient questionnaire; sensors	NS	[64]
Pre-eclampsia	Medical records: Demographic and laboratory data	multiple imputation for missing data using fully conditional specification	[115]
Pre-eclampsia	Medical records; Sensor: BP	NS	[31]
Pre-eclampsia	Study: Stockholm-Gotland Obstetric Cohort	missing data: single-chained imputation with mean value	[81]
Pre-eclampsia and Stress / Worry	Study: Monitoring Mothers-to-Be (nuMoM2b)	NS	[116]
Pre-eclampsia	Medical equipment: Illumina's TruSeq small RNA sample preparation kit	Removal of erroneous samples, Feature selection	[117]
Pre-eclampsia	Medical records	NS	[85]
Pre-eclampsia	Study: Improving Health and Development Outcomes for Children	Missing data completion with the average value of the data	[118]
Pre-eclampsia, Hypertensive disorders	Survey: National Health and Nutrition Survey; Sensor: remote BP monitoring (bracelet)	NS	[47]

continuación

Tabla 5.11 – continuación

<b>Process</b>	<b>Data acquisition</b>	<b>Preprocessing</b>	<b>Ref.</b>
Pre-eclampsia, Hypertensive disorders	Medical records	NS	[119]
Hypertensive disorders	Medical records	NS	[120, 121, 78, 54]
Hypertensive disorders	Medical records; patient questionnaire	NS	[122]
Hypertensive disorders	Experts: proteinuria testing; Sensor: BP measurement	NS	[123]
Hypertensive disorders	Experts	NS	[124]
Hypertensive disorders	Data Repo; Medical records	NS	[65]
Depression	Medical records	NS	[159]
Depression	Survey	Under Sampling, Over Sampling, SMOTE, Soft Margin, FGB	[160]
Depression	Medical records	Feature selection: univariate LR	[82]
Depression	NS	NS	[53]
Stress	Sensors: BiostampRC, Polar H7, Neulog GSR; Patient questionnaire	data segmentation, normalization and cleaning, Feature selection: CfsSubsetEval	[161]
Stress	Patient questionnaire; Medical records	Rescale data algorithm	[162]
Stress	Sensor: Garmin vivosmart smart bands	data normalization	[48]
Emotions	Social media	NS	[163]
Birth defects	Medical records	statistical analysis	[99]

continuación

Tabla 5.11 – continuación

<b>Process</b>	<b>Data acquisition</b>	<b>Preprocessing</b>	<b>Ref.</b>
Birth defects	Health Institute: Fetal Medicine Foundation	data normalization and reduction, clustering: K-means algorithm	[98]
Birth defects	Medical records; Medical equipment: Ultrasound, blood samples	Each unknown case is assigned into a class between “euploid” and “aneuploid” using a cut-off value	[97]
Birth defects	Synthetic data	NS	[100]
Birth defect	Social media	manual process	[77]
Birth defects	Study: NICHD Successive Small-for-Gestational-Age Births study	NS	[103]
Birth defects	Medical records	missing or erroneous records were excluded	[104]
Birth defects	Health Institute: PM2.5 concentrations; Medical Records	missing data was excluded	[83]
Birth defects	Patient questionnaire; Data repo: US Environmental Protection Agency’s Air Quality System	missing data was excluded	[105]
Birth defects	Patient questionnaire: collected from hospital	Data cleaning, Removal of duplicates, discretization	[106]
Birth defects	Patient questionnaire, Health Institute	bootstrap resamples got extremely imbalanced data	[101]
Birth defects	Patient questionnaire, Health Institute	over-under sampling techniques	[79]
Birth defects	Medical records; Medical equipment: fetal heart images	NS	[102]
Birth defects, Mortality	Medical records; Data repo	NS	[74]

continuación

Tabla 5.11 – continuación

<b>Process</b>	<b>Data acquisition</b>	<b>Preprocessing</b>	<b>Ref.</b>
Fetal state	Data Repo: UCI ML CTG dataset	NS	[125, 128, 131]
Fetal state	Data Repo: UCI ML CTG dataset	statistical features extracted	[132]
Fetal state	Data Repo: UCI ML CTG dataset	Gaussian Radial basis functions; Feature selection: GA	[130]
Fetal state	Data Repo: UCI ML CTG dataset	SMOTE balancing technique	[127]
Fetal state	Data Repo: UCI ML CTG dataset	Dropout and regularization to combat overfitting	[129]
Fetal state	Data Repo: UCI ML CTG dataset	data labeled as noise, interferece or artifacts were removed	[126]
Fetal state	Data Repo: UCI ML CTG dataset	NS	[136]
Fetal state	Medical equipment: Doppler ultrasound	NS	[30]
Fetal state	Mobile phone; Sensor: fECG	NS	[137]
Fetal state	Data Repo: UCI ML CTG dataset	Feature selection: IAGA; Baseline: PCA	[71]
Fetal state	Data Repo: UCI ML CTG dataset	Feature selection: PCA based on Ranker search	[66]
Fetal state	Data Repo: fECG from Daisy database	Signal processing: EMG low pass filter, baseline wander high pass filter	[133]
Fetal state	Data Repo: aECG from MIT database	files are converted from .dat to .txt	[134]
Fetal state	Data Repo: CTG recordings from Brno Hospital	Feature selection: Principal component analysis	[135]
Fetal state	Patient questionnaire, Experts	Feature selection: Tree-based algorithm	[45]

continuación

Tabla 5.11 – continuación

<b>Process</b>	<b>Data acquisition</b>	<b>Preprocessing</b>	<b>Ref.</b>
Preterm birth	Data repo: EHG signals (TPEHG dataset in Physionet)	SMOTE, Signal filtering, Feature selection: root mean squares, peak frequency, median frequency, sample entropy	[90, 88]
Preterm birth	Study: Zambian Preterm Birth Prevention Study	NS	[91]
Preterm birth	Health Institute: NICHD	Varying Sample Size, Skewed Class Distributions	[92]
Preterm birth	Medical records	data undersampling, Feature selection	[76]
Preterm birth	Study: NFPHEP	Missing data: similarity-based heuristic algorithm; Feature selection: Linear Correlation, Normalized Mutual Information, DT (Information Gain and AUC)	[93]
Preterm birth	Patient questionnaire: demographic and health-related; Medical equipment: urine and plasma samples	SMOTE	[186]
Preterm birth	Study: NFPHEP	NS	[95]
Preterm birth	Data repo: EHG signals (TPEHG dataset in Physionet)	Feature selection: Hilbert-Huang Transform, Signal processing: bandpass using a six- order Butterworth digital filter, Manual process	[187]

continuación

Tabla 5.11 – continuación

Process	Data acquisition	Preprocessing	Ref.
Preterm birth	Data repo: EHG signals (TPEHG dataset in Physionet)	Signals discretized and Butterworth filter, SMOTE, Feature selection: IMF's Hilbert transformation	[94]
Preterm birth (on women diagnosed with pregnancy related disorders)	Medical records	NS	[96]
Preterm birth	Medical records	missing values imputation, normalization, Feature selection: Map-reduce	[89]
Preterm birth, Fetal growth	Medical records; Data repo: MODIS satellite data	NS	[75]
Fetal growth	Data repo: Magee-Womens Obstetric Maternal and Infant data	NS	[148]
Fetal growth	Medical equipment: ultrasound	manual process by experts (feature extraction), Feature selection: Haar-like	[150]
Fetal growth	Data Repo: LGA dataset from National Program	Feature Selection: GridSearch-based Recursive Feature Elimination with CV + IG and with CV + IG + Stacked generalization	[149]
Fetal growth	Patient questionnaire: PPAQ; Medical records	missing values replaced with the median of observed values; missing covariate data: missingness indicator method	[151]
Fetal growth	Medical records: ultrasounds	Data augmentation: image processing	[157]

continuación

Tabla 5.11 – continuación

<b>Process</b>	<b>Data acquisition</b>	<b>Preprocessing</b>	<b>Ref.</b>
Fetal growth	Data Repo: Nova Scotia Atlee Perinatal Database	missing data were excluded	[152]
Fetal growth	Health Institute: National Institute of Perinatology of Mexico; Experts: data collection	incomplete or poorly captured data were eliminated	[153]
Fetal growth	Medical records	missing data were excluded; Feature selection: Recursive feature elimination; Feature ranking: RF, XGBoost, verified with PCA. Normality of features: Chi square test, Covariance matrix	[155]
Fetal growth	Medical records	null values removed, normalization, Oversampling: duplicate all data instances	[154]
Fetal growth	Experts: manual extraction of data; Medical equipment: ultrasound	Samples normalization, Feature selection: Haar-like	[156]
Fetal growth	Medical records; Study: Air Pollution, Genetics and Early Life Events	missing data and not included clinical cases were excluded	[158]
Labour and delivery	Survey: conducted by the maternal neonatal and child health programme	data trimming: missing and irrelevant data were excluded	[143]
Labour and delivery	Medical records	dimensionality reduction and data cleaning	[146]

continuación

Tabla 5.11 – continuación

Process	Data acquisition	Preprocessing	Ref.
Labour and delivery	Survey	Unbalanced distribution: sampling weights, records with missing data excluded, Feature selection: Bivariate analysis and multivariable LR, SMOTE	[147]
Labour and delivery	Medical records	data conversion to CSV format	[145]
Labour and delivery	Medical equipment: EHG recordings using Ag/AgCl disposable electrodes	Manual segmentation of the EHC bursts; Signal processing: bandpass Butterworth filter and downsampling, Feature selection: Sequential Forward	[144]
Labour and delivery	Medical records	NS	[142]
Labour and delivery	Experts	NS	[67]
Labour and delivery	Medical records	data cleaning, filtering process: deletion of stopwords and a process of stemming, Feature selection: ReliefF, minimum Redundancy Maximum Relevance, Gain Ratio and IG, Correlation based FS	[70]
Miscarriage	Wearable: healthcare sensors (HR, TEMP, Activity); Mobile phone	Data mining algorithms	[46]
Termination	Survey: The Bangladesh Demographic and Health Survey (BDHS)	Feature Selection	[188]

continuación



Tabla 5.11 – continuación

<b>Process</b>	<b>Data acquisition</b>	<b>Preprocessing</b>	<b>Ref.</b>
Termination	Medical records: SAPE and AIDA using intelligent agents	uncomplete or noisy data were eliminated, oversampling	[189]
Hypotension	Experts: collection of epidural process data	NS	[190]
Multiple Sclerosis	Online forums	data filtering	[191]
HIV	Experts: Q&A	NS	[29]
Postpartum complication	Medical records	NS	[192]
Postpartum complication	Medical records	data normalization, missing values were excluded, Oversampling: additional dataset by duplicating all the instances from the initial dataset	[193]
Placental disorders	Medical equipment: ultrasound	Automatic (expert dot annotations), Confidence Maps	[194]
Placental disorders	Medical equipment: MRI clinical scanner	Normalization of intensities of all images + Discretization; Multiple univariate LR, Feature preprocessing: variace threshold, recursive feature elimination, PCA, Maximum absolute scaling, ANOVA	[195]
Systemic lupus erythematosus	Medical equipment: ultrasound	NS	[28]
Mortality	Data Repo: SIM (infant mortality) and SINASC (live birth data)	data is processed and aggregated	[137]

continuación

Tabla 5.11 – continuación

<b>Process</b>	<b>Data acquisition</b>	<b>Preprocessing</b>	<b>Ref.</b>
Mortality	Medical records	imbalanced data: randomly sample controls, Feature selection: Filter method	[138]
Mortality	Medical records	Imbalanced data: Control group was sub-sampled; Feature selection: ANOVA	[80]
Mortality	Medical records	Dimensionality reduction, Feature selection: computational (wrapper) methods and human input	[139]
Mortality	Medical records	mode imputation strategy for missing data	[73]
Mortality	Study	NS	[140]
Mortality	Data Repo: UN, UNDP, World Bank, WHO	NS	[72]
Mortality	Data Repo; Medical equipment; Synthetic data	Dimensionality Reduction	[141]
Mortality	Data Repo: SIM (infant mortality) and SINASC (live birth data)	NS	[49]
Quality of life	Sensor: TEMP, HUM, PM10/PM2.5, carbon monoxide	NS	[164]
Quality of life	Medical records	Feature selection	[165]
Quality of life	Medical records	records with missing covariate data were excluded	[166]
Quality of life	Data repo; Patient questionnaire; Sensors	Data cleaning, resamplinmg; multiple imputation mode for missing values	[167]

continuación

Tabla 5.11 – continuación

<b>Process</b>	<b>Data acquisition</b>	<b>Preprocessing</b>	<b>Ref.</b>
Quality of life	Medical records; Sensor: HK-2010/1 single channel pulse; Experts: data collection	filtering process	[168]
Quality of life	Sensor: Signal of fetal movement (accelerometer)	Sequential feature algorithms, Forward feature construction	[51]
Quality of life	Synthetic data; Experts: manual validation of data	NS	[68]
Quality of life	Experts: information regarding high risk pregnancy, antenatal care	NS	[84]
Quality of life	Experts; Medical records	validation and normalization. Standardization and Transformation with experts	[169]
Quality of life	Sensor: 14 electrodes fixed on the wearable coat	Feature selection: Segmented Pigeon Hole algorithm	[50]
Quality of life	Study: SPARCS	NS	[170]
Quality of life	Medical equipment	Signal processing: impulsive artifact and baseline wandering removal, power-line canceling; ICA	[171]
Quality of life	Synthetic data; Medical equipment: ultrasound; Data repo: fetal ultrasound	NS	[172]
Quality of life	Study: INTERGROWTH-21st	NS	[86]
Quality of life	Synthetic data	NS	[56]
Quality of life	Patient questionnaire; Survey	NS	[87]
Quality of life	Patient questionnaire	NS	[55]
Quality of life	Patient input	NS	[57]

continuación

Tabla 5.11 – continuación

Process	Data acquisition	Preprocessing	Ref.
Quality of life	Experts: Q&A	Bloom filters	[173]
Quality of life	Mobile phone	NS	[58, 59]
Quality of life	Medical records	NS	[69]
Quality of life	Medical equipment: ultrasound; Sensors: BP, PPG, Body TEMP, 3-lead ECG system	NS	[174]
Quality of life	Data repo; Health institute; Survey	data reduction, noise removal	[175]
Quality of life	Experts	NS	[176]
Quality of life	Medical records	NS	[177]
Quality of life	Medical records: gathered by a DSS focused on nursing practices	null or noisy data were removed, normalization	[178]
Quality of life	Data repo: National Library of Medicine	regular expressions, manual process	[179]
Quality of life	Social media	Tweets were tokenized using ARK Twokenizer	[180]

## 5.2. Discusión

### 5.2.1. Resumen de los resultados

El objetivo de esta revisión ha sido recopilar, estudiar y sintetizar la literatura científica (publicada desde el año 2008) que utiliza técnicas de computación (Inteligencia Artificial y sus subcampos) en la salud y bienestar de las embarazadas. Los aspectos que se han intentado destacar han sido los descriptores más utilizados en las publicaciones, los países de publicación, la funcionalidad y el producto final de los estudios, los factores sociales que aparecen en los estudios, los subcampos de de IA estudiados, el origen de los datos y su tratamiento, el tipo y la técnica del modelo, algoritmos, validación y test del modelo,

lenguajes de programación y frameworks empleados, seguridad TI y protección de datos personales.

Dentro de la IA, *Machine Learning* es la rama más empleada en el conjunto de los estudios revisados. No es una sorpresa que también en este ámbito se esté experimentando con las técnicas asociadas a esta rama, ya que en los últimos años se ha comenzado a aplicar en una gran variedad de ámbitos, tanto dentro como fuera de la salud. La mayoría de estudios que aplican esta rama de la IA ofrecen información acerca de la técnica o técnicas concretas utilizadas, junto con los algoritmos y su parametrización a cada caso, el preprocesamiento realizado a los datos, la validación y test del modelo, y las métricas que se utilizan para medir el rendimiento.

El desarrollo de *Decision Support System* se ha enfocado principalmente en la diabetes gestacional, pero también el parto, el estado fetal, la preeclampsia y trastornos hipertensivos y calidad de vida. Todos estos procesos requieren de monitorización constante ya que puede ser necesario actuar sobre ellos rápidamente con algún tipo de tratamiento o la modificación del mismo. En el caso de la diabetes, por ejemplo, se habla de la monitorización de la glucosa en sangre, los trastornos hipertensivos, la monitorización de la presión arterial. En ciertos casos puede ser necesario ajustar el tratamiento o la terapia, por lo que un sistema de soporte a la toma de decisiones es un desarrollo adecuado en este caso. Todos estos procesos, incluso el proceso del parto, suelen provocar muchas visitas al hospital. En algunos de los estudios revisados también se muestra interés y se estudia la utilidad que pueden tener estas aplicaciones para reducir el número de visitas al hospital y, en consecuencia, los costes asociados. En muchas ocasiones, estas visitas se pueden resolver a través de un sistema de este tipo, en el que un médico puede atender a la paciente de forma virtual, ya que recibe sus datos a través de la plataforma y puede indicar un tratamiento o cambio en el mismo. Otra lectura que merece tener el uso de sistemas de soporte a la toma de decisiones es que durante el proceso del parto, en ocasiones, los médicos deben decidir entre realizar una cesárea o no a una paciente. En este caso, puede ser interesante un sistema que aglutine toda la información necesaria para tomar esta decisión.

Hay que destacar que la mitad de los artículos han considerado algún factor de tipo social, ya sea económico, demográfico, étnico, etc. Los países de procedencia de autores en los que han tenido en cuenta este tipo de dato son, en orden decreciente: Estados Unidos, China, India, Portugal, Brasil, Pakistán, Inglaterra, Canadá, Israel, Sudáfrica, Arabia saudí, Australia, Rusia, Chipre, Italia, Holanda, España, Kenya, Corea del Sur, Mexico, Bangladesh, Francia, Oman, Etiopía, Colombia, Puerto Rico, Ecuador, Iran, Rumanía, Irlanda, Suecia, Zambia, Alemania, Tanzania y Bélgica. etc. Esto también se puede observar de forma gráfica en la Figura 5.2.

El hecho de incorporar información de este tipo no necesariamente implica que el estudio se haya realizado específicamente para un entorno en el que estos factores sean especialmente relevantes, pero a lo largo de la revisión se ha hecho notar el interés de la evidencia científica en cómo la IA podría ser empleada en países subdesarrollados donde los recursos sanitarios, tanto humanos como materiales, son limitados. Asimismo, el lugar de residencia, el nivel de educación, el estado civil, también han sido detalles importantes. Por ejemplo, el lugar de residencia de la embarazada llega a ser relevante ya que proporciona información acerca de los niveles de contaminación que puede haber en el del área residencial, el nivel de ingresos, la educación recibida o la dificultad de acceso a un centro médico. Aunque en todos los casos es enriquecedora una solución tecnológica que pueda asistir y ayudar a la embarazada, en estas situaciones se puede entender que lo es mucho más y el impacto y beneficio de su uso podría ser muy significativo tanto desde la perspectiva social como económica. Centrando el estudio en los artículos que han considerado factores sociales de cualquier tipo, llama la atención que un 78'87 % hayan desarrollado un modelo, ya que se podría esperar que un mayor número de desarrollos de productos que pudieran ser entregados y utilizados por las embarazadas. Se ve una diferencia notable también en el número de documentos que han solicitado y obtenido la aprobación de un comité ético. De aquellos estudios que han considerado factores sociales, un 45 % tienen la aprobación de un comité ético, mientras que los que no han considerado factores sociales, solo un 18,8 %. Esto se puede explicar porque en aquellos casos en los que se han incorporado factores sociales es cuando se ha podido trabajar con datos coleccionados (o siendo coleccionados por los mismos autores) de pacientes. En estos casos, el conjunto de datos es mucho más completo que si se utiliza la información de un repositorio de imágenes médicas (cardiotocografías, ecografías, etc.).

Se ha identificado que, principalmente, los estudios se enfocan en la salud física de la embarazada, siendo significativamente menor el volumen de aquellos que lo plantean desde la perspectiva de la salud mental. Aunque hay una temática muy variada en cuanto al proceso del embarazo abordado en cada estudio, el objetivo más recurrente de los mismos es la predicción, detección o clasificación de alguna afección, trastorno o estado, seguido por el cuidado y monitorización del estado de salud de la embarazada. Por tanto, la evidencia científica se concentra alrededor del desarrollo de modelos, sobre todo de *Machine Learning*, concretamente tareas de clasificación (aprendizaje supervisado) en muchas ocasiones sin una evaluación clínica posterior. Esto evidencia que el estado de madurez de la investigación está aún en etapas iniciales. Es necesario también considerar que los datos disponibles suelen ser datos etiquetados que ya marcan la pauta de la técnica de aprendizaje a emplear. En un gran número de casos, distintos estudios han utilizado los mismos conjuntos de datos con los mismos objetivos, variando las técnicas y metodologías para ello.

En muchos casos, la creación de un modelo es el primer paso que hay que dar antes de poder incorporarlo en una solución tecnológica que luego se pueda ofrecer a un usuario. Por tanto, aunque es de esperar que como resultado de la revisión se haya encontrado la existencia de muchos estudios que desarrollan modelos, también es interesante apuntar que la mayoría de ellos se quedan en dicha fase.

Son menos los estudios que plantean desarrollar una solución tecnológica (como pueden ser, un *wearable* o una aplicación móvil) que la embarazada pueda utilizar directamente, y son prácticamente anecdóticos los que utilizan como fuente de datos las emociones de la embarazada. En esta revisión, se ha evidenciado la ausencia de estudios que combinen estos dos aspectos (emociones y soluciones tecnológicas diseñadas para el uso directo por la paciente). Se ve por tanto que, aunque la investigación de IA está siendo estudiada y divulgada, no es tanto el caso aún de la Computación Afectiva.

La obtención y adquisición de datos es muy variada. En la mayoría de ocasiones se han utilizado datos que no se adquieren en tiempo real de la paciente, si no que han sido registrados previamente, como pueden ser los registros médicos, datos de otros estudios realizados, cuestionarios y encuestas, datos recolectados utilizando instrumental y equipamiento médicos, etc. Es interesante discutir acerca de las fuentes de los datos, ya que el planteamiento es distinto cuando se contempla una recolección de datos propia, a cuando se utilizan datos ya existentes y/o externos. Cuando en un estudio se utilizan datos externos (por ejemplo, de repositorios, registros médicos, de otros estudios, etc), se puede dar el caso de que los datos hayan sufrido pérdidas, contener errores, no tener una adecuada representatividad de los casos, o incluso no adecuarse al cien por cien a la pregunta que los investigadores necesitan resolver. Esto conlleva la necesidad de realizar un preprocesamiento de los datos, empleando distintas técnicas para mejorar la calidad de la información. Asimismo, puede tener un impacto negativo en los resultados del estudio. La adquisición de datos propios es interesante ya que permite a los investigadores trabajar con un conjunto personalizado, y por ende, más adecuado para la tarea que se está intentando llevar a cabo. Esto puede también tener un impacto positivo en los resultados de los algoritmos.

Es interesante también la relación que pueda existir entre la fuente de los datos empleados en el estudio y los sistemas finales propuestos. En el desarrollo de modelos, las fuentes de datos más comunes son los registros médicos, repositorios de bases de datos, equipos médicos, estudios, conocimiento y opiniones de expertos y encuestas. Se puede remarcar que en los estudios que han utilizado como fuente de datos sensores, *wearables* o teléfonos móviles (15 artículos), el 93'3% (14 de 15 artículos) han desarrollado un producto final distinto a un modelo: *wearables*, *e-Health system*, *decision support system*, *chatbots*, *framework*, aplicaciones móviles, ontologías y un ecógrafo portátil.

Prácticamente la gran mayoría de estudios han empleado algoritmos, independientemente de la técnica de IA utilizada. Es interesante destacar que más de la mitad de estos artículos han utilizado más de un algoritmo, lo que indica que en muchas ocasiones se realizan comparaciones de los resultados de los distintos algoritmos, para analizar cuál se ajusta mejor al objetivo propuesto. En algunos estudios utilizan modelos más avanzados, como pueden ser las redes neuronales, y los comparan contra otros algoritmos que llaman *baseline*. Dependiendo del artículo, algunos de los algoritmos considerados son *Logistic Regression*, *Support Vector Machines*, *Decision Trees*. Por lo general, hay algoritmos mucho más empleados que otros, como pueden ser: *Artificial Neural Networks*, *Logistic Regression*, *Support Vector Machines*, *Decision Trees*. No obstante, aunque otros algoritmos se hayan utilizado en menor medida, se ha observado un abanico realmente amplio de opciones.

Generalmente, los lenguajes de programación R, Python y MATLAB son los que se utilizan más en tareas asociadas al aprendizaje automático: clasificación, regresión, implementación de algoritmos, validación cruzada, etc. Además de ser los mejor preparados para estas tareas al incorporar ciertas estructuras de datos que pueden resultar muy interesantes (diccionarios y dataframes en Python, por ejemplo), también incorporan una gran variedad de paquetes, librerías y funciones especialmente elaboradas y dedicadas a este tipo de desarrollo. También se ha reportado el uso de otro tipo de plataformas para el aprendizaje automático y análisis estadístico, como son WEKA, STATA, SPSS y SAS.

Otro aspecto interesante que se ha considerado en esta revisión ha sido el de la seguridad de la información y la protección de datos personales. Al tratarse en muchos casos de registros médicos, cabe plantearse cómo se realiza el manejo de esta información. Aunque son más numerosos los estudios que especifican que los pacientes han tenido que firmar un consentimiento informado para formar parte del estudio, no son tantos los que mencionan haber realizado alguna implementación de seguridad TI, como puede ser el uso de firewall, certificados o el cifrado de datos.

En definitiva, como se ha presentado en este capítulo, son muchas las conclusiones y aprendizajes que se pueden obtener de esta revisión que, además de incluir un gran número de documentos, ha planteado una cantidad considerable de variables de estudio y ha contado con un equipo multidisciplinar para su desarrollo.

### 5.2.2. Limitaciones

No se ha llevado a cabo una evaluación de la calidad de los estudios incluidos en la revisión, lo que se puede interpretar como una limitación de la misma. No obstante, la evaluación de la calidad no es un paso obligatorio en la realización de revisiones sistemáticas exploratorias.



### 5.2.3. Conclusiones

Dada la cantidad de literatura científica publicada en la temática, se puede establecer que también en este campo de la medicina (Obstetricia y ginecología), como en muchos otros, existe un interés creciente en todas las oportunidades que puede ofrecer la IA. La investigación en IA aplicada a la salud ha resultado en descubrimientos muy interesantes en los últimos años, dando paso a una sinergia que puede llegar a beneficiar a muchísimas personas y siendo especialmente interesante el apoyo que puede ofrecer a aquellas que estén en situaciones desfavorecidas o de desigualdad. Sin embargo, no hay que perder de vista que este campo es muy novedoso y trae consigo muchas implicaciones éticas, sobre todo cuando se aplica a la salud.

Se espera que la investigación en este campo continúe con el desarrollo de soluciones novedosas.

## 5.3. Lista de acrónimos

aECG: Abdominal electrocardiogram  
Adaboost: Adaptive Boosting  
AIDA: Archive and Difussion of Medical Information  
AIRS: Artificial Immune Recognition System  
ANN: Artificial Neural Network  
AODE: Averaged one-dependence estimators  
BAN: Body area network  
BDEu: Bayesian Dirichlet equivalent uniform  
BN : Bayesian Network  
BP: Blood pressure  
CART: Classification and Regression Trees  
CI: Computational Intelligence  
CNN: Convolutional Neural Network  
CTG: Cardiotocography  
CV: Cross Validation  
DJ: Decision Jungle  
DL: Deep Learning  
DM : Data Mining  
DSA: Deletion/substitutionn addition algorithm

DSS : Decision Support System

DT: Decision Tree

EHR: Electronic health record

fECG: Fetal electrocardiogram

GA: Gestational Age

GB: Gradient Boosting

GBM: Gradient Boosting Machine

GDM: Gestational Diabetes Mellitus

GES: Greedy equivalence search

GMM: Gaussian Mixture Models

GUI: Graphic User Interface

HC: Head Circumference

HIV : Human immunodeficiency virus

HR: Heart Rate

HUM: Humidity

KDD: Knowledge Discovery in Databases

kNN: K nearest neighbour

KRR: Knowledge Representation and Reasoning

ICA: Independent Component Analysis

LBW: Low Birth Weight

LDA: Linear Discriminant Analysis

LGA: Large for gestational age

LMS: Learning Management System

LR: Logistic Regression

MARSplines: Multivariate Adaptive Regression Splines

MCMC: Markov chain Monte Carlo

ML: Machine Learning

MRI: Medical Resonance Imaging

MODIS: Moderate-resolution Imaging Spectroradiometer

NB: Naive Bayes

NFPHEP: National Free Preconception Health Examination Project

NICHD: National Institute of Child Health and Human Development

NIDDK: National Institute of Diabetes and Digestive and Kidney Diseases

NIH: National Institute of Health

NLP: Natural Language Processing NN: Neural Networks

NS: Not specified

---

PCA: Principal Component Analysis  
PM: Particulate matter  
PPAQ: Pregnancy Physical Activity Questionnaire  
PPG: Photoplethysmography  
PSO: Particle swarm optimization  
Q&A: Questions and answers;  
RBFN: Radial Basis Function Network  
RF : Random Forest  
SAPE: Nursing Practice Support Systems  
SGA: Small for gestational age  
SPARCS: Statewide Planning And Research Cooperative System  
SVM: Support Vector Machine  
TEMP: temperature  
TPEHG: The Term-Preterm Electrohysterography Database  
UN: United Nations  
UNDP: United Nations Development Programme  
WHO: World Health Organization



# Análisis temporal, económico, de viabilidad y aplicabilidad

En este capítulo se presenta, por un lado, un primer apartado con la planificación y cronología del TFM y, por otro, en apartados independientes, el análisis del trabajo realizado desde las perspectivas económica, de viabilidad y de aplicabilidad.

## 6.1. Análisis temporal

A continuación se presenta la planificación y cronología del TFM. En ella, se enumeran las tareas y subtareas realizadas y se ofrece una breve descripción de las mismas. La planificación y las tareas principales han estado marcadas por la estructura y etapas de la metodología [2] de *scoping review* aplicada en este caso. A continuación se describen cada una de ellas y se incluyen en la Figura 6.1 donde se puede observar el diagrama de Gantt de este trabajo.

**Tarea 1: Estudio previo:** en esta tarea se han llevado a cabo sobre todo distintas búsquedas y comprobaciones, y es todo lo que se ha realizado antes de comenzar con la revisión

- Estudio de la metodología de Scoping Review: se ha repasado la metodología y también anotaciones (lecciones aprendidas, dificultades, etc.) de una revisión anterior realizada por la alumna y tutora con otro equipo, en la que se había aplicado la misma metodología.
- Búsqueda en bases de datos (distintas *keywords*): Para volver a familiarizarse con las búsquedas en las bases de datos bibliográficas, se han llevado a cabo distintas búsquedas mezclando distintos descriptores. Esto ha servido sobre todo para comprender cómo realizar mejor (las *keywords* más utilizadas, las bases de datos con mejores buscadores, etc.) la búsqueda final.

- Búsqueda de Scoping Review en bases de datos: esta tarea se ha llevado a cabo para asegurarse de que no existiera ya una revisión parecida a la que se quería hacer.
- Establecimiento de las *keywords*: Una vez revisada las comprobaciones y las búsquedas pertinentes, se establecieron los descriptores con los que trabajar en la revisión.

### **Tarea 2: Búsquedas:**

- Establecimiento de los criterios de inclusión/exclusión: En este paso se han establecido los estudios que se incluirían en la revisión y los que no. Las bases de datos que se utilizarán, los descriptores, el periodo de estudio, etc.
- Búsqueda y descarga de estudios de las bases de datos: Con las búsquedas y los filtros ya establecidos, se ha realizado la búsqueda en cada base de datos de las seleccionadas.
- Eliminación de duplicados: Se han eliminado los duplicados que se pudiesen haber producido por utilizar como fuentes distintas bases de datos.
- Revisión inicial de estudios: Se ha consultado una parte de cada artículo para comprender mejor los resultados que se han obtenido, y para eliminar falsos positivos (artículos que aunque han aparecido en las búsquedas, no tratan del tema de interés)

### **Tarea 3: Revisión y selección de estudios:**

- Elaboración de documento de instrucciones para el equipo: se ha escrito un documento en el que se transmitía al equipo revisor cómo realizar la revisión: Qué artículos han de ser revisados por cada miembro (asignación del trabajo), los programas de gestión de referencias bibliográficas y modo de uso, las fechas de entrega, etc.
- Primera iteración de revisión en equipo: Cada miembro revisa el bloque asignado.
- Segunda iteración de revisión en equipo: Cada miembro revisa el bloque asignado. Durante este periodo, se han mantenido reuniones para asegurar que la revisión se realizaba con los mismos criterios por cada miembro del equipo.
- Elaboración de documento histórico (seguimiento) de artículos: Un documento Excel en el que cada artículo tiene una entrada y el histórico (las revisiones por las que ha pasado, los resultados de las revisiones, su inclusión o no, etc.)
- Estudio de los resultados de la primera revisión y elaboración de informe: Estudio de los resultados. Los acuerdos y desacuerdos del equipo, para determinar los siguientes pasos. El documento creado se compartió con el equipo. Se pusieron en común los

desacuerdos y por qué habían sucedido y se revisaron los criterios de inclusión/exclusión. Se realiza otro reparto de documentos para revisar.

- Segunda revisión en equipo: Los artículos en los que no se había llegado a un acuerdo o que resultaban dudosos, se han vuelto a revisar con los nuevos criterios aclarados.
- Estudio de los resultados de la segunda revisión y elaboración de informe: Se elabora otro documento con los porcentajes de acuerdos y desacuerdos y los documentos finalmente incluidos al finalizar la segunda revisión y estudiar sus resultados.

#### **Tarea 4: Elaboración de la plantilla de extracción:**

- Elaboración de la primera propuesta de plantilla de extracción: Se presenta un primer borrador de la plantilla de extracción.
- Prueba piloto de la primera propuesta de plantilla: Se pone a prueba la plantilla propuesta con un número reducido de artículos. Esto ayuda a identificar posibles planteamientos erróneos o inadecuados, así como la necesidad de incluir más u otro tipo de información.
- Propuesta final de la plantilla de extracción: Con los conocimientos adquiridos a lo largo de la prueba piloto, se elabora la propuesta final.

#### **Tarea 5: Extracción de la información:**

- Elaboración de documento de instrucciones para el equipo: se escribe un documento con información útil para la revisión: los artículos a revisar, explicación de la plantilla de extracción y normas de estilo, etc.
- Realizar la extracción en equipo: cada miembro revisa los artículos asignados completando su plantilla con la información extraída.
- Unificación de las plantillas completadas en un solo documento: para facilitar el estudio de la información extraída, se reúne toda la información en un único documento común.
- Unificación de las revisiones de cada miembro en una sola revisión: dado que cada artículo ha sido revisado por cuatro miembros (dos de cada área), se han de unificar las entradas en una sola, combinando y uniendo las extracciones.

#### **Tarea 6: Síntesis de la información:**

- Elaboración de tablas y gráficas: se ha creado material para mejorar la visualización de lo encontrado en la revisión.

■ Elaboración de la memoria.




Figura 6.1 Diagrama de Gantt del Trabajo Fin de Máster



## 6.2. Análisis económico

La duración de este trabajo ha comprendido los meses de diciembre a junio, inclusive. Según el Boletín Oficial de la Junta de Andalucía [196], el sueldo de un investigador doctor es de un máximo de 42.000€/anuales, y el de un investigador predoctoral, de 26.000€/anuales. Considerando que todos los miembros del equipo han realizado la revisión con una dedicación parcial, si calculamos el sueldo de cada investigador:

- Tres investigadores doctores contratados durante seis meses a tiempo parcial conlleva un coste de 31.500 €.
- Dos investigadores doctores contratados desde el mes de mayo a junio, inclusive (los dos miembros que se incorporaron a la revisión a posteriori): 14.000 €.
- Un investigador predoctoral contratado durante seis meses a tiempo parcial conlleva un coste de 6.500 €.

El coste total del trabajo realizado en la revisión asciende a 52.000 €.

## 6.3. Análisis de viabilidad

Uno de los grandes retos que presenta este tipo de revisiones es alcanzar un equilibrio entre su amplitud y su profundidad. Puede llegar a resultar inviable la revisión de todos los resultados provenientes de una búsqueda demasiado amplia, demasiado profunda, y por supuesto, cuando se dan ambas circunstancias. Es importante por tanto elegir una temática en la que se pueda obtener dicho equilibrio, siendo algunas veces necesario modificar la pregunta de investigación o reducir el periodo de estudio. Es, por tanto, necesario adaptar la revisión a los recursos disponibles: materiales, pero sobre todo, humanos y temporales.

## 6.4. Análisis de aplicabilidad

La metodología empleada en esta revisión se puede aplicar a cualquier otra pregunta de investigación en cualquier área de conocimiento. Resulta muy útil la aplicación de esta metodología para realizar una revisión rigurosa que no solamente sirve para familiarizarse con el tema en cuestión, sino que va mucho más allá, permitiendo identificar, con una enfoque científico, posibles nichos de investigación.

En el caso que nos ocupa de este TFM, la realización de esta revisión aporta al equipo multidisciplinar conocimientos muy interesantes a la hora de consolidar una colaboración con médicos del Hospital Virgen del Rocío.

# Conclusiones

En este Trabajo Fin de Máster se ha pretendido desarrollar paso a paso, de forma exhaustiva, la realización de una revisión sistemática exploratoria. Se han utilizado una gran cantidad de artículos provenientes de cinco bases de datos distintas, por lo que se puede entender que es una muestra representativa.

Las conclusión quizá más importante y relevante a la que se ha llegado en la revisión es que hay poca evidencia científica que emplee la Computación Afectiva aplicada a la salud y bienestar de las embarazadas, siendo, por ende, un campo de estudio poco explorado. Desde la publicación del libro de *Affective Computing* de Rosalind Picard [197] en el año 1997, este tema ha suscitado un interés creciente en la comunidad científica. Se ha demostrado que las emociones suponen una fuente de datos que puede aportar información valiosa e interesante en una solución tecnológica que pueda servir de apoyo, ayuda, empoderamiento, información, etc. Por tanto, el reconocimiento y la expresión de emociones por parte de las máquinas abre un camino de investigación apasionante.

Durante la elaboración de la revisión se ha adquirido un mayor conocimiento acerca de la literatura científica existente en la aplicación de la IA a la salud y bienestar de la embarazada, tanto desde el punto de vista médico como desde la lente de las tecnologías de la información. Una revisión de este tipo brinda la oportunidad de familiarizarse con el tema, lo que a su vez facilita la identificación de nichos de investigación.

En el camino recorrido durante el trabajo de presentación de los resultados de esta revisión se ha hecho uso de herramientas informáticas y de programación. Se desea destacar la importancia y utilidad del lenguaje de programación Python, que ha sido utilizado para la elaboración de gráficas y el análisis de la información. Las librerías de Python que se han utilizado han sido las siguientes: *dataframe*, *matplotlib*, *bibtexparser*, *numpy*.

Son muchas las lecciones aprendidas en este TFM. Algunas de las más destacables son las siguientes:

- Comprensión y puesta en práctica de distintas metodologías de revisión sistemática exploratoria (Objetivo 1).

- Se conocen las áreas de Inteligencia Artificial que se aplican al ámbito de la salud y bienestar de las embarazadas, así como otros muchos aspectos que han formado parte de esta revisión (Objetivo 2).
- La realización de una revisión metodológica en equipo con una gran cantidad de artículos requiere de una dedicación considerable de tiempo, una buena planificación y, sobre todo, una adecuada y planificada coordinación y comunicación de equipo.

## 7.1. Trabajo Futuro

En esta revisión se ha identificado un nicho de investigación que aun no se encuentra muy explorado: el uso de la computación afectiva aplicada a la salud y bienestar de las embarazadas. Son muchas las soluciones tecnológicas que incorporen las emociones las que se pueden proponer, con muchos fines que ya se han visto a lo largo de la revisión: apoyo a la mujer a lo largo del embarazo, monitorización de trastornos y/o enfermedades, intervenciones para la depresión, detección y control del estrés, etc. La incorporación de las emociones puede ofrecer un valor añadido importante y muy interesante a este ámbito de la salud.

El tercer objetivo de este TFM no se ha podido realizar, pero está previsto que sea parte de un trabajo de investigación que comenzará a realizarse a continuación de la finalización del máster, en el programa de doctorado de Ingeniería Informática en el que la autora de este TFM ya está matriculada.

# Bibliografía

- [1] M. J. Grant and A. Booth, “A typology of reviews: an analysis of 14 review types and associated methodologies,” *Health Information & Libraries Journal*, vol. 26, pp. 91–108, May 2009.
- [2] H. Arksey and L. O'Malley, “Scoping studies: towards a methodological framework,” *International Journal of Social Research Methodology*, vol. 8, pp. 19–32, Feb. 2005.
- [3] A. C. Tricco, E. Lillie, W. Zarin, K. K. O'Brien, H. Colquhoun, D. Levac, D. Moher, M. D. Peters, T. Horsley, L. Weeks, S. Hempel, E. A. Akl, C. Chang, J. McGowan, L. Stewart, L. Hartling, A. Aldcroft, M. G. Wilson, C. Garritty, S. Lewin, C. M. Godfrey, M. T. Macdonald, E. V. Langlois, K. Soares-Weiser, J. Moriarty, T. Clifford, O. Tunçalp, and S. E. Straus, “PRISMA Extension for Scoping Reviews (PRISMA-ScR): Checklist and Explanation,” *Annals of Internal Medicine*, vol. 169, pp. 467–473, 10 2018.
- [4] A. Kilic, “Artificial intelligence and machine learning in cardiovascular health care,” *The Annals of Thoracic Surgery*, vol. 109, pp. 1323–1329, May 2020.
- [5] J. L. Marcus, W. C. Sewell, L. B. Balzer, and D. S. Krakower, “Artificial intelligence and machine learning for HIV prevention: Emerging approaches to ending the epidemic,” *Current HIV/AIDS Reports*, vol. 17, pp. 171–179, Apr. 2020.
- [6] C. Su, Z. Xu, J. Pathak, and F. Wang, “Deep learning in mental health outcome research: a scoping review,” *Translational Psychiatry*, vol. 10, Apr. 2020.
- [7] F. Thabtah, D. Peebles, J. Retzler, and C. Hathurusingha, “A review of dementia screening tools based on mobile application,” *Health and Technology*, May 2020.
- [8] N. S. Tyler and P. G. Jacobs, “Artificial intelligence in decision support systems for type 1 diabetes,” *Sensors*, vol. 20, p. 3214, June 2020.
- [9] A. H. Sapci and H. A. Sapci, “Innovative assisted living tools, remote monitoring technologies, artificial intelligence-driven solutions, and robotic systems for aging societies: Systematic review,” *JMIR Aging*, vol. 2, p. e15429, Nov. 2019.
- [10] P. Schmidt, A. Reiss, R. Dürichen, and K. V. Laerhoven, “Wearable-based affect recognition—a review,” *Sensors*, vol. 19, p. 4079, Sept. 2019.
- [11] K. Grabowski, A. Rynkiewicz, A. Lassalle, S. Baron-Cohen, B. Schuller, N. Cummins, A. Baird, J. Podgórska-Bednarz, A. Pieniążek, and I. Łucka, “Emotional expression

- in psychiatric conditions: New technology for clinicians,” *Psychiatry and Clinical Neurosciences*, vol. 73, pp. 50–62, Dec. 2018.
- [12] L. Davidson and M. R. Boland, “Enabling pregnant women and their physicians to make informed medication decisions using artificial intelligence,” *Journal of Pharmacokinetics and Pharmacodynamics*, Apr. 2020.
- [13] J. Balayla and G. Shrem, “Use of artificial intelligence (AI) in the interpretation of intrapartum fetal heart rate (FHR) tracings: a systematic review and meta-analysis,” *Archives of Gynecology and Obstetrics*, vol. 300, pp. 7–14, May 2019.
- [14] N. Mays, E. Roberts, and J. Popay, *Studying the organisation and delivery of health services: Research methods*, ch. Synthesising research evidence. Routledge, 1 ed., 2001.
- [15] D. Levac, H. Colquhoun, and K. K. O’Brien, “Scoping studies: advancing the methodology,” *Implementation Science*, vol. 5, no. 1, p. 69, 2010.
- [16] H. M. Daudt, C. van Mossel, and S. J. Scott, “Enhancing the scoping study methodology: a large, inter-professional team’s experience with arksey and o’malley’s framework,” *BMC Medical Research Methodology*, vol. 13, no. 1, p. 48, 2013.
- [17] H. L. Colquhoun, D. Levac, K. K. O’Brien, S. Straus, A. C. Tricco, L. Perrier, M. Kastner, and D. Moher, “Scoping reviews: time for clarity in definition, methods, and reporting,” *Journal of Clinical Epidemiology*, vol. 67, pp. 1291–1294, Dec 2014.
- [18] M. D. J. Peters, C. M. Godfrey, H. Khalil, P. McInerney, D. Parker, and C. B. Soares, “Guidance for conducting systematic scoping reviews,” *International Journal of Evidence-Based Healthcare*, vol. 13, no. 3, 2015.
- [19] M. Peters, C. Godfrey, P. McInerney, Z. Munn, A. Tricco, and H. Khalil, *Joanna Briggs Institute Reviewers’ Manual*, ch. Chapter 11: Scoping Reviews (2020 version). The Joanna Briggs Institute, 4 ed., 2017.
- [20] A. C. Tricco, E. Lillie, W. Zarin, K. O’Brien, H. Colquhoun, M. Kastner, D. Levac, C. Ng, J. P. Sharpe, K. Wilson, M. Kenny, R. Warren, C. Wilson, H. T. Stelfox, and S. E. Straus, “A scoping review on the conduct and reporting of scoping reviews,” *BMC Medical Research Methodology*, vol. 16, no. 1, p. 15, 2016.
- [21] D. Moher, A. Liberati, J. Tetzlaff, and D. G. Altman, “Preferred reporting items for systematic reviews and meta-analyses: the prisma statement,” *BMJ*, vol. 339, 2009.
- [22] *PROSPERO. International prospective register of systematic reviews*. <https://www.crd.york.ac.uk/prospero/>. Accedido: 13 abril 2020.
- [23] *Open Science Framework*. <https://osf.io/>. Accedido: 13 abril 2020.
- [24] *Figshare*. <https://figshare.com/>. Accedido: 13 abril 2020.
- [25] F. Jiang, Y. Jiang, H. Zhi, Y. Dong, H. Li, S. Ma, Y. Wang, Q. Dong, H. Shen, and Y. Wang, “Artificial intelligence in healthcare: past, present and future,” *Stroke and Vascular Neurology*, vol. 2, pp. 230–243, June 2017.

- [26] E. J. Topol, “High-performance medicine: the convergence of human and artificial intelligence,” *Nature Medicine*, vol. 25, pp. 44–56, Jan. 2019.
- [27] B. Tran, G. Vu, G. Ha, Q.-H. Vuong, M.-T. Ho, T.-T. Vuong, V.-P. La, M.-T. Ho, K.-C. Nghiem, H. Nguyen, C. Latkin, W. Tam, N.-M. Cheung, H.-K. Nguyen, C. Ho, and R. Ho, “Global evolution of research in artificial intelligence in health and medicine: A bibliometric study,” *Journal of Clinical Medicine*, vol. 8, p. 360, Mar. 2019.
- [28] T. Yu, T.-H. Chiu, J. Van Den Wijngaard, T.-T. Hsieh, B. Weserhof, and E. Tseng, “Timing the delivery of preterm fetus: A case study based on computer simulation,” in *AAAI Fall Symposium - Technical Report*, vol. FS-09-03, pp. 131–139, 2009.
- [29] A. F. Jimenez Velez, J. M. Monguet Fierro, and L. Teran, “Geospatial collective intelligence for health planning: A case study for screening tests in the city of Esmeraldas, Ecuador,” in *2017 Fourth International Conference on eDemocracy & eGovernment (ICEDEG)*, pp. 167–172, IEEE, apr 2017.
- [30] A. Kazantsev, J. Ponomareva, and P. Kazantsev, “Development and validation of an AI-enabled mHealth technology for in-home pregnancy management,” in *Proceedings - 2014 International Conference on Information Science, Electronics and Electrical Engineering, ISEEE 2014*, vol. 2, pp. 927–931, 2014.
- [31] M. Velikova, P. J. Lucas, and M. Spaanderman, “A predictive Bayesian network model for home management of preeclampsia,” in *Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, vol. 6747 LNAI, pp. 179–183, 2011.
- [32] *Scopus, Elsevier*. <https://www.scopus.com/home.uri>. Accedido: 10 febrero 2020.
- [33] *Web of Science*. <http://apps.webofknowledge.com/>. Accedido: 10 febrero 2020.
- [34] *PubMed, US National Library of Medicine, National Institutes of Health*.
- [35] *IEEE Xplore, Institute of Electrical and Electronics Engineers*. <https://ieeexplore.ieee.org/>. Accedido: 10 febrero 2020.
- [36] *ACM Digital Library, Association for computing machinery*. <https://dl.acm.org>. Accedido: 10 febrero 2020.
- [37] *Institute of Electrical and Electronics Engineers*. <https://www.ieee.org/>. Accedido: 10 febrero 2020.
- [38] *BibTeX: a tool and a file format which are used to describe and process lists of references*. <http://www.bibtex.org/>. Accedido: 10 febrero 2020.
- [39] *MeSH (Medical Subject Headings): controlled vocabulary thesaurus used for indexing articles for PubMed*. <https://www.ncbi.nlm.nih.gov/mesh>. Accedido: 11 abril 2020.
- [40] *TeXMed - a BibTeX interface for PubMed*. <https://www.bioinformatics.org/texmed/>. Accedido: 10 febrero 2020.

- [41] *IEEE Xplore Digital Library. Resources and help. Command Search.* <https://ieeexplore.ieee.org/Xplorehelp/#!/searching-ieee-xplore/command-search#summary-of-data-fields>. Accedido: 10 febrero 2020.
- [42] *Digital Object Identifier System.* <https://www.doi.org/>. Accedido: 11 abril 2020.
- [43] *Mendeley, A free reference manager and an academic social network (versión 1.19.4).* <https://www.mendeley.com>. Accedido: 11 Abril 2020.
- [44] *European Conference on Artificial Intelligence.* <http://ecai2020.eu/call-for-papers/mainconference/>. Accedido: 27 Junio 2020.
- [45] A. Akbulut, E. Ertugrul, and V. Topcu, "Fetal health status prediction based on maternal clinical history using machine learning techniques," *Computer Methods and Programs in Biomedicine*, vol. 163, pp. 87–100, 2018.
- [46] H. Asri, H. Mousannif, and H. Al Moatassime, "Reality mining and predictive analytics for building smart applications," *Journal of Big Data*, vol. 6, no. 1, 2019.
- [47] I. Marin and N. Goga, "Hypertension detection based on machine learning," in *ACM International Conference Proceeding Series*, 2019.
- [48] O. Oti, I. Azimi, A. Anzanpour, A. M. Rahmani, A. Axelin, and P. Liljeberg, "IoT-Based Healthcare System for Real-Time Maternal Stress Monitoring," in *Proceedings of the 2018 IEEE/ACM International Conference on Connected Health: Applications, Systems and Engineering Technologies*, CHASE '18, (New York, NY, USA), pp. 57–62, Association for Computing Machinery, 2018.
- [49] R. Ramos, C. Silva, M. Moreira, J. Rodrigues, M. Oliveira, and O. Monteiro, "Using predictive classifiers to prevent infant mortality in the Brazilian northeast," in *2017 IEEE 19th International Conference on e-Health Networking, Applications and Services, Healthcom 2017*, vol. 2017-Decem, pp. 1–6, 2017.
- [50] A. Sheryl Oliver and N. Maheswari, "Identifying the gestures of toddler, pregnant woman and elderly using segmented pigeon hole feature extraction technique and IR-threshold classifier," *Indian Journal of Science and Technology*, vol. 9, no. 39, 2016.
- [51] X. Zhao, X. Zeng, L. Koehl, G. Tartare, and J. De Jonckheere, "A Wearable System for In-Home and Long-Term Assessment of Fetal Movement," *IRBM*, dec 2019.
- [52] D. Adams, H. Zheng, M. Sinclair, M. Murphy, and J. McCullough, "Integrated care for pregnant women with Type one diabetes using wearable technology," in *BIBE 2019; The Third International Conference on Biological Information and Biomedical Engineering*, pp. 1–5, 2019.
- [53] E. Green, N. Pearson, S. Rajasekharan, M. Rauws, A. Joerin, E. Kwobah, C. Musyimi, C. Bhat, R. Jones, and Y. Lai, "Expanding access to depression treatment in Kenya through automated psychological support: Protocol for a single-case experimental design pilot study," *Journal of Medical Internet Research*, vol. 21, no. 4, 2019.



- [54] M. Moreira, J. Rodrigues, A. Oliveira, K. Saleem, and A. Neto, "Performance evaluation of predictive classifiers for pregnancy care," in *2016 IEEE Global Communications Conference, GLOBECOM 2016 - Proceedings*, 2016.
- [55] G. Saranya, G. Geetha, and M. Safa, "E-Antenatal assistance care using decision tree analytics and cluster analytics based supervised machine learning," in *IEEE International Conference on IoT and its Applications, ICIOT 2017*, 2017.
- [56] Y. Santur, S. Santur, and M. Karaköse, "Architecture and implementation of a smart-pregnancy monitoring system using web-based application," *Expert Systems*, 2019.
- [57] S. Tumpa, A. Islam, and M. Ankon, "Smart care: An intelligent assistant for pregnant mothers," in *4th International Conference on Advances in Electrical Engineering, ICAEE 2017*, vol. 2018-Janua, pp. 754–759, 2017.
- [58] K. Mugoye, H. Okoyo, and S. McOyowo, "Smart-bot Technology: Conversational Agents Role in Maternal Healthcare Support," in *2019 IST-Africa Week Conference, IST-Africa 2019*, 2019.
- [59] L. Vaira, M. Bochicchio, M. Conte, F. Casaluci, and A. Melpignano, "Mama bot: A system based on ML and NLP for supporting women and families during pregnancy," in *ACM International Conference Proceeding Series*, pp. 273–277, 2018.
- [60] E. Caballero-Ruiz, G. García-Sáez, M. Rigla, M. Villaplana, B. Pons, and M. Hernando, "A web-based clinical decision support system for gestational diabetes: Automatic diet prescription and detection of insulin needs," *International Journal of Medical Informatics*, vol. 102, pp. 35–49, 2017.
- [61] E. Gomes Filho, P. Pinheiro, M. Pinheiro, L. Nunes, and L. Gomes, "Heterogeneous Methodology to Support the Early Diagnosis of Gestational Diabetes," *IEEE Access*, vol. 7, pp. 67190–67199, 2019.
- [62] M. Peleg, Y. Shahar, S. Quaglini, T. Broens, R. Budasu, N. Fung, A. Fux, G. García-Sáez, A. Goldstein, A. González-Ferrer, P. Soffer, and B. van Schooten, "Assessment of a personalized and distributed patient guidance system," *International Journal of Medical Informatics*, vol. 101, pp. 108–130, 2017.
- [63] M. Rigla, I. Martínez-Sarriegui, G. García-Sáez, B. Pons, and M. Hernando, "Gestational Diabetes Management Using Smart Mobile Telemedicine," *Journal of Diabetes Science and Technology*, vol. 12, no. 2, pp. 260–264, 2018.
- [64] M. Abubakar, A. Bibi, R. Hussain, Z. Bibi, A. Gul, Z. Bashir, S. N. Arshad, M. A. Uppal, and S. U. Chaudhary, "Towards Providing Full Spectrum Antenatal Health Care in Low and Middle Income Countries," in *Proceedings of the 9th International Joint Conference on Biomedical Engineering Systems and Technologies*, pp. 478–483, SCITEPRESS - Science and Technology Publications, 2016.
- [65] M. Moreira, J. Rodrigues, A. Sangaiah, J. Al-Muhtadi, and V. Korotaev, "Semantic interoperability and pattern classification for a service-oriented architecture in pregnancy care," *Future Generation Computer Systems*, vol. 89, pp. 137–147, 2018.

- [66] Y. Zhang and Z. Zhao, "Fetal state assessment based on cardiotocography parameters using PCA and AdaBoost," in *Proceedings - 2017 10th International Congress on Image and Signal Processing, BioMedical Engineering and Informatics, CISP-BMEI 2017*, vol. 2018-Janua, pp. 1–6, 2018.
- [67] E. Bourgani, C. D. Stylios, G. Manis, and V. C. Georgopoulos, "Timed Fuzzy Cognitive Maps for Supporting Obstetricians' Decisions," in *IFMBE Proceedings*, vol. 45, pp. 753–756, 2015.
- [68] A. Gorthi, C. Firtion, and J. Vepa, "Automated risk assessment tool for pregnancy care," in *2009 Annual International Conference of the IEEE Engineering in Medicine and Biology Society*, vol. 560045, pp. 6222–6225, IEEE, sep 2009.
- [69] C. Mukherjee, K. Gupta, and R. Nallusamy, "A system to provide primary maternity healthcare services in developing countries," in *Annual SRII Global Conference, SRII*, pp. 243–249, 2012.
- [70] C. Pruenza, M. Teulon, L. Lechuga, J. Diaz, and A. Gonzalez, "Development of a Predictive Model for Induction Success of Labour," *INTERNATIONAL JOURNAL OF INTERACTIVE MULTIMEDIA AND ARTIFICIAL INTELLIGENCE*, vol. 4, pp. 21–28, mar 2018.
- [71] S. Ravindran, A. Jambek, H. Muthusamy, and S.-C. Neoh, "A novel clinical decision support system using improved adaptive genetic algorithm for the assessment of fetal well-being," *Computational and Mathematical Methods in Medicine*, vol. 2015, 2015.
- [72] D. A. Adeyinka, B. O. Olakunde, and N. Muhajarine, "Evidence of health inequity in child survival: spatial and Bayesian network analyses of stillbirth rates in 194 countries," *Scientific Reports*, vol. 9, p. 19755, dec 2019.
- [73] I. Pan, L. B. Nolan, R. R. Brown, R. Khan, P. van der Boor, D. G. Harris, and R. Ghani, "Machine Learning for Social Services: A Study of Prenatal Case Management in Illinois.," *American journal of public health*, vol. 107, pp. 938–944, jun 2017.
- [74] M. Boland, F. Polubriaginof, and N. Tatonetti, "Development of A Machine Learning Algorithm to Classify Drugs of Unknown Fetal Effect," *Scientific Reports*, vol. 7, no. 1, 2017.
- [75] J. Casey, P. James, K. Rudolph, C.-D. Wu, and B. Schwartz, "Greenness and birth outcomes in a range of Pennsylvania communities," *International Journal of Environmental Research and Public Health*, vol. 13, no. 3, 2016.
- [76] C. Gao, S. Osmundson, D. Velez Edwards, G. Jackson, B. Malin, and Y. Chen, "Deep learning predicts extreme preterm birth from electronic health records," *Journal of Biomedical Informatics*, vol. 100, 2019.
- [77] A. Klein, A. Sarker, H. Cai, D. Weissenbacher, and G. Gonzalez-Hernandez, "Social media mining for birth defects research: A rule-based, bootstrapping approach to collecting data for rare health-related events on Twitter," *Journal of Biomedical Informatics*, vol. 87, pp. 68–78, 2018.

- [78] M. Moreira, J. Rodrigues, V. Furtado, C. Mavromoustakis, N. Kumar, and I. Woungang, "Fetal Birth Weight Estimation in High-Risk Pregnancies Through Machine Learning Techniques," in *IEEE International Conference on Communications*, vol. 2019-May, 2019.
- [79] Z. Ren, J. Zhu, Y. Gao, Q. Yin, M. Hu, L. Dai, C. Deng, L. Yi, K. Deng, Y. Wang, X. Li, and J. Wang, "Maternal exposure to ambient PM10 during pregnancy increases the risk of congenital heart defects: Evidence from machine learning models," *Science of the Total Environment*, vol. 630, pp. 1–10, 2018.
- [80] E. Rodríguez, F. Estrada, W. Torres, and J. Santos, *Early prediction of severe maternal morbidity using machine learning techniques*, vol. 10022 LNAI. 2016.
- [81] A. Sandström, J. Snowden, J. Höijer, M. Bottai, and A.-K. Wikström, "Clinical risk assessment in early pregnancy for preeclampsia in nulliparous women: A population based cohort study," *PLoS ONE*, vol. 14, no. 11, 2019.
- [82] S. Wang, J. Pathak, and Y. Zhang, *Using electronic health records and machine learning to predict postpartum depression*, vol. 264. 2019.
- [83] S. Chen, S. Wang, T. Li, H. Zhu, S. Liang, K. Xu, Y. Zhang, X. Yuan, Y. Yang, H. Pan, H. Pan, and X. Shi, "Effect of PM2.5 on macrosomia in China: A nationwide prospective cohort study," *Pediatric Obesity*, vol. 15, 2020.
- [84] J. Lam, Y. Noor, and E. Supriyanto, "Ontology driven knowledge base for high risk pregnancy management," in *Proceedings - 2015 4th International Conference on Instrumentation, Communications, Information Technology and Biomedical Engineering, ICICI-BME 2015*, 2015.
- [85] I. Marin and N. Goga, "Nutrition consultant based on machine learning for preeclampsia complications," *SCIENTIFIC PAPERS-SERIES D-ANIMAL SCIENCE*, vol. 62, no. 2, pp. 82–87, 2019.
- [86] A. T. Papageorghiou, B. Kemp, W. Stones, E. O. Ohuma, S. H. Kennedy, M. Purwar, L. J. Salomon, D. G. Altman, J. A. Noble, E. Bertino, M. G. Gravett, R. Pang, L. Cheikh Ismail, F. C. Barros, A. Lambert, Y. A. Jaffer, C. G. Victora, Z. A. Bhutta, and J. Villar, "Ultrasound-based gestational-age estimation in late pregnancy," *Ultrasound in Obstetrics & Gynecology*, vol. 48, pp. 719–726, dec 2016.
- [87] F. Sukums, N. Mensah, R. Mpembeni, S. Massawe, E. Duysburgh, A. Williams, J. Kaltschmidt, S. Loukanova, W. Haefeli, and A. Blank, "Promising adoption of an electronic clinical decision support system for antenatal and intrapartum care in rural primary healthcare facilities in sub-Saharan Africa: The QUALMAT experience," *International Journal of Medical Informatics*, vol. 84, no. 9, pp. 647–657, 2014.
- [88] I. Idowu, P. Fergus, A. Hussain, C. Dobbins, M. Khalaf, R. Eslava, and R. Keight, "Artificial intelligence for detecting preterm uterine activity in gynecology and obstetric care," in *Proceedings - 15th IEEE International Conference on Computer and Information Technology, CIT 2015, 14th IEEE International Conference on Ubiquitous Computing and Communications, IUCC 2015, 13th IEEE International Conference on Dependable, Autonomic and Se*, pp. 215–220, 2015.

- [89] T. Khatibi, N. Kheyrikoochaksarayee, and M. Sepehri, "Analysis of big data for prediction of provider-initiated preterm birth and spontaneous premature deliveries and ranking the predictive features," *Archives of Gynecology and Obstetrics*, vol. 300, no. 6, pp. 1565–1582, 2019.
- [90] P. Fergus, P. Cheung, A. Hussain, D. Al-Jumeily, C. Dobbins, and S. Iram, "Prediction of Preterm Deliveries from EHG Signals Using Machine Learning," *PLoS ONE*, vol. 8, no. 10, 2013.
- [91] K. Rittenhouse, B. Vwalika, A. Keil, J. Winston, M. Stoner, J. Price, M. Kapasa, M. Mubambe, V. Banda, W. Muunga, W. Muunga, and J. Stringer, "Improving preterm newborn identification in low-resource settings with machine learning," *PLoS ONE*, vol. 14, no. 2, 2019.
- [92] I. Vovsha, A. Rajan, A. Salieb-Aouissi, A. Raja, A. Radeva, H. Diab, A. Tomar, and R. Wapner, "Predicting preterm birth is not elusive: Machine learning paves the way to individual wellness," in *AAAI Spring Symposium - Technical Report*, vol. SS-14-01, pp. 82–89, 2014.
- [93] S. Dong, Z. Feric, X. Li, S. M. Rahman, G. Li, C. Wu, A. Z. Gu, J. Dy, D. Kaeli, J. Meeker, I. Y. Padilla, J. Cordero, C. V. Vega, Z. Rosario, and A. Alshawabkeh, "A hybrid approach to identifying key factors in environmental health studies," in *2018 IEEE International Conference on Big Data (Big Data)*, IEEE, Dec. 2018.
- [94] D. Despotovic, A. Zec, K. Mladenovic, N. Radin, and T. Turukalo, "A Machine Learning Approach for an Early Prediction of Preterm Delivery," in *SISY 2018 - IEEE 16th International Symposium on Intelligent Systems and Informatics, Proceedings*, pp. 265–270, 2018.
- [95] Q. Li, Y.-Y. Wang, Y. Guo, H. Zhou, X. Wang, Q. Wang, H. Shen, Y. Zhang, D. Yan, Y. Zhang, H.-J. Wang, and X. Ma, "Effect of airborne particulate matter of 2.5 MM or less on preterm birth: A national birth cohort study in China," *Environment International*, pp. 1128–1136, 2018.
- [96] M. Moreira, J. Rodrigues, G. Marcondes, A. Neto, N. Kumar, and I. Diez, "A Preterm Birth Risk Prediction System for Mobile Health Applications Based on the Support Vector Machine Algorithm," in *IEEE International Conference on Communications*, 2018.
- [97] A. Neocleous, C. Neocleous, N. Petkov, K. Nicolaides, and C. Schizas, "Prenatal diagnosis of aneuploidy using artificial neural networks in relation to health economics," in *IFMBE Proceedings*, vol. 57, pp. 930–934, 2016.
- [98] A. Neocleous, K. Nicolaides, and C. Schizas, "Intelligent Noninvasive Diagnosis of Aneuploidy: Raw Values and Highly Imbalanced Dataset," *IEEE Journal of Biomedical and Health Informatics*, vol. 21, no. 5, pp. 1271–1279, 2017.
- [99] A. C. Neocleous, K. H. Nicolaides, and C. N. Schizas, "First Trimester Noninvasive Prenatal Diagnosis: A Computational Intelligence Approach.," *IEEE journal of biomedical and health informatics*, vol. 20, pp. 1427–1438, sep 2016.

- [100] H. Teder, P. Paluoja, K. Rekker, A. Salumets, K. Krjutskov, and P. Palta, “Computational framework for targeted high-coverage sequencing based NIPT,” *PloS one*, vol. 14, no. 7, p. e0209139, 2019.
- [101] Y. Luo, Z. Li, H. Guo, H. Cao, C. Song, X. Guo, and Y. Zhang, “Predicting congenital heart defects: A comparison of three data mining methods,” *PloS one*, vol. 12, no. 5, p. e0177811, 2017.
- [102] L. Yeo and R. Romero, “Fetal Intelligent Navigation Echocardiography (FINE): a novel method for rapid, simple, and automatic examination of the fetal heart,” *Ultrasound in Obstetrics & Gynecology*, vol. 42, pp. 268–284, sep 2013.
- [103] S. Kim and P. S. Albert, “A class of joint models for multivariate longitudinal measurements and a binary event,” *Biometrics*, vol. 72, pp. 917–925, sep 2016.
- [104] D. Shigemi, S. Yamaguchi, S. Aso, and H. Yasunaga, “Predictive model for macrosomia using maternal parameters without sonography information,” *The journal of maternal-fetal & neonatal medicine : the official journal of the European Association of Perinatal Medicine, the Federation of Asia and Oceania Perinatal Societies, the International Society of Perinatal Obstetricians*, vol. 32, pp. 3859–3863, nov 2019.
- [105] K. Weber, W. Yang, S. Carmichael, A. Padula, and G. Shaw, “A machine learning approach to investigate potential risk factors for gastroschisis in California,” *Birth Defects Research*, vol. 111, no. 4, pp. 212–221, 2019.
- [106] F. Choudhry, U. Qamar, and M. Chaudhry, “Rule based inference engine to forecast the prevalence of congenital malformations in live births,” in *2015 IEEE/ACIS 16th International Conference on Software Engineering, Artificial Intelligence, Networking and Parallel/Distributed Computing (SNPD)*, pp. 1–7, IEEE, jun 2015.
- [107] N. S. Artzi, S. Shilo, E. Hadar, H. Rossman, S. Barbash-Hazan, A. Ben-Haroush, R. D. Balicer, B. Feldman, A. Wiznitzer, and E. Segal, “Prediction of gestational diabetes based on nationwide electronic health records,” 2020.
- [108] T. Zheng, W. Ye, X. Wang, X. Li, J. Zhang, J. Little, L. Zhou, and L. Zhang, “A simple model to predict risk of gestational diabetes mellitus from 8 to 20 weeks of gestation in Chinese women,” *BMC pregnancy and childbirth*, vol. 19, p. 252, jul 2019.
- [109] L. Yoffe, A. Polsky, A. Gilam, C. Raff, F. Mecacci, A. Ognibene, F. Crispi, E. Gratacós, H. Kanety, S. Mazaki-Tovi, N. Shomron, and M. Hod, “Early diagnosis of gestational diabetes mellitus using circulating microRNAs,” *European Journal of Endocrinology*, vol. 181, pp. 565–577, nov 2019.
- [110] M. Moreira, J. Rodrigues, N. Kumar, J. Al-Muhtadi, and V. Korotaev, “Evolutionary radial basis function network for gestational diabetes data analytics,” *Journal of Computational Science*, vol. 27, pp. 410–417, 2018.
- [111] H. F. Du, Fan, Zhong Weiyang, Wu Wei, Peng Danhong, Xu Tian, Wang Jun, Wang Gongdao, “Prediction of pregnancy diabetes based on machine learning,” *BIBE*, no. JUNE -20-22, pp. 142–147, 2019.

- [112] H.-C. Lin, C.-T. Su, and P.-C. Wang, “An application of artificial immune recognition system for prediction of diabetes following gestational diabetes,” *Journal of Medical Systems*, vol. 35, no. 3, pp. 283–289, 2011.
- [113] H. Qiu, H.-Y. Yu, L.-Y. Wang, Q. Yao, S.-N. Wu, C. Yin, B. Fu, X.-J. Zhu, Y.-L. Zhang, Y. Xing, H. Yang, and S.-D. Lei, “Electronic Health Record Driven Prediction for Gestational Diabetes Mellitus in Early Pregnancy,” *Scientific Reports*, vol. 7, no. 1, 2017.
- [114] R. Schumann, S. Bromuri, J. Krampf, and M. I. Schumacher, “Agent Based Monitoring of Gestational Diabetes Mellitus (Demonstration),” in *Proceedings of the 11th International Conference on Autonomous Agents and Multiagent Systems - Volume 3, AAMAS ’12*, (Richland, SC), pp. 1487–1488, International Foundation for Autonomous Agents and Multiagent Systems, 2012.
- [115] J. H. Jhee, S. Lee, Y. Park, S. E. Lee, Y. A. Kim, S.-W. Kang, J.-Y. Kwon, and J. T. Park, “Prediction model development of late-onset preeclampsia using machine learning-based methods,” *PloS one*, vol. 14, no. 8, p. e0221202, 2019.
- [116] T. Krishnamurti, A. Davis, and H. Simhan, “Worrying yourself sick? Association between pre-eclampsia onset and health-related worry in pregnancy,” *Pregnancy Hypertension*, vol. 18, pp. 55–57, 2019.
- [117] L. Yoffe, A. Gilam, O. Yaron, A. Polsky, L. Farberov, A. Syngelaki, K. Nicolaides, M. Hod, and N. Shomron, “Early Detection of Preeclampsia Using Circulating Small non-coding RNA,” *Scientific Reports*, vol. 8, no. 1, pp. 1–11, 2018.
- [118] A. Martínez-Velasco, L. Martínez-Villaseñor, and L. Miralles-Pechuán, “Machine Learning Approach for Pre-Eclampsia Risk Factors Association,” in *Proceedings of the 4th EAI International Conference on Smart Objects and Technologies for Social Good - Goodtechs ’18*, Goodtechs ’18, (New York, New York, USA), pp. 232–237, ACM Press, 2018.
- [119] M. Moreira, J. Rodrigues, F. Carvalho, N. Chilamkurti, J. Al-Muhtadi, and V. Denisov, “Biomedical data analytics in mobile-health environments for high-risk pregnancy outcome prediction,” *Journal of Ambient Intelligence and Humanized Computing*, vol. 10, no. 10, pp. 4121–4134, 2019.
- [120] M. Moreira, J. Rodrigues, V. Furtado, N. Kumar, and V. Korotaev, “Averaged one-dependence estimators on edge devices for smart pregnancy data analysis,” *Computers and Electrical Engineering*, vol. 77, pp. 435–444, 2019.
- [121] M. Moreira, J. Rodrigues, N. Kumar, J. Al-Muhtadi, and V. Korotaev, “Nature-Inspired Algorithm for Training Multilayer Perceptron Networks in e-health Environments for High-Risk Pregnancy Care,” *Journal of Medical Systems*, vol. 42, no. 3, 2018.
- [122] E. Tejera, M. Jose Areias, A. Rodrigues, A. Rama, J. Manuel Nieto-Villar, and I. Rebelo, “Artificial neural network for normal, hypertensive, and preeclamptic pregnancy classification using maternal heart rate variability indexes,” *Journal of Maternal-Fetal and Neonatal Medicine*, vol. 24, no. 9, pp. 1147–1151, 2011.

- [123] M. Moreira, J. Rodrigues, A. Oliveira, and K. Saleem, "Smart mobile system for pregnancy care using body sensors," in *2016 International Conference on Selected Topics in Mobile and Wireless Networking, MoWNeT 2016*, 2016.
- [124] M. Moreira, J. Rodrigues, N. Kumar, J. Niu, and I. Woungang, "Performance Assessment of Decision Tree-Based Predictive Classifiers for Risk Pregnancy Care," in *2017 IEEE Global Communications Conference, GLOBECOM 2017 - Proceedings*, vol. 2018-Janua, pp. 1–5, 2017.
- [125] A. Akbulut, E. Ertugrul, and V. Topcu, "Fetal Health State Monitoring Using Decision Tree Classifier from Cardiotocography Measurements," in *IEEE International Conference on Communications*, 2018.
- [126] Z. Comert, A. F. Kocamaz, and S. Gungor, "Cardiotocography signals with artificial neural network and extreme learning machine," in *2016 24th Signal Processing and Communication Application Conference (SIU)*, pp. 1493–1496, IEEE, may 2016.
- [127] Z. Hoodbhoy, M. Noman, A. Shafique, A. Nasim, D. Chowdhury, and B. Hasan, "Use of Machine Learning Algorithms for Prediction of Fetal Risk using Cardiotocographic Data.," *International journal of applied & basic medical research*, vol. 9, no. 4, pp. 226–230, 2019.
- [128] S. Jadhav, S. Nalbalwar, and A. Ghatol, "Modular neural network model based foetal state classification," in *2011 IEEE International Conference on Bioinformatics and Biomedicine Workshops, BIBMW 2011*, pp. 915–917, 2011.
- [129] J. Miao and K. Miao, "Cardiotocographic diagnosis of fetal health based on multiclass morphologic pattern predictions using deep learning classification," *International Journal of Advanced Computer Science and Applications*, vol. 9, no. 5, pp. 1–11, 2018.
- [130] H. Ocak, "A medical decision support system based on support vector machines and the genetic algorithm for the evaluation of fetal well-being," *Journal of Medical Systems*, vol. 37, no. 2, 2013.
- [131] H. Sahin and A. Subasi, "Classification of the cardiotocogram data for anticipation of fetal risks using machine learning techniques," *Applied Soft Computing Journal*, vol. 33, pp. 231–238, 2015.
- [132] C. Sundar, M. Chitradevi, and G. Geetharamani, "Incapable of identifying suspicious records in CTG data using ANN based machine learning techniques," *Journal of Scientific and Industrial Research*, vol. 73, no. 8, pp. 510–516, 2014.
- [133] R. Hameed and N. Țăpuș, "Healthcare monitoring system for fetal electrocardiogram using least mean square based adaptive noise canceling approach," in *Proceedings of the 8th International Conference on Electronics, Computers and Artificial Intelligence, ECAI 2016*, 2017.
- [134] M. A. Hasan and M. Mamun, "BPNN based MECG elimination from the abdominal signal to extract fetal signal for continuous fetal monitoring," *Acta Scientiarum. Technology*, vol. 35, pp. 195–203, apr 2013.

- [135] G. Feng, J. Gerald Quirk, and P. Djuric, "Supervised and Unsupervised Learning of Fetal Heart Rate Tracings with Deep Gaussian Processes," in *2018 14th Symposium on Neural Networks and Applications, NEUREL 2018*, 2018.
- [136] K. Agrawal and H. Mohan, "Cardiotocography Analysis for Fetal State Classification Using Machine Learning Algorithms," in *2019 International Conference on Computer Communication and Informatics (ICCCI)*, pp. 1–6, IEEE, jan 2019.
- [137] J. Andrade, A. Duarte, and A. Arsénio, "Social Web for Large-Scale Biosensors," *International Journal of Web Portals*, vol. 4, pp. 1–19, jul 2012.
- [138] C. Gao, S. Osmundson, X. Yan, D. Edwards, B. Malin, and Y. Chen, *Learning to identify severe maternal morbidity from electronic health records*, vol. 264. 2019.
- [139] F. Cerqueira, T. Ferreira, A. de Paiva Oliveira, D. Augusto, E. Krempser, H. Corrêa Barbosa, S. do Carmo Castro Franceschini, B. de Freitas, A. Gomes, and R. Siqueira-Batista, "NICEsim: An open-source simulator based on machine learning techniques to support medical research on prenatal and perinatal care decision making," *Artificial Intelligence in Medicine*, vol. 62, no. 3, pp. 193–201, 2014.
- [140] H. Qureshi, M. Khan, S. Quadri, and R. Hafiz, "Association of pre-pregnancy weight and weight gain with perinatal mortality," in *Proceedings of the 8th International Conference on Frontiers of Information Technology, FIT'10*, 2010.
- [141] Z. Hoodbhoy, B. Hasan, F. Jehan, B. Bijmens, and D. Chowdhury, "Machine learning from fetal flow waveforms to predict adverse perinatal outcomes: a study protocol," *Gates Open Research*, vol. 2, p. 8, feb 2018.
- [142] R. L. Molina, M. Gombolay, J. Jonas, A. M. Modest, J. Shah, T. H. Golen, and N. T. Shah, "Association Between Labor and Delivery Unit Census and Delays in Patient Management: Findings From a Computer Simulation Module," *Obstetrics and gynecology*, vol. 131, pp. 545–552, mar 2018.
- [143] F. Jawad, T. Choudhury, A. Najeeb, M. Faisal, F. Nusrat, R. Shamita, and R. Rahman, "Data mining techniques to analyze the reason for home birth in Bangladesh," in *2015 IEEE/ACIS 16th International Conference on Software Engineering, Artificial Intelligence, Networking and Parallel/Distributed Computing, SNPD 2015 - Proceedings*, 2015.
- [144] J. Alberola-Rubio, J. Garcia-Casado, G. Prats-Boluda, Y. Ye-Lin, D. Desantes, J. Valero, and A. Perales, "Prediction of labor onset type: Spontaneous vs induced; role of electrohysterography?," *Computer Methods and Programs in Biomedicine*, vol. 144, pp. 127–133, 2017.
- [145] S. Hussain, R. Riaz, T. Fatima, S. Rizvi, F. Riaz, and S. Kwon, "A comparative study of supervised machine learning techniques for diagnosing mode of delivery in medical sciences," *International Journal of Advanced Computer Science and Applications*, vol. 10, no. 12, pp. 120–125, 2019.
- [146] S. Abbas, R. Riaz, S. Kazmi, S. Rizvi, and S. Kwon, "Cause analysis of caesarian sections and application of machine learning methods for classification of birth data," *IEEE Access*, vol. 6, pp. 67555–67561, 2018.



- [147] B. Tesfaye, S. Atique, T. Azim, and M. Kebede, “Predicting skilled delivery service use in Ethiopia: Dual application of logistic regression and machine learning algorithms,” *BMC Medical Informatics and Decision Making*, vol. 19, no. 1, 2019.
- [148] A. Naimi, R. Platt, and J. Larkin, “Machine Learning for Fetal Growth Prediction,” *Epidemiology*, vol. 29, no. 2, pp. 290–298, 2018.
- [149] F. Akhtar, J. Li, Y. Pei, A. Imran, A. Rajput, M. Azeem, and Q. Wang, “Diagnosis and prediction of Large-for-Gestational-Age fetus using the stacked generalization method,” *Applied Sciences (Switzerland)*, vol. 9, no. 20, 2019.
- [150] T. L. van den Heuvel, H. Petros, S. Santini, C. L. de Korte, and B. van Ginneken, “Automated Fetal Head Detection and Circumference Estimation from Free-Hand Ultrasound Sweeps Using Deep Learning in Resource-Limited Countries,” *Ultrasound in Medicine & Biology*, vol. 45, pp. 773–785, mar 2019.
- [151] S. F. Ehrlich, R. S. Neugebauer, J. Feng, M. M. Hedderson, and A. Ferrara, “Exercise During the First Trimester and Infant Size at Birth: Targeted Maximum Likelihood Estimation of the Causal Risk Difference,” *American Journal of Epidemiology*, vol. 189, pp. 133–145, feb 2020.
- [152] S. Kuhle, B. Maguire, H. Zhang, D. Hamilton, A. C. Allen, K. S. Joseph, and V. M. Allen, “Comparison of logistic regression with machine learning methods for the prediction of fetal growth abnormalities: a retrospective cohort study,” *BMC Pregnancy and Childbirth*, vol. 18, p. 333, dec 2018.
- [153] O. Campos Trujillo, J. Perez-Gonzalez, and V. Medina-Bañuelos, “Early Prediction of Weight at Birth Using Support Vector Regression,” in *IFMBE Proceedings*, vol. 75, pp. 37–41, 2020.
- [154] P. Loreto, H. Peixoto, A. Abelha, and J. Machado, *Predicting low birth weight babies through data mining*, vol. 932. 2019.
- [155] A. Yarlapati, S. Roy Dey, and S. Saha, “Early Prediction of LBW Cases via Minimum Error Rate Classifier: A Statistical Machine Learning Approach,” in *2017 IEEE International Conference on Smart Computing, SMARTCOMP 2017*, 2017.
- [156] J. Li, Y. Wang, B. Lei, J.-Z. Cheng, J. Qin, T. Wang, S. Li, and D. Ni, “Automatic Fetal Head Circumference Measurement in Ultrasound Using Random Forest and Fast Ellipse Fitting,” *IEEE journal of biomedical and health informatics*, vol. 22, pp. 215–223, jan 2018.
- [157] Z. Sobhaninia, S. Rafiei, A. Emami, N. Karimi, K. Najarian, S. Samavi, and S. M. Reza Soroushmehr, “Fetal Ultrasound Image Segmentation for Measuring Biometric Parameters Using Multi-Task Deep Learning,” in *2019 41st Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*, pp. 6545–6548, 2019.
- [158] A. Padula, K. Mortimer, A. Hubbard, F. Lurmann, M. Jerrett, and I. Tager, “Exposure to traffic-related air pollution during pregnancy and term low birth weight: Estimation of causal associations in a semiparametric model,” *American Journal of Epidemiology*, vol. 176, no. 9, pp. 815–824, 2012.

- [159] M. Moreira, J. Rodrigues, N. Kumar, K. Saleem, and I. Illin, "Postpartum depression prediction through pregnancy data analysis for emotion-aware smart systems," *Information Fusion*, vol. 47, pp. 23–31, 2019.
- [160] S. Natarajan, A. Prabhakar, N. Ramanan, A. Bagilone, K. Siek, and K. Connelly, "Boosting for Postpartum Depression Prediction," in *Proceedings - 2017 IEEE 2nd International Conference on Connected Health: Applications, Systems and Engineering Technologies, CHASE 2017*, pp. 232–240, 2017.
- [161] Z. D. King, J. Moskowitz, B. Egilmez, S. Zhang, L. Zhang, M. Bass, J. Rogers, R. Ghaffari, L. Wakschlag, and N. Alshurafa, "Micro-Stress EMA: A Passive Sensing Framework for Detecting in-the-Wild Stress in Pregnant Mothers," *Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies*, vol. 3, pp. 1–22, sep 2019.
- [162] V. Madhusri, G. Kesavkrishna, D. Marimuthu, and R. Sathyanarayanan, "Performance Comparison of Machine Learning Algorithms to Predict Labor Complications and Birth Defects Based on Stress," in *2019 IEEE 10th International Conference on Awareness Science and Technology, iCAST 2019 - Proceedings*, 2019.
- [163] G. Delnevo, S. Mirri, L. Monti, C. Prandi, M. Putra, M. Roccetti, P. Salomoni, and R. J. Sokol, "Patients Reactions to Non-Invasive and Invasive Prenatal Tests: A Machine-Based Analysis from Reddit Posts," in *Proceedings of the 2018 IEEE/ACM International Conference on Advances in Social Networks Analysis and Mining, ASONAM '18*, pp. 980–987, IEEE Press, 2018.
- [164] J. A. Adeleke and D. Moodley, "An Ontology for Proactive Indoor Environmental Quality Monitoring and Control," in *Proceedings of the 2015 Annual Research Conference on South African Institute of Computer Scientists and Information Technologists - SAICSIT '15*, SAICSIT '15, (New York, New York, USA), pp. 1–10, ACM Press, 2015.
- [165] J. Klann, P. Szolovits, S. Downs, and G. Schadow, "Decision support from local data: Creating adaptive order menus from past clinician behavior," *Journal of Biomedical Informatics*, vol. 48, pp. 84–93, 2014.
- [166] D. M. Stieb, L. Chen, B. S. Beckerman, M. Jerrett, D. L. Crouse, D. W. R. Omariba, P. A. Peters, A. van Donkelaar, R. V. Martin, R. T. Burnett, N. L. Gilbert, M. Tjepkema, S. Liu, and R. M. Dugandzic, "Associations of Pregnancy Outcomes and PM 2.5 in a National Canadian Study," *Environmental Health Perspectives*, vol. 124, pp. 243–249, feb 2016.
- [167] Q. Zhu, B. Xia, Y. Zhao, H. Dai, Y. Zhou, Y. Wang, Q. Yang, Y. Zhao, P. Wang, X. La, H. Shi, Y. Liu, and Y. Zhang, "Predicting gestational personal exposure to PM2.5 from satellite-driven ambient concentrations in Shanghai.," *Chemosphere*, vol. 233, pp. 452–461, oct 2019.
- [168] J. Chen, H. Huang, W. Hao, and J. Xu, "A machine learning method correlating pulse pressure wave data with pregnancy," *International Journal for Numerical Methods in Biomedical Engineering*, vol. 36, no. 1, 2020.

- [169] B. N. Lakshmi, "Prediction Based Health Monitoring in Pregnant Women," pp. 594–598, 2015.
- [170] X. Shou, G. Mavroudeas, A. New, K. Arhin, J. N. Kuruzovich, M. Magdon-Ismael, and K. P. Bennett, "Supervised Mixture Models for Population Health," in *2019 IEEE International Conference on Bioinformatics and Biomedicine (BIBM)*, pp. 1057–1064, nov 2019.
- [171] M. Varanini, G. Tartarisco, L. Billeci, A. Macerata, G. Pioggia, and R. Balocchi, "An efficient unsupervised fetal QRS complex detection from abdominal maternal ECG," *Physiological Measurement*, vol. 35, no. 8, pp. 1607–1619, 2014.
- [172] M. A. Maraci, M. Yaqub, R. Craik, S. Beriwal, A. Self, P. von Dadelszen, A. Pappageorgiou, and J. A. Noble, "Toward point-of-care ultrasound estimation of fetal gestational age from the trans-cerebellar diameter using CNN-based ultrasound image analysis," *Journal of Medical Imaging*, vol. 7, p. 1, jan 2020.
- [173] T. Satish Kumar, Vishwakiran, and P. Devaiah, "Health adviser: Social question and answer system using datamining," *International Journal of Recent Technology and Engineering*, vol. 8, no. 2, pp. 4294–4297, 2019.
- [174] R. K. Megalingam, G. Pocklassery, V. Jayakrishnan, and G. Mourya, "PULSS: Portable ultrasound scanning system," in *c2013 IEEE Global Humanitarian Technology Conference: South Asia Satellite, GHTC-SAS 2013*, pp. 119–123, 2013.
- [175] D. Mohan, J. Bashingwa, P. Dane, S. Chamberlain, N. Tiffin, and A. Lefevre, "Use of big data and machine learning methods in the monitoring and evaluation of digital health programs in India: An exploratory protocol," *Journal of Medical Internet Research*, vol. 21, no. 5, 2019.
- [176] S. Zakane, L. Gustafsson, G. Tomson, S. Loukanova, A. Sié, J. Nasiell, and P. Bastholm-Rahmner, "Guidelines for maternal and neonatal "point of care": Needs of and attitudes towards a computerized clinical decision support system in rural Burkina Faso," *International Journal of Medical Informatics*, vol. 83, no. 6, pp. 459–469, 2014.
- [177] I. Nunes, R. Choren, C. Nunes, B. Fábri, F. Silva, G. Carvalho, and C. J. P. de Lucena, "Supporting Prenatal Care in the Public Healthcare System in a Newly Industrialized Country," in *Proceedings of the 9th International Conference on Autonomous Agents and Multiagent Systems: Industry Track, AAMAS '10*, pp. 1723–1730, International Foundation for Autonomous Agents and Multiagent Systems, 2010.
- [178] S. Pereira, F. Portela, M. F. Santos, J. Machado, and A. Abelha, "Clustering-based Approach for Categorizing Pregnant Women in Obstetrics and Maternity Care," in *Proceedings of the Eighth International C\* Conference on Computer Science & Software Engineering - C3S2E '15*, C3S2E '15, (New York, New York, USA), pp. 98–101, ACM Press, 2008.
- [179] L. M. Rodriguez and D. D. Fushman, "Automatic Classification of Structured Product Labels for Pregnancy Risk Drug Categories, a Machine Learning Approach.," *AMIA ... Annual Symposium proceedings. AMIA Symposium*, vol. 2015, pp. 1093–102, 2015.

- [180] M. Rouhizadeh, A. Magge, A. Klein, A. Sarker, and G. Gonzalez, “A Rule-Based Approach to Determining Pregnancy Timeframe from Contextual Social Media Postings,” in *Proceedings of the 2018 International Conference on Digital Health*, DH '18, (New York, NY, USA), pp. 16–20, Association for Computing Machinery, 2018.
- [181] S. Acharya, D. Swaminathan, S. Das, K. Kansara, S. Chakraborty, D. Kumar, T. Francis, and K. R. Aatre, “Non-Invasive Estimation of Hemoglobin Using a Multi-Model Stacking Regressor,” *IEEE Journal of Biomedical and Health Informatics*, pp. 1–1, nov 2019.
- [182] O. Gerget, D. Devyatykh, and M. Shcherbakov, *Data-driven approach for modeling of control action impact on anemia dynamics based on energy-informational health state criteria*, vol. 754. 2017.
- [183] D. Krishnan, G. Menakath, A. Radhakrishnan, Y. Himavarshini, A. Aparna, K. Mukundan, R. Pathinarupothi, B. Alangot, S. Mahankali, and C. Maddipati, “Evaluation of predisposing factors of Diabetes Mellitus post Gestational Diabetes Mellitus using Machine Learning Techniques,” in *2019 IEEE Student Conference on Research and Development, SCORed 2019*, pp. 81–85, 2019.
- [184] M. Mahunnah and K. Taveter, “A scalable multi-agent architecture in environments with limited connectivity: Case study on individualised care for healthy pregnancy,” *IEEE International Conference on Digital Ecosystems and Technologies*, no. October 2014, pp. 84–89, 2013.
- [185] M. Moreira, J. Rodrigues, J. Al-Muhtadi, V. Korotaev, and V. de Albuquerque, “Neuro-fuzzy model for HELLP syndrome prediction in mobile cloud computing environments,” *Concurrency Computation*, 2018.
- [186] M. T. Aung, Y. Yu, K. K. Ferguson, D. E. Cantonwine, L. Zeng, T. F. McElrath, S. Pennathur, B. Mukherjee, and J. D. Meeker, “Prediction and associations of preterm birth and its subtypes with eicosanoid enzymatic pathways and inflammatory markers.,” *Scientific reports*, vol. 9, p. 17049, nov 2019.
- [187] L. Chen and Y. Hao, “Feature Extraction and Classification of EHG between Pregnancy and Labour Group Using Hilbert-Huang Transform and Extreme Learning Machine,” *Computational and Mathematical Methods in Medicine*, vol. 2017, 2017.
- [188] F. Ahmed, M. M. B. Shams, P. C. Shill, and M. Rahman, “Classification on BDHS data analysis: Hybrid approach for predicting pregnancy termination,” in *2019 International Conference on Electrical, Computer and Communication Engineering (ECCE)*, pp. 1–6, IEEE, feb 2019.
- [189] A. Brandão, E. Pereira, F. Portela, M. Santos, A. Abelha, and J. Machado, “Predicting the risk associated to pregnancy using Data Mining,” in *ICAART 2015 - 7th International Conference on Agents and Artificial Intelligence, Proceedings*, vol. 2, pp. 594–601, 2015.
- [190] E. K. Lee, H. Tian, J. Lee, X. Wie, J. J. Neeld, K. D. Smith, and A. R. Kaplan, “Investigating a Needle-Based Epidural Procedure in Obstetric Anesthesia.,” *AMIA ... Annual Symposium proceedings. AMIA Symposium*, vol. 2018, pp. 720–729, 2018.

- [191] B. Rezaallah, D. J. Lewis, C. Pierce, H.-F. Zeilhofer, and B.-I. Berg, “Social Media Surveillance of Multiple Sclerosis Medications Used During Pregnancy and Breast-feeding: Content Analysis,” *Journal of Medical Internet Research*, vol. 21, p. e13003, aug 2019.
- [192] K. Betts, S. Kisely, and R. Alati, “Predicting common maternal postpartum complications: leveraging health administrative data and machine learning,” *BJOG: An International Journal of Obstetrics and Gynaecology*, vol. 126, no. 6, pp. 702–709, 2019.
- [193] A. Morais, H. Peixoto, C. Coimbra, A. Abelha, and J. Machado, “Predicting the need of Neonatal Resuscitation using Data Mining,” in *Procedia Computer Science*, vol. 113, pp. 571–576, 2017.
- [194] H. Qi, S. Collins, and J. A. Noble, “Automatic Lacunae Localization in Placental Ultrasound Images via Layer Aggregation,” in *Medical image computing and computer-assisted intervention : MICCAI ... International Conference on Medical Image Computing and Computer-Assisted Intervention*, vol. 11071, pp. 921–929, sep 2018.
- [195] H. Sun, H. Qu, L. Chen, W. Wang, Y. Liao, L. Zou, Z. Zhou, X. Wang, and S. Zhou, “Identification of suspicious invasive placentation based on clinical MRI data using textural features and automated machine learning,” *European radiology*, vol. 29, pp. 6152–6162, nov 2019.
- [196] “Boletín oficial de la junta de andalucía.” (<https://www.juntadeandalucia.es/boja/2020/119/5?item=0>). Accedido el 03/07/2020.
- [197] R. W. Picard, *Affective Computing*. Cambridge, MA, USA: MIT Press, 1997.



# Anexo A

## A.1. Python Script 1

Script que ha empleado para unificar los seis documentos Excel en un solo documento. Se ha utilizado la librería pandas.

```
# -*- coding: utf-8 -*-  
import pandas as pd  
  
rev1 = 'DataChart_SR_Plantilla_Extracci n_REV1.xlsx'  
rev2 = 'DataChart_SR_Plantilla_Extracci n_REV2.xlsx'  
rev3 = 'DataChart_SR_Plantilla_Extracci n_REV3.xlsx'  
rev4 = 'DataChart_SR_Plantilla_Extraccio n_REV4.xlsx'  
rev5 = 'DataChart_SR_Plantilla_Extracci n_REV5.xlsx'  
rev6 = 'DataChart_SR_Plantilla_Extraccio n_REV6.xlsx'  
  
general = range(6, 16)  
general_medical = range(6,36)  
medical = range(16,36)  
  
def excel_unify():  
    # create new dataframe for the resulting dataframe  
    all_data = pd.DataFrame()  
  
    # read all excels  
    df_rev1 = pd.read_excel(rev1, skiprows=1, na_filter=  
        False)
```

```

df_rev2 = pd.read_excel(rev2, skiprows=1, na_filter=
    False)
df_rev3 = pd.read_excel(rev3, skiprows=1, na_filter=
    False)
df_rev4 = pd.read_excel(rev4, skiprows=1, na_filter=
    False)
df_rev5 = pd.read_excel(rev5, skiprows=1, na_filter=
    False)
df_rev6 = pd.read_excel(rev6, skiprows=1, na_filter=
    False)

# set as index column with article identifier
df_rev3_2 = df_rev3.set_index('Identifier', drop=False)
df_rev1_2 = df_rev1.set_index('Identifier', drop=False)
df_rev2_2 = df_rev2.set_index('Identifier', drop=False)

rev3_rev1 = []
numbers = range(1, 57)
for i in numbers:
    root_id = 'SR2020-00{0}'.format(i)
    rev3_rev1.append(root_id)

rev2_rev1 = []
numbers = range(57, 114)
for i in numbers:
    if i < 100 or i > 101:
        root_id = 'SR2020-00{0}'.format(i)
    else:
        root_id = 'SR2020-0{0}'.format(i)
    rev2_rev1.append(root_id)

rev2_rev3 = []
numbers = range(114, 171)
for i in numbers:
    root_id = 'SR2020-00{0}'.format(i)
    rev2_rev3.append(root_id)

```



```
for index , id in enumerate(rev3_rev1):
    for col in general_medical:
        lt = df_rev4[(df_rev4['Identifier'] == id)].iloc
            [0][col]
        df_rev1_2.iloc[index , col] = lt
    all_data = all_data.append(df_rev1_2.loc[id , :])
    all_data = all_data[df_rev1_2.columns]
    for col in medical:
        vc = df_rev5[(df_rev5['Identifier'] == id)].iloc
            [0][col]
        df_rev3_2.iloc[index , col] = vc
    all_data = all_data.append(df_rev3_2.loc[id , :])
    all_data = all_data[df_rev3_2.columns]
finish_index = index

for index , id in enumerate(rev2_rev1 , start=finish_index
+1):
    for col in general_medical:
        vc = df_rev5[(df_rev5['Identifier'] == id)].iloc
            [0][col]
        df_rev2_2.iloc[index , col] = vc
    all_data = all_data.append(df_rev2_2.loc[id , :])
    all_data = all_data[df_rev2_2.columns]
    for col in medical:
        lu = df_rev6[(df_rev6['Identifier'] == id)].iloc
            [0][col]
        df_rev1_2.iloc[index , col] = lu
    all_data = all_data.append(df_rev1_2.loc[id , :])
    all_data = all_data[df_rev1_2.columns]
finish_index = index

for index , id in enumerate(rev2_rev3 , start=finish_index
+1):
    for col in medical:
```

```

        lt = df_rev4[(df_rev4['Identifier'] == id)].iloc
            [0][col]
        df_rev2_2.iloc[index, col] = lt
    all_data = all_data.append(df_rev2_2.loc[id, :])
    all_data = all_data[df_rev2_2.columns]
    for col in general_medical:
        lu = df_rev6[(df_rev6['Identifier'] == id)].iloc
            [0][col]
        df_rev3_2.iloc[index, col] = lu
    all_data = all_data.append(df_rev3_2.loc[id, :])
    all_data = all_data[df_rev3_2.columns]

writer = pd.ExcelWriter('Extraccion_IA.xlsx', engine=
    'xlsxwriter')
all_data.to_excel(writer, sheet_name='SR_IA', index=
    False)

workbook = writer.book
worksheet = writer.sheets['SR_IA']

cell_format = workbook.add_format()
cell_format.set_align('justify')

worksheet.set_column('A:A', 9, cell_format)
worksheet.set_column('B:B', 13, cell_format)
worksheet.set_column('C:C', 15, cell_format)
worksheet.set_column('D:D', 22, cell_format)
worksheet.set_column('E:E', 18, cell_format)
worksheet.set_column('F:F', 10, cell_format)
worksheet.set_column('G:G', 18, cell_format)
worksheet.set_column('H:L', 22, cell_format)
worksheet.set_column('K:O', 15, cell_format)
worksheet.set_column('Q:AJ', 15, cell_format)
worksheet.set_column('P:P', 22, cell_format)
worksheet.set_column('AK:AP', 18, cell_format)
worksheet.set_column('AQ:AQ', 22, cell_format)

```

```
worksheet.set_column('AR:BA', 18, cell_format)
worksheet.set_column('BA:BA', 20, cell_format)
writer.save()
```

## A.2. Python Script 2

Este script emplea la librería `bibtexparser` para leer los archivos `.bib` descargados de las bases de datos. Se eliminan los duplicados y mapea cada artículo con las bases de datos en las que se ha encontrado. La salida es un documento CSV donde están contenidos todos los artículos no duplicados con los que se ha comenzado la revisión, siguiendo el siguiente formato: *título, fuente1, fuente2*.

```
# -*- coding: utf-8 -*-
from difflib import SequenceMatcher
import string
import bibtexparser
import collections
import csv

# devuelve un ratio sobre 1 de la coincidencia en dos
strings

def coincidencia(a, b):
    return SequenceMatcher(None, a, b).ratio()

def normaliza_texto(titulo):
    titulo_norm = titulo.lower()
    return titulo_norm.translate(str.maketrans('', '',
        string.punctuation))

def leerbibtex_pubmed():
    titulos, titulos_norm = [], []
    with open('Files/pubmed2020100_allyears.bib', encoding="
        utf8") as bibtex_file:
        bib_database = bibtexparser.load(bibtex_file)
        for elem in bib_database.entries:
```

---

```

        if int(elem['year']) > 2008:
            titulo = (elem['title']).replace('}', '').
                replace('{', '')
            titulos.append(titulo)
            titulos_norm.append(normaliza_texto(titulo))
    return titulos, titulos_norm

def leerbibtex_scopus():
    titulos, titulos_norm = [], []
    with open('Files/scopus20201002.bib', encoding="utf8")
        as bibtex_file:
            bib_database = bibtexparser.load(bibtex_file)
            for elem in bib_database.entries:
                titulo = (elem['title']).replace('}', '').
                    replace('{', '')
                if 'RETRACTED_ARTICLE:' not in titulo:
                    titulos.append(titulo)
                    titulos_norm.append(normaliza_texto(titulo))
    return titulos, titulos_norm

def leerbibtex_xplore():
    titulos, titulos_norm = [], []
    with open('Files/xplore20201002.bib', encoding="utf8")
        as bibtex_file:
            bib_database = bibtexparser.load(bibtex_file)
            for elem in bib_database.entries:
                titulo = (elem['title']).replace('}', '').
                    replace('{', '')
                titulos.append(titulo)
                titulos_norm.append(normaliza_texto(titulo))
    return titulos, titulos_norm

def leerbibtex_wos():

```

```

    titulos , titulos_norm = [], []
    with open('Files/wos20201002.bib', encoding="utf8") as
        bibtex_file:
            bib_database = bibtexparser.load(bibtex_file)
            for elem in bib_database.entries:
                titulo = (elem['title']).replace('}', '').
                    replace('{', '').replace('\n', '_')
                titulos.append(titulo)
                titulos_norm.append(normaliza_texto(titulo))
    return titulos , titulos_norm

def leerbibtex_acm():
    titulos , titulos_norm = [], []
    parser = bibtexparser.bparser.BibTexParser(
        common_strings=True)
    with open('Files/acm20201002.bib', encoding="utf8") as
        bibtex_file:
            bib_database = bibtexparser.load(bibtex_file , parser
                =parser)
            for elem in bib_database.entries:
                titulo = (elem['title']).replace('}', '').
                    replace('{', '')
                titulos.append(titulo)
                titulos_norm.append(normaliza_texto(titulo))
            return titulos , titulos_norm

res_pubmed , res_pubmed_n = leerbibtex_pubmed()
res_scopus , res_scopus_n = leerbibtex_scopus()
res_xplore , res_xplore_n = leerbibtex_xplore()
res_wos , res_wos_n = leerbibtex_wos()
res_acm , res_acm_n = leerbibtex_acm()

definitiva = {}
Set_global = set(res_scopus)

```

```

Set_global.update(res_xplore)
Set_global.update(res_wos)
Set_global.update(res_pubmed)
Set_global.update(res_acm)

lista_normalizados = []
num_doc = []
for i in Set_global:
    norm = normaliza_texto(i)
    if norm not in lista_normalizados:
        definitiva.setdefault(i, [])
        if norm in res_scopus_n:
            definitiva[i].append('Scopus')
        if norm in res_xplore_n:
            definitiva[i].append('IEEE')
        if norm in res_wos_n:
            definitiva[i].append('WoS')
        if norm in res_pubmed_n:
            definitiva[i].append('Pubmed')
        if norm in res_acm_n:
            definitiva[i].append('ACM')
    lista_normalizados.append(norm)

definitiva_ordenada = collections.OrderedDict(sorted(
    definitiva.items()))

with open('result.csv', 'w', encoding='utf-8', newline='')
    as f:
        writer = csv.writer(f, delimiter=';')
        for row in definitiva_ordenada.items():
            writer.writerow(row)

```

### A.3. Python Script 3

Script de creación de la figura de descriptores: Figura 5.1. Se ha empleado la librería matplotlib.

```
# -*- coding: utf-8 -*-
import pandas as pd
from collections import defaultdict
from matplotlib import pyplot
import numpy as np
import itertools

def keywords():

    chart = '
        DataChart_SR_Plantilla_Extracci n_ NICA_actual.xlsx
    '

    d = defaultdict(int)
    df = pd.read_excel(chart, skiprows=1, na_filter=False,
        encoding='utf-8')
    res = []
    for entry in df['Author_Keywords']:
        if ';' in entry:
            each = entry.split(";")
            for i in each:
                i = i.strip().lower()
                i = i.replace('\r', '_').replace('\n', '').
                    replace('.', '').replace(u'\uffff', '')
                res.append(i)

    label_data = [k for k, v in d.items() if float(v) >=
        5.0]
    d_subset = {k: d[k] for k in label_data}

    s = sorted(d_subset.items(), key=lambda x: x[1], reverse
        =True)
    d = dict(s)
    d = {k.capitalize(): v for k, v in d.items()}
    labels = list(d.keys())

    values = list(d.values())
```

```

colors = ['#D88C9A', '#FFC4D6', '#FFBC42', '#99C1B9', '
        #8E7DBE', '#F25F5C', '#C1FBA4', "#247BA0", "#E0DCDC",
        "#6A994E", "#BDD5EA", "#E77728", "#FF5D8F", "
        #368F8B", "#E0FBFC"]
fig1, ax1 = pyplot.subplots()
explode = (
0.05, 0.05, 0.05, 0.05, 0.05, 0.05, 0.05, 0.05, 0.05,
0.05, 0.05, 0.05, 0.05, 0.05, 0.05, 0.05, 0.05, 0.05,
0.05)

pyplot.pie(values, labels=labels, colors=colors, autopct
        ='%1.1f%%', startangle=90, pctdistance=0.85,
        explode=explode)
centre_circle = pyplot.Circle((0, 0), 0.70, fc='white')
fig = pyplot.gcf()
fig.gca().add_artist(centre_circle)
ax1.axis('equal')
pyplot.tight_layout()
pyplot.show()
pyplot.savefig('keywords_graph.png')

```

## A.4. Python Script 4

Script de creación de la figura de productos finales: Figura 5.3. De manera análoga se ha realizado la figura que ilustra los subcampos de IA: Figura 5.4. Se ha empleado la librería matplotlib.

```

# -*- coding: utf-8 -*-
import pandas as pd
from collections import defaultdict
from matplotlib import pyplot
import numpy as np
import itertools

def finalproduct():

```



```

chart = '
    DataChart_SR_Plantilla_Extracci n_ NICA_actual.xlsx
'

total_papers = 156
d = defaultdict(int)
df = pd.read_excel(chart, skiprows=1, na_filter=False)
for entry in df['Final_product']:
    if ';' in entry:
        each = entry.split(";")
        for i in each:
            if i != '':
                d[i.strip().lower()] += 1
    else:
        if entry != '':
            d[entry.strip().lower()] += 1

label_data = [k for k, v in d.items() if float(v) > 1.0]
d = {k: d[k] for k in label_data}
d = {k.capitalize(): v for k, v in d.items()}
x = list(d.keys())
values = list(d.values())
percentages = []
for i in values:
    i = (i * 100) / total_papers
    i = round(i, 2)
    percentages.append(i)

colors = ['#8DD3C7', '#FED75C', '#BEBADA', '#FB8072', '
    #80B1D3', '#FDB462', '#AEDF61', "#FCCDE5", "#D9D9D9",
    "#BC80BD", "#CCEBC5", "#FFED6F", "#D62728", "#
    FF7F00", "#6A3D9A", "#FB9A99", "#BCBD22", "
    #7F7F7F"]

explode = (0.05, 0.05, 0.05, 0.05, 0.05, 0.05, 0.05,
    0.05, 0.05, 0.05, 0.05, 0.05, 0.05, 0.05, 0.05,
    0.05, 0.05, 0.05, 0.05)

```

```

patches, texts = pyplot.pie(d.values(), colors=colors,
                             startangle=90, pctdistance=0.85, explode=explode)
labels = ['{0}__{1:1.2f}%'.format(i, j) for i, j in
          zip(d.keys(), percentages)]

sort_legend = True
if sort_legend:
    patches, labels, dummy = zip(*sorted(zip(patches,
                                              labels, d.values()),
                                       key=lambda x: x
                                              [2],
                                       reverse=True))

pyplot.legend(patches, labels, loc='left_center',
              bbox_to_anchor=(-0.1, 1.),
              fontsize=8)

pyplot.savefig('piechart_finalproducts.png', bbox_inches
              ='tight')

```

## A.5. Python Script 5

Script de creación de la figura de adquisición de datos: Figura 5.5. De manera análoga se ha realizado la figura que ilustra los lenguajes de programación: Figura 5.6 y la que ilustra los procesos asociados al embarazo: Figura 5.7. Se ha empleado la librería matplotlib.

```

# -*- coding: utf-8 -*-
import pandas as pd
from collections import defaultdict
from matplotlib import pyplot
import numpy as np
import itertools

def data_acquisition():

```

---

```

chart = '
    DataChart_SR_Plantilla_Extracci n_ NICA_actual.xlsx
'

d = defaultdict(int)
df = pd.read_excel(chart, skiprows=1, na_filter=False)

for entry in df['Data_acquisition']:
    if ';' in entry:
        each = entry.split(";")
        for i in each:
            i = i.replace('\r', '').replace('\n', '').strip()
            if ":" in i:
                if i != '':
                    i = i.split(":")[0]
                    d[i.strip().lower()] += 1
            else:
                if i != '':
                    d[i.strip().lower()] += 1
        else:
            if entry != 'N/A':
                if ":" in entry:
                    j = entry.split(":")[0]
                    if j != '':
                        d[j.strip().lower()] += 1
                else:
                    if entry != '':
                        d[entry.strip().lower()] += 1

s = sorted(d.items(), key=lambda x: x[1], reverse=True)
d = dict(s)
d = {k.capitalize(): v for k, v in d.items()}

pyplot.rcParams()
beautifying()
y = list(d.keys())

```

```

y_pos = np.arange(len(y))
fig, ax = pyplot.subplots(figsize=(6, 4.5))

papers = d.values()

ax.barh(y_pos, papers, align='center', color="#8c4966",
        alpha=0.6)
ax.set_yticks(y_pos)
ax.set_yticklabels(y, fontsize=14)
ax.invert_yaxis() # labels read top-to-bottom
ax.set_xlabel('Number_of_papers', fontsize=14,
              fontweight='black', color='#333F4B')
ax.set_title('Data_acquisition', fontsize=14, fontweight
            = 'black', color='#333F4B')
ax.spines['top'].set_color('none')
ax.spines['right'].set_color('none')
ax.spines['left'].set_smart_bounds(True)
ax.spines['bottom'].set_smart_bounds(True)

pyplot.show()
pyplot.savefig('out.png')

```

## A.6. Python Script 6

Script de creación de las figuras que ilustran los años de publicación y la tipología de los estudios incluidos: Figura 4.12 y Figura 4.13. Se ha empleado la librería matplotlib.

```

# -*- coding: utf-8 -*-
import pandas as pd
from collections import defaultdict
from matplotlib import pyplot
import numpy as np
import itertools

def study_characteristics():
    d = defaultdict(int)
    d_type = defaultdict(int)

```

```
d_type['Article'] = 94
d_type['Conference_proceedings'] = 56
d_type['Book'] = 6
with open('Files/INCLUIDOS_SCOPING.bib', encoding="utf8")
    as bibtex_file:
    bib_database = bibtexparser.load(bibtex_file)

    for elem in bib_database.entries:
        d[int(elem['year'])] +=1
s = sorted(d.items(), key=lambda x: x[0], reverse=False)
d = dict(s)

with open('Files/INCLUIDOS_SCOPING.bib', encoding="utf8")
    as file:
    print(file)
colors = ['#005b96']

pyplot.bar(range(len(d)), list(d.values()), align='
    center', color = colors)
pyplot.xticks(range(len(d)), list(d.keys()))

pyplot.xlabel('Publication_year', fontsize=12,
    fontweight='black', color='#333F4B')
pyplot.ylabel('Number_of_papers', fontsize=12,
    fontweight='black', color='#333F4B')
pyplot.show()

s = sorted(d_type.items(), key=lambda x: x[1], reverse=
    True)
d = dict(s)
d = {k.capitalize(): v for k, v in d.items()}

labels = list(d.keys())
print(len(labels))
values = list(d.values())
colors = ['#3f9bb6', '#7abfc9', '#a4f6f0']
```

```
fig1 , ax1 = pyplot.subplots()  
pyplot.pie(values , labels=labels , colors=colors , autopct  
    = '%1.1f%%', startangle=90)  
ax1.axis('equal')  
pyplot.tight_layout()  
pyplot.show()
```